

保健統計学実習

第1日目
第1回 EZRの使い方、データセットの読み込み、
第2回 頻度集計、記述統計、相関、エクセルの基礎
第3回 Python設定,基本コードPython設定

滋賀医科大学 NCD疫学研究センター
医療統計学部門
原田 亜紀子
(aharada@belle.shiga-med.ac.jp)

講義・演習スケジュール

回	日	内容
1	8/27(木)	1 R, EZR の使い方, データセットの読み込み, 頻度集計
		2 記述統計, 相関
		3 エクセルの基礎, Python 設定, 基本コード
2	8/28(金)	4 仮説検定の基礎, カイ2乗検定, マクネマー検定
		5 t 検定, Wilcoxon 検定, サンプルサイズ設計
		6 調査データ解析
3	9/1(火)	7 分散分析
		8 重回帰分析
		9 ロジスティック回帰, Poisson 回帰
4	9/2(水)	10 生存時間解析
		11 クラスタ分析
		12 AI Deep learning 演習(1) * Python Collaboratory 使用
5	9/4(金)	13 AI Deep learning 演習(2) * Python Collaboratory 使用
		14 AI Deep learning 演習(3) * Python Collaboratory 使用
		15 解析実習まとめ(復習・課題の時間)

イントロダクション

実習の進め方

- ・ 集中講義・実習(計5日)
- ・ 講義とPCを使用した実習を並行していきます
- ・ 講義資料、サンプルデータは電子ファイルで配布
- ・ 講義・実習はR(EZR,R-studio),Pythonを使用して行います。
- ・ 成績評価
 - ・ 講義に対する参加意欲(40%)、講義時に課する課題と講義終了時に課するレポート(60%)により評価する。

本日の実習内容

1 統計パッケージR(EZR)の使い方
データセットの読み込み、頻度集計、記述統計

2 記述統計の基礎
1) 位置: 平均, メディアン, パーセント
2) ばらつき: range, inter-quartile range, CV
3) 分布: 歪度skewness, 尖度kurtosis, 正規性
4) グラフ
5) 2変量の相関: Correlation

3 EZRコード保存

4 エクセルの基礎

5 Python設定,基本コード

◆使用するデータファイル

Health1
Health3
Excelドリル

CSV

XLS

「.csv」ファイルと「.sav」(SPSS
データセット)で提供します

5

本日の到達目標

• 統計パッケージの1つであるRの操作に慣れる

- 様々なデータセットがある状況で、Rに読み込みができるようになる
- データの記述データを出力し、特徴をつかめるようになる
 - 記述統計量
 - 変数間の相関
 - 様々なグラフ
- 2群の比較(連続量)の検定手法 t検定、Wilcoxon検定の理解

• データ作成などに用いるExcelにおいて、使用頻度の高い関数を学ぶ

- 解析を行うデータセットを作る
- Excelの基本操作

• 最終日のAI演習に向けてPythonの導入(基本操作)

6

第1回

1. 統計パッケージR(EZR)の使い方

2. データセットの読み込み

3. 頻度集計

7

統計パッケージ 代表的なもの

• SAS

• R

• Python

• STATA

プログラミング(code入力) タイプ

• SPSS


• JMP

ポイント・クリック インターフェースタイプ

• (EZR:R)

• (SAS Enterprise Guide)

8



EZR (最新版 Ver.1.68)

自治医科大学附属さいたま医療センター 血液科の神田善伸教授が統計解析環境RのGUI環境であるRコマンドをカスタマイズしたものがEZRである。

EZRでは、医学統計学における諸種の統計的方法をマウスのみで実行できる。

ダウンロードは、ブラウザで「EZR」と入力すれば、左図のホームページがトップになる。

<http://www.jichi.ac.jp/saitama-sct/SaitamaHP/files/statmed.html>

京都府立大の解析環境では利用できる(インストール済)状況となっている

EZRを起動してみよう

現在32-bit版は提供されていない

こんな画面

出力結果の一例

Rスクリプト

EZRではメニューで選ばれた解析方法をRに変換して実行している。ここは、そのRでの実行コマンドが表示されている。


Rでの実行コマンド (省略してよい)

Rでの結果 (省略してよい)

EZRでの結果 (Rでの結果の要約)

EZRの結果は日本語で表示される

Rとの関連



R:プログラム(スクリプト)ベース
↓
Rコマンドー: コマンドベース
*解析機能が限定
↓
EZR:カスタマイズ機能で、多くの
解析機能を追加

13

EZRに関する教科書など




改定4版

14

参考資料(ワークブック系) *資料として保存してあります

- 下川敏雄.EZR による医学統計入門 第2.0版 (和歌山県立医科大学附属病院 臨床研究センター)



15

EZRの基本操作、解析の流れ

- データの読み込み
- データの整備(変数ビューの設定)
- データの加工
- 分析・グラフの作成
- 分析結果の出力



16

EZRの画面

各操作(データセット・解析・グラフ)メニュー

選択したメニューのコードが表示。コードで分析も可能(学習用に使える)

結果出力

17

EZRにおけるメニュー

【統計解析】

各操作(データセット・解析・グラフ)メニュー

選択したメニューのコードが表示。コードで分析も可能(学習用に使える)

結果出力

18

EZRにおけるメニュー

【統計解析】

各操作(データセット・解析・グラフ)メニュー

選択したメニューのコードが表示。コードで分析も可能(学習用に使える)

結果出力

19

EZRにおけるメニュー

【グラフ】

各操作(データセット・解析・グラフ)メニュー

選択したメニューのコードが表示。コードで分析も可能(学習用に使える)

結果出力

20

1) データを読み込む

①読み込む方法

- 直接データ入力
- 外部ファイル
 - Excel
 - SPSSデータセット
 - .
 - .
 - .

②EZRで読み込むことができるファイル形式


- SPSSファイル
- Excelスプレッドシート
- CSVファイル
- SASデータ・ファイル
- Stataデータファイル
- など

21

21

読み込むデータセット

使用するデータファイル
「health.csv」を読み込んでみる



ある町の健診(一部加工)データ

「health.csv」または「health.sav」

*データは同じ


- 5変数
 - 性別(sex) 文字
 - 年齢(age) 数値
 - 収縮期血圧(sbp) 数値
 - 拡張期血圧(dbp) 数値
 - 食塩摂取量(salt) 数値



22


22

データの読み込み



.csvファイルはココ

.savファイルはココ



データセット名を入力: Health

変数名をつける Health

23

23

2)EZRのメニュー画面 変数ビュー画面

データセットの確認




読み込んだ変数の特性など




24

24

- 平均値(標準偏差)で要約する場合には、「連続変数(正規分布)」を選択する。
- 「出力先」において結果をcsvファイルに保存する場合には、「csvファイル」を選択する。
- 「四分位範囲」で中央値のバラツキを表示する場合には「四分位変数」を選択する。



変数	グループ	F	M	P値
n		244	177	
sex (%)				
	F	244 (100.0)	0 (0.0)	<0.001
	M	0 (0.0)	177 (100.0)	
age		58.45 (8.06)	59.53 (7.45)	0.168
dbp		72.23 (9.50)	76.62 (11.53)	<0.001
salt		9.39 (2.10)	9.44 (1.85)	0.864
sbp		122.73 (16.27)	125.49 (15.80)	0.083



Factor	Group	HTN_c						p-value
		1	2	3	4	5	6	
n		161	74	151	31	3	1	
sex (%)	F M	110 (68.3) 51 (31.7)	35 (47.3) 39 (52.7)	83 (55.0) 68 (45.0)	15 (48.4) 16 (51.6)	1 (33.3) 2 (66.7)	0 (0.0) 1 (100.0)	0.013
age		57.17 (8.62)	59.77 (7.81)	60.37 (6.77)	58.29 (8.99)	61.39 (5.89)	64.00 (NA)	NA
dbp		85.88 (5.83)	71.58 (5.05)	80.37 (6.32)	85.39 (10.92)	94.33 (13.43)	130.00 (NA)	NA
salt		9.08 (1.82)	9.19 (1.89)	9.64 (2.10)	9.77 (1.86)	10.50 (3.81)	10.20 (NA)	NA
sbs		108.19 (7.89)	124.43 (3.09)	135.09 (10.48)	144.03 (10.25)	162.39 (2.52)	180.00 (NA)	NA

データの 種類

3298

質的・量的の2種類に大別される

- 量的データ
 - 計量データ: 血圧のように、数値単位があるデータで、計量データは、小数点以下の値をとり連続的に切れ目がないため呼ぶこともある。
 - 計数データ: 個数や人数のように個数あるいは回数として測定されたデータである。
- 質的データ
 - 2値データ: 名義・順序カテゴリカル・データに分けられる。
 - 治療改善・非改善のように、アウトカムが2カテゴリで表されるデータ名義データ: 状態をラベルとして扱う。疾患の種類や血液型がここに該当す。
 - 順序データ: 進行程度を軽度、中程度のカテゴリで測る場合<順序関係が成り立つ>
 - 多値データは、3個以上のカテゴリで表される。

情報量 ↓ 大	分類 (水準)		解説と例	データの種類
	小	名義尺度 同一性	 データは、単に記号としての意味だけを表す。 大小関係や順序の概念はない 例: 職業・性別・背番号・診断名	質的データ (カテゴリカル・データ)
		順序尺度 同一性 + 順序性	 データは、順序の概念があり、大小関係を表す。 例: 服サイズ (L・M・S)、薬効 (悪化・無効・有効・著効)	
		間隔尺度 同一性 + 順序性 + 加法性	 ある一定の単位を基にして測定された尺度 例: 摂氏・華氏の温度・暦年	量的データ
	大	比尺度 同一性 + 順序性 + 加法性 + 等比性	 ある一定の単位を基にして測定された尺度に加え原点が存在 原点=なし、0=なしとなる尺度です。 例: 長さ・重さ・濃度・人数・絶対温度	

2 記述統計の基礎

＊読み込んだデータセット(health.csv)

ある町で実施した健康診断データ N=421(仮想)

- 年齢: 40-60yr.の男女
- 変数
 - 性別, 年齢, 収縮期血圧 (SBP), 拡張期血圧 (DBP)
 - 尿中の食塩排泄量 (SALT)

•データセット名=health



解析手法の選択
データの型と解析の目的

これから何回も登場します
解析を行うときには確認をしよう！！

	データの型		
	2値	連続	生存時間
集計・記述	1変量 頻度集計	ヒストグラム 要約統計量	Kaplan-Meier法
	2変量 分割表	散布図、相関係数	
解析の目的	群比較	χ^2 検定 Fisher 直接確率検定	t検定 Wilcoxonの 順位和検定
	多群比較	コクランマンテル 検定	分散分析 ログランク検定
モデルあてはめ	ロジスティック回帰	重回帰分析	Cox回帰

分析・グラフの作成 記述統計の出力(その1)

記述統計の出力(その2) 「標準メニューから」

標準メニュー：統計量

	mean	sd	se(mean)	IQR	cv	skewness	kurtosis	0%	25%	50%	75%	100%	n
age	58.904988	7.815765	0.38091710	11.0	0.1326843	-0.8350078	-0.3264182	40.0	54.0	61.0	65.0	69.0	421
dbp	74.076010	10.244344	0.49927879	14.0	0.1382950	0.6247807	1.4475364	49.0	67.0	73.0	81.0	130.0	421
salt	9.361995	2.028025	0.09883989	2.7	0.2166232	0.2995741	0.3197815	3.8	7.9	9.3	10.6	17.2	421
sbp	123.888361	16.115783	0.78543520	23.0	0.1300831	0.3612619	0.3200493	91.0	112.0	123.0	135.0	187.0	421

平均
標準偏差・分散
標準誤差

四分位範囲
変動係数

• 歪度
• 尖度

↑
• パーセンタイル

要約統計量 各変数の特徴を見てみよう

• データを要約する統計量

1) 位置の指標

- 平均値(算術平均)
 - 他に 幾何平均, 加重平均, 調和平均, 両側切り捨て(トリム)平均
- 中央値
- 最頻値
- 分位点(パーセンタイル) など

2SD

• 散らばりの指標

- 分散
- 標準偏差
- 範囲(レンジ)
- 四分位偏差, 四分位範囲

• 形状の指標

- 歪度
- 尖度

統計学の復習です

38

1)位置の指標

39

平均値・中央値・最頻値

世帯平均収入の例

平均値は10,000世帯を年間収入をすべて足し上げて、世帯数10,000で割った数値。この例の場合、平均値より年間収入が多い世帯は3,875世帯で、平均値と直線的な「真ん中」では割れている。

中央値は10,000世帯を年間収入の多い順に並べて、上から数えて5,000世帯と下から数えて5,000世帯の数値。

(左) 最頻値(Mode)
度数分布で度数が最大の階級値

中央値(Median)
昇順、降順に並べた場合に中央に来る値

(右) 平均値(Mean)
標本データを合計し、標本サイズで除した値

正規分布


正規分布であれば3つは一致

右に歪んだ分布


辞書順の逆の並び

図1 正規分布と左に歪んだ分布における平均値・中央値・最頻値


40




41



42



43



44

2)散らばりの指標

45


散らばりの指標

- 平均値: $\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$
- 偏差: $x_i - \bar{x}$
- 分散: $S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
- 標準偏差 $S = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$

46


母集団と標本

- 多くの調査では、母集団を想定し、そこから選んだ一部の集合(標本)を調べることで(推定・検定)、母集団の特性を知る
- 母集団の特性を知るためには、標本抽出のやり方が重要となる



47

標本と母集団



48

母数の推定

- 平均と分散の推定量
 - $\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
 - $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ……不偏分散
- 区間推定
 - 真の値が、ある区間に入る確率を $1 - \alpha$ になるように保障する方法
 - 95%信頼区間 ($\alpha = 0.05$) が用いられる
 - 95%信頼区間 = 推定値 $\pm 1.96 \times$ 標準誤差
- 標準誤差
 - 標本平均のバラツキの指標
 - 標本平均の推定値の精度
 - 推定値の標準偏差

$$SE = \frac{SD}{\sqrt{n}}$$

49

	mean	sd	se(mean)	iqr	cv	skewness	kurtosis	U%	25%	50%	75%	100%	n
age	56.904988	7.815765	0.38091710	11.0	0.1326843	-0.8350078	-0.3284162	40.0	54.0	61.0	65.0	69.0	421
dbp	74.076010	10.244344	0.49927879	14.0	0.1382950	0.6247807	1.4475364	49.0	67.0	73.0	81.0	130.0	421
salt	9.361995	2.028025	0.09883989	2.7	0.2166232	0.2995741	0.3197815	3.8	7.9	9.3	10.6	17.2	421
sbp	123.888361	16.115783	0.78543520	23.0	0.1300831	0.3612619	0.3200493	91.0	112.0	123.0	135.0	187.0	421

平均
標準偏差・分散
標準誤差

四分位範囲
変動係数

歪度
尖度

パーセンタイル

分散 = 259.718
標準偏差 = $\sqrt{259.718} = 16.116$
標準誤差 = $SD / \sqrt{n} = 0.785$

50

95%信頼区間の解釈

- 無作為抽出により100個の信頼区間を求めた
- そのうちの95個は真値を含むような区間

標本から推定された母平均の信頼区間

100個の信頼区間のうち5個は、推定された母平均の信頼区間に母平均が含まれていないと考える

母平均 μ
(本当は分からない)

51

3)形状の指標

52

要約統計量

- データを要約する統計量
 - 位置の指標
 - 平均値(算術平均)
 - 他に 幾何平均, 両側切り捨て(トリム)平均
 - 中央値
 - 最頻値
 - 分位点 など
 - 散らばりの指標
 - 分散
 - 標準偏差
 - 範囲(レンジ)
 - 四分位偏差
 - 形状の指標
 - 歪度
 - 尖度

53

歪度 Skewness(b_1), 尖度 Kurtosis(b_2)

Skewness: distortion

Kurtosis: sharpness

歪度 Skewness: distortion

尖度 Kurtosis: sharpness

$$b_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})^3 / (n-1)}{SD^3}, \quad b_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^4 / (n-1)}{SD^4} - 3$$

54

正規分布

平均 μ , 分散 σ^2 がわかれば分布形が推定できる
データの平均と分散を利用して検定や解析が行える

55

正規分布かどうか？

- パラメトリックな手法(ある分布を仮定した手法)を用いるかどうか判断する際に、正規分布かどうか確認する
- 正規分布が前提

56

分布の判断

	mean	sd	se(mean)	IQR	cv	skewness	kurtosis	UX	25%	50%	75%	100%	n
age	56.904988	7.815765	0.38091710	11.0	0.1328943	-0.6350078	-0.3294182	40.0	54.0	61.0	65.0	68.0	421
dbp	74.076010	10.244344	0.49927879	14.0	0.1382950	0.6247807	1.4475564	49.0	67.0	73.0	81.0	130.0	421
salt	9.361995	2.028025	0.09889889	2.7	0.2186232	0.2995741	0.3197815	3.8	7.8	9.3	10.6	17.2	421
sbp	123.888361	16.115783	0.78543520	23.0	0.1300831	0.3612619	0.3200493	91.0	112.0	123.0	135.0	187.0	421

平均
標準偏差・分散
標準誤差

四分位範囲
変動係数

• 歪度
• 尖度

パーセンタイル

分散 = 259.718
標準偏差 = $\sqrt{259.718} = 16.116$

57

分布の判断: Q-Qプロットをみてみよう

[分析]—[記述統計]—[正規Q-Qプロット]

58

尖度・歪度・Q-Qプロット

SBP

DBP

Salt

尖度・歪度の目安 絶対値が1前後であれば(越えていなければ) 正規分布に近い

```
> skewness.kurtosis(health$sbp)
```

Skewness(歪度、正規分布では0) 0.361
Kurtosis(尖度、正規分布では0) 0.320

```
> skewness.kurtosis(health$dbp)
```

Skewness(歪度、正規分布では0) 0.625
Kurtosis(尖度、正規分布では0) 1.450

```
> skewness.kurtosis(health$salt)
```

Skewness(歪度、正規分布では0) 0.30
Kurtosis(尖度、正規分布では0) 0.32

59


尖度・歪度

1.正規確率プロットにより、データは正規分布しているか？判断します

2.正規性からの逸脱はどのようなものか？

→データが歪んでいる、予想よりテールが短い、予想よりテールが長い

60



61

正規性の検定について

Skewness(歪度、正規分布では0) 0.361
Kurtosis(尖度、正規分布では0) 0.320

Asymptotic one-sample Kolmogorov-Smirnov test
正規分布に従う(仮説)→棄却されない→従う
data: health\$sbp
D = 0.037474, p-value = 0.5955
alternative hypothesis: two-sided

> # サンプル数が5000以下の場合のみShapiro-Wilk検定の結果も表示されます。(サンプル数 = 421)

> shapiro.test(health\$sbp)

Shapiro-Wilk normality test
正規分布に従う(仮説)→棄却→従わない
data: health\$sbp
W = 0.98514, p-value = 0.0002601


62

4) 2変量の相関


63

散布図 血圧・年齢の関連 [グラフ]-[散布図]


64




65



66



67





68

69


71

70





EZRによる 変数のカテゴリー化



変数のカテゴリー化

【アクティブデータセット】→【変数の操作】
→【連続変数を指定した閾値で3群以上に分けた変数を作成する】

収縮期血圧区分

収縮期血圧区分と食塩摂取

Figure 1 consists of two parts. On the left is a screenshot of the R console window. The script being executed is as follows:

```
# 1. データを読み込む
# 2. 年齢別の平均血圧を計算する
# 3. 結果をファイルに保存する

# 1. データを読み込む
data.csv <- read.csv("data.csv")
mean.csv <- data.frame()

# 2. 年齢別の平均血圧を計算する
for (age in unique(data.csv$age)) {
  mean.csv <- rbind(mean.csv, data.frame(
    age = age,
    mean_sbp = mean(data.csv$sbp[data.csv$age == age])
  ))
}

# 3. 結果をファイルに保存する
write.csv(mean.csv, "mean.csv", row.names = FALSE)
```

On the right is a boxplot showing the distribution of blood pressure (sbp) for different age groups. The y-axis is labeled 'sbp' and ranges from 4 to 16. The x-axis is labeled 'age' and shows age groups: 120-129, 130-139, 140-149, 150-159, 160-169, and 170-. The boxplots show that the median blood pressure increases with age, with the 160-169 group having the highest median and the 170- group having the lowest median.

第1日目 の課題(1)

1. 血圧区分(変数のカテゴリー化)、箱ひげ図の作成ができる
→血圧区分ごとの食塩摂取量について、箱ひげ図を作成
2. 血圧(SBP,DBP)、年齢、食塩摂取量について、散布図、相関を検討し、4変数の関係性について、気づいた点を記述せよ。
適宜、必要なグラフを使用し説明すること
ヒント:
血圧同士の相関は???
食塩摂取と血圧の相関は???
年齢と収縮期血圧、拡張期血圧の散布図、相関は???

第2回

レポート機能, 各種グラフ

R-studioの使い方


EZR⇔R

レポート機能 R markdown

- 例えば、演習データセット「health」で、男女別のSBPについてバイオリンプロットを作成し、レポートする



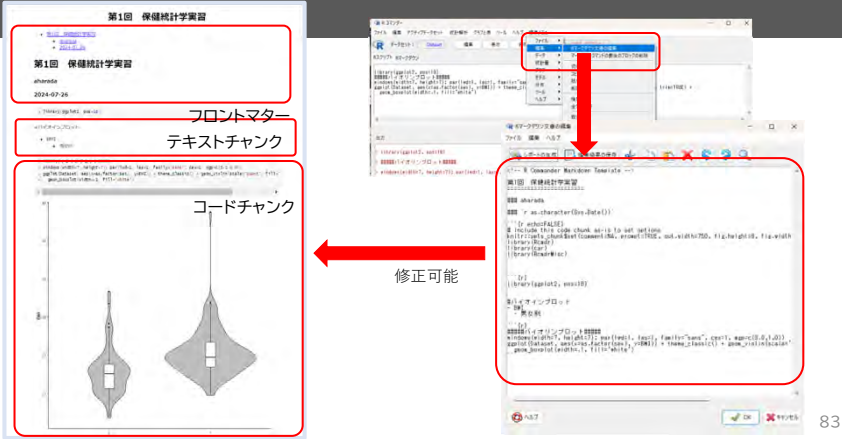
81



82

レポート

[標準メニュー]－[標準]－[Rマークダウン文書の編集]



83

<pre> title: "Replace with Main Title" author: "ahara" date: "r Sys.Date()" # Uses current date ... <!-- You can edit this R Markdown document, for example to explain what you're doing and to draw conclusions from your data analysis. Auto-generated section titles, typically preceded by ###, can also be edited. It's generally not a good idea to edit the R code that the R Commander writes, but you can freely edit between (not within) R code blocks." Each R code block starts with ```(r) and ends with ``` --> ```{r echo=FALSE, message=FALSE} # include this code chunk as-is to set options knitr::opts_chunk\$set(comment=NA, prompt=TRUE) library(Rcmdr) library(car) library(RcmdrMisc) ... ## ##### バイオインフラクト ##### windows(width=7, height=7); par(lwd=1, las=1, family="sans", cex=1, mps=c(3.0,1.0)) plot(Dataset, aes(x=as.factor(sex), y=sbpl) + theme classic() + geom.violin(scale="count", fill="grey", trim="mean") + geom.boxplot(width=.1, fill="white") </pre>	<pre> title: "第1回医療統計学実習" author: "a.harada" date: "r Sys.Date()" # Uses current date ... <!-- You can edit this R Markdown document, for example to explain what you're doing and to draw conclusions from your data analysis. Auto-generated section titles, typically preceded by ###, can also be edited. It's generally not a good idea to edit the R code that the R Commander writes, but you can freely edit between (not within) R code blocks." Each R code block starts with ```(r) and ends with ``` --> ```{r echo=FALSE, message=FALSE} # include this code chunk as-is to set options knitr::opts_chunk\$set(comment=NA, prompt=TRUE) library(Rcmdr) library(car) library(RcmdrMisc) ... ## ##### バイオインフラクト ##### windows(width=7, height=7); par(lwd=1, las=1, family="sans", cex=1, mps=c(3.0,1.0)) plot(Dataset, aes(x=as.factor(sex), y=sbpl) + theme classic() + geom.violin(scale="count", fill="grey", trim="mean") + geom.boxplot(width=.1, fill="white") </pre>
---	---

84

拡大

フロントマター

テキストチャンク

コードチャンク

85

85

テキストチャンク コード

見出し

#見出し1

##見出し2

###見出し3

- テキスト1

- テキスト1.1

- テキスト1.2

-テキスト1.2.1

テキスト 斜体

****テキスト**** 太字

~~テキスト~~ 打消し

 テキスト text 色指定

86

86


第1回保健統計学実習 演習課題

aharada

2024-08-14

appplot

```
> ggplot(mtcars) + geom_point(aes(x = displ, y = hwy))
```



87

87

第1日目 の課題(2)

R markdown機能を使用し、レポート出力を試みる

→いくつかのグラフ結果について出力を行う

88

88

EZRとR-studio

EZRはRのコードをベースにしています(裏で動いています)
直接Rコードで操作するには?
EZRのコマンドラインに入力
R-STUDIO

89

これまで行った解析をコードでみる

- データ読み込み

```
#####SPSSデータセットのインポート#####
health<-
readSPSS("F:/■■■■大学/◎◎滋賀医大/■■■■講義関連/京都府大/講義資料
/2023 R/＃＃第1回/dataset/health.sav",
rownames=FALSE, stringsAsFactors=TRUE, tolower=FALSE)
```
- 連続変数の要約

```
#####連続変数の要約#####
res<- numSummary2(health[, "age"], statistics=c("mean", "u.sd",
"u.var", "quantiles"), quantiles=c(0.25, .5, .75, 1))
```
- 箱ひげ図

```
#####箱ひげ図#####
windows(width=7, height=7); par(lwd=1, las=1, family="sans",
cex=1, mgp=c(3.0, 1, 0))
boxplot(health$age[complete.cases(health$age)], ylab="age")
```

90

Github

- <https://github.com/harabou>
- https://github.com/harabou/Biostat_Kyoto_pref
- Rcodeのダウンロード

R-Markdown用のコード

Rのコード

91

R studio

スクリプト
Rスクリプトを書く場所





環境
変数などの情報

コンソール
命令を書いたり、その結果が
表示されたりする所


ファイル
プロット
パッケージ etc.

RStudioは、Rを使用するための開発環境（プログラミングのためのアプリケーション）です。
Rを用いた統計解析は、R単体でも（RStudioを使わなくても）可能ですが、RStudioを使って統計解析を
行う人が多い。

92




Import datasetから
CSV形式は「Text(base)」



97

97




IMPORTする
ファイルの1行目が変数見出しの場合など
は「Heading」をYesとする

98

98

コードを入力するため、New fileから「R Script」を選択



99

99

講義例題 R解析例

100

100

データの記述

tableone, tidyverseパッケージ等を使用

- データの記述の例題として「health3.csv」を用意
- 健診データ(仮想)で、
 - ID, 性別, 年齢, 収縮期血圧(SBP)、拡張期血圧(DBP)、推定食塩摂取量(SALT)、高血圧分類(HTN_c : 1-7) などからなる

至適高血圧	sbp<120 and dbp< 80	HTN.c= 1
正常高血圧	120<=sbp<130 and dbp< 80	HTN.c=2;
正常高値血圧	130<=sbp<140 or 80<=dbp< 90	HTN.c=3;
I度高血圧	140<=sbp<160 or 90<=dbp< 100	HTN.c=4;
II度高血圧	160<=sbp<180 or 100<=dbp< 110	
HTN.c=5;		
III度高血圧	180<=sbp and 110<=dbp	HTN.c=6;
Other HTN=c=7;		

- データの記述→記述統計→(血圧データについて)散布図
→箱ひげ図→ヒストグラム→ヴァイオリンプロットのコード例を示してある

101


101

```
library(tidyverse)install.packages("tidyverse")

##boxplot
g_box<- ggplot(data= healthc, aes(x = factor(sex), y = sbp))+geom_boxplot()g_box

##histgram
g_hist<- ggplot(data= healthc, aes(x = age))
+geom_histogram(fill="white",
color="black")+theme_classic()g_hist

##violinplot
vp<-ggplot(data= healthc, mapping = aes(x = factor(sex), y = sbp)) + geom_violin() +
geom_point() + labs(title = "sex") +
theme_bw() + theme(legend.key =
element_blank())g_vp
```



102

102


health <- read.csv("F:/■■■■大学/◎◎滋賀医大/■■■講義関連/京都府大/講義資料/2023.R/##第1回/dataset/health.csv")

library(tidyverse)install.packages("tidyverse")

```
##boxplot
g_box<- ggplot(data= health, aes(x = factor(sex), y = sbp))+geom_boxplot()
g_box
```

```
##histgram
g_hist<- ggplot(data= health, aes(x = age))
+geom_histogram(fill="white",
color="black")+theme_classic()
g_hist
```

```
##violinplot
g_vp<-ggplot(data= health, mapping = aes(x = factor(sex), y = sbp)) + geom_violin() +
geom_point() + labs(title = "sex") + theme_bw()
+ theme(legend.key = element_blank())
g_vp
```




103

103

```
#散布図
g_point_2 <- ggplot(data= health, aes(x = sbp, y = dbp))+geom_point () +theme_classic()
g_point_2
```

```
##summary table
health3 <- read.csv("F:/■■■■大学/◎◎滋賀医大/■■■講義関連/京都府大/講義資料/2023.R/##第1回/dataset/health3.csv")
```

```
library(tableone)
tbl_1 <- CreateTableOne(vars = c("sex","age", "sbp","dbp","salt","HTN.c"),
strata="sex",factorVars=c("sex","HTN.c"),data = health3)
tbl_1
```



104


104

```
attach(health3)
cor(cbind(sbp, dbp))
cor.test(sbp, dbp)
cor(sbp, dbp,
method="spearman")
cor(sbp, dbp,
method="pearson")

quant<-cbind (health3$age,
health3$sbp, health3$dbp,
health3$salt)
quant2<-cbind (age, sbp,
dbp, salt)
cor(quant2)
pairs(quant2)
```


```
> cor(sbp, dbp, method="spearman")
[1] 0.7193167
> cor(sbp, dbp, method="pearson")
[1] 0.7189422
```


	age	sbp	dbp	salt
age	1.00000000	0.1686048	0.01739726	0.08910298
sbp	0.16860481	1.0000000	0.71894223	0.17764427
dbp	0.01739726	0.7189422	1.0000000	0.15370642
salt	0.08910298	0.1776443	0.15370642	1.00000000




R markdown

- Document(HTML)
- R-studioでの演習
 - さきほどのRstudioでの演習をレポート提出用ファイルに仕上げる
- 手順
 - Rmarkdownで記述
 - Rmarkdown html modeで指定
 - Rcodeを配置
 - Knitでの掃き出し
 - 確認





R Markdown画面



①Rcode部分 (boxplot)

②Rcode部分 (ヒストグラム)




③Rcode部分 (Violonplot)

```
56- #####
57- ##table
58- rtab2, echo=TRUE
59- tbl_1
60- #####
61- r cor, include=FALSE
62- g_point_2 <- ggplot(data= health, aes(x = sbp, y = dbp))+geom_point () +theme_classic()
63- #####
64- ##散布図
65- r cor2, echo=TRUE
66- g_point_2
67- #####
68- r cor3, include=FALSE
69- attach(health)
70- cor(cbind(sbp, dbp))
71- cor.test(sbp, dbp)
72- cor(sbp, dbp, method="spearman")
73- cor(sbp, dbp, method="pearson")
74- #####
75- quant<-cbind(health$age, health$sex, health$smoke, health$weight)
76- quant2<-cbind(quant, sbp, dbp, salt)
77- #####
78- ##散布図2
79- r cor4, Echo=TRUE
80- cor(quant2)
81- pairs(quant2)
```

④Rcode部分 (TableOne表)

⑤Rcode部分 (散布図)

⑥Rcode部分 (散布図)



Document

```
1 <---
2 title: "R-studio演習レポート フォーム"
3 author: "A.Harada"
4 date: "2024-07-28"
5 output: html_document
6 <---
7
8 ## R-studioでの演習
9 さきほどのRstudioでの演習をレポート提出用ファイル
10
11
12
13
14
```

R-studio演習レポート フォーム

A Harada
2024-07-28

R-studioでの演習

さきほどのRstudioでの演習をレポート提出用ファイルに仕上げる

手順

- Rmarkdownで記述
- Rmarkdown html modeで推定
- Rcodeを配置
- Knitでの書き出し
- 確認

①Rcode部分 (boxplot)

②Rcode部分 (ヒストグラム)

③Rcode部分 (Violonplot)

④Rcode部分 (TableOne表)

⑤Rcode部分 (散布図)

⑥Rcode部分 (散布図)

R-studio演習レポート フォーム

A Harada
2024-07-28

R-studioでの演習

さきほどのRstudioでの演習をレポート提出用ファイルに仕上げる

手順

- Rmarkdownで記述
- Rmarkdown html modeで推定
- Rcodeを配置
- Knitでの書き出し
- 確認

①Rcode部分 (boxplot)

R markdown

• Power Point出力

直接PowerPoint出力も可

```
1 <---
2 title: "Rmarkdown"
3 author: "Harada"
4 date: "2024-07-28"
5 output: powerpoint_presentation
6 <---
7
8 ## R-studioでの演習
9 さきほどのRstudioでの演習をスライド用ファイルに仕上げる
10
11
12
13
14
15
16
17
18
19
20
21
22
23
24 health <- read.csv("data/health.csv")
25 (echo = FALSE)
26
27
28
29
30 library(tidyverse)
31 (echo = FALSE)
32
33
34
35
36 g_box <- ggplot(data = health, aes(x = factor(sex), y = sbp)) + geom_boxplot()
37
38
```

1

2

3

4

Powerpoint資料

R-studioでの演習

手順

1

2

3

4

5

17

第1日目 の課題(2)

再掲

R markdown機能を使用し、レポート出力をしてみる
→いくつかのグラフ結果について出力を行う

118

第3回

エクセルの基礎(1)

119

Excelの基礎 (1)

• ファイル形式

• 計算式

• 表の作成

• グラフ

• 関数

• 入力規則

• 集計

• 置換

• ブックと印刷

◆使用するデータファイル

Health1

Health3

Excelドリル

20

関数

覚えておいてほしい14の関数	
関数名	概要
SUM	合計値
MAX、MIN	最大値・最小値
ROUND	四捨五入
IFERROR	エラー時の表示切替
IF	条件判定
IFS	複数条件判定
SUMIF	条件を指定して合計
SUMIFS	複数条件で合計
COUNTIF	条件を満たす値の数
COUNTIFS	複数条件を満たす数
VLOOKUP	値の検索・表示
XLOOKUP	値の検索・表示

121

121

演算子

演算子	意味	使用例	使用例の説明
算術演算子			
+(プラス)	加算	A1+A2	A1の値にA2の値を足す
-(マイナス)	減算	A3-A2	A3の値からA2の値を引く
*(アスタリスク)	乗算	A3*100	A3の値に100を掛ける
/(スラッシュ)	除算 ^{※1}	B5/B1	B5の値をB1の値で割る
^(キャレット)	べき乗	C7^2	C7の値を2乗する
%(パーセント)	パーセント指定	A1*80%	A1の値に80%(0.8)を掛ける
比較演算子 ^{※2}			
=	等しい	A1=B1	A1の値とB1の値が等しければTRUE、そうでなければFALSEとなる
<>	等しくない	A1<>B1	A1の値とB1の値が等しくなければTRUE、そうでなければFALSEとなる
>	より大きい	A1>B1	A1の値がB1の値より大きければTRUE、そうでなければFALSEとなる
<	より小さい	A1<B1	A1の値がB1の値より小さければTRUE、そうでなければFALSEとなる
>=	以上	A1>=B1	A1の値がB1の値以上であればTRUE、そうでなければFALSEとなる
<=	以下	A1<=B1	A1の値がB1の値以下であればTRUE、そうでなければFALSEとなる

122

122

文字列演算子			
&(アンパサンド)	連結	"できる"&E4	E4に「シリーズ」という文字列が入力されていれば、「できるシリーズ」という文字列になる
参照演算子			
:(コロソ)	セル範囲	A1:B10	A1とB10の間にあるすべてのセル、つまりA1～A10およびB1～B10が指定される
,(カンマ)	セル範囲の複数指定	A1:B10,D1:D10	A1とB10の間にあるすべてのセルと、D1とD10の間にあるすべてのセル、つまりA1～A10、B1～B10、D1～D10が指定される
(半角空白)	セル範囲の共通部分	A1:B4 B2:C5	A1とB4との間にあるすべてのセルと、B2とC5との間にあるすべてのセルの重複する部分、つまりB2～B4の範囲が指定される

123

123

「01_計算初級」

SUM, オートΣ

「01_計算初級」
例題3問＋練習問題8問



124

124

=SUM(セル範囲)

SUM関数のセル範囲の指定方法 (2種類)

	A	B	C	D	E	F
1						
2		支店別売上集計				
3			販売数	金額		
4			個	千円		
5		支店A	14,820	8,000		
6		支店B	9,600	5,150		
7		合計	24,420	13,150		
8						

=SUM(C5:C6)
範囲指定方式で、セル範囲
C5:C6の合計を計算

=SUM(D5,D6)
個別指定方式で、セルD5
とセルD6の合計を計算

計算対象のセル範囲の指定方法には
「範囲指定方式」と「個別指定方式」
の2種類がある。

125

125

「02_一般関数」

一般関数

126

126

=MAX(セル範囲) =MIN(セル範囲)

最大値／最小値の算出

	A	B	C	D	E	F	G
1							
2		気温・販売数相関検討表		気温最高値	32		
3			気温	販売数	気温最低値	28	
4			℃	個			
5		8月1日(日)	31	800			
6		8月2日(月)	32	850			
7		8月3日(火)	29	700			
8		8月4日(水)	28	700			
9		8月5日(木)	30	780			
10		※気温は13時時点の値					
11							

=MAX(C5:C9)
セル範囲C5:C9の最大値を算出

=MIN(C5:C9)
セル範囲C5:C9の最小値を算出

MAX／MIN関数を利用して最大値／最小値を
算出した。

127

127

=ROUND(セル範囲,桁数)

ROUND関数で四捨五入したところ

	A	B	C	D	E	F	G
1							
2		配置人員数試算					
3			単位：人				
4			増	加	倍	率	
5			現行	1.3	1.5		
6		店舗A	3	3.9	4.5		
7		店舗B	15	19.5	22.5		
8		店舗C	21	27.3	31.5		
9		※増数は四捨五入					
10							

=C6*D5

	A	B	C	D	E	F	G
1							
2		配置人員数試算					
3			単位：人				
4			増	加	倍	率	
5			現行	1.3	1.5		
6		店舗A	3	4	5		
7		店舗B	15	20	23		
8		店舗C	21	27	32		
9		※増数は四捨五入					
10							

=ROUND(C6*D5,0)

128

• PHONETIC関数

• ふりがなの文字列を取り出します。

あ い え
う お

• INT(数値)

• 数値を超えない最大の整数を返します。正の数では小数以下切り捨てと同じ。

• RANK(数値)

• 範囲内で数値 が何番目に位置するかを返します。

129

129

=COUNT(範囲)

• 範囲内で数値データが入力されているセルの個数を返します。

	A	B	C	D	E	F	G	H	I
1	アンケート結果								
2	質問番号	回答番号							
3	質問1	1							
4	質問2	2							
5	質問3	不明							
6	質問4	1							
7	質問5								
8	有効解答数	3							
9									
10									
11									

-COUNT-

値1 B3:B7 = 12 "不明" 1

値2 = 数値

= 3

引数リストに含まれる数値の個数を返します。

値1: 値1, 値2... にはデータまたはデータが入力したセルの参照を 1 から 30 個まで指定します。数値データだけがカウントされます。

数式の結果 = 3

OK キャンセル

130

130

=COUNTA(範囲)

• 範囲内でデータが入力されているセルの個数(数値も文字も含む)を返す

	A	B	C	D	E	F	G	H	I
1		東京							
2		新橋							
3	名前	品川							
4		川崎							
5									
6	個数	4							
7									
8									
9									
10									
11									

-COUNTA-

値1 B1:B5 = "東京", "新橋", "品川", "川崎"

値2 = 数値

= 4

引数リストに含まれる、空白でないセルの個数を返します。

値1: 値1, 値2... にはカウントしたいセルを参照を 1 から 30 個まで指定します。

数式の結果 = 4

OK キャンセル

131

131

=COUNTIFS(範囲)

• =COUNTIFS(検索条件範囲1,検索条件1,検索条件範囲2,検索条件2.....)

=COUNTIFS(B5:B10,G4,C5:C10,H8)

↓ 絶対参照にする

=COUNTIFS(\$B\$5:\$B\$10,G4,\$C\$5:\$C\$10,\$H\$8)

132

132

●COUNTIFS関数での集計

販売記録	商品名	店舗	売価	販売数
1	デスストップPC	東京本店	150,000	2
2	タブレット	名古屋支店	82,000	1
3	デスストップPC	東京本店	150,000	1
4	タブレット	東京本店	85,000	1
5	デスストップPC	名古屋支店	120,000	1
6	PC用デスク	東京本店	9,800	1

条件①: デスストップPC
条件②: 東京本店
条件③: カウントの総和

① セルH4に「=COUNTIFS」を入力し、1つめのセル範囲と条件のペアを指定する。

② 2つめのセル範囲と条件式のペアを指定し、最後に「」を入力して、
「Enter」キーを押す。

③ ペア2組・合計4つの引数を指定することで、2つの条件の両方を満たすデータの件数を、カウントすることができる。

●参照形式を指定して一括入力

販売記録	商品名	店舗	売価	販売数
1	デスストップPC	東京本店	150,000	2
2	タブレット	名古屋支店	82,000	1
3	デスストップPC	東京本店	150,000	1
4	タブレット	東京本店	85,000	1
5	デスストップPC	名古屋支店	120,000	1
6	PC用デスク	東京本店	9,800	1

絶対参照: B5:B10, G4
相対参照: C5:C10, H8

セルH4をコピーする

常に同じ範囲(値)を参照する場合は、絶対参照で指定する。そうすれば、セルをコピーするだけで、目的の表をすばやく作成できる。

IF

≡

135

=IF(論理式, TRUEの場合の表示内容, FALSEの場合の表示内容)

● 論理式に指定できる主な演算子と計算結果

論理式	演算子の意味	説明
A1 = 10	等しい	A1の値が10の場合に TRUE
A1 <> 10	等しくない	A1の値が10以外の場合に TRUE
A1 < 10	小さい	A1の値が10よりも小さい場合に TRUE
A1 > 10	大きい	A1の値が10よりも大きい場合に TRUE
A1 <= 10	以下	A1の値が10以下の場合に TRUE
A1 >= 10	以上	A1の値が10以上の場合に TRUE

136

IF(論理式, 真の場合, 偽の場合)

• 論理式 真または偽のどちらかに評価できる値または式を指定します。

使用例 1

予算上限が100万円

のとき、それぞれの計画を評価

予算内であれば"○"を表示

.....真の場合に返す値、文字列、または数式を指定

予算オーバーであれば"予算外"と表示します。

.....偽の場合に返す値、文字列、または数式を指定

計画	予定金額	評価
プランA	1,230,000	予算外
プランB	980,000	○
プランC	1,003,000	予算外

=IF(D23<=1000000,"○","予算外")

137

137

=IF(論理式, TRUEの場合の表示内容, FALSEの場合の表示内容)

• 収縮期血圧<120

1

• 120 <= 収縮期血圧<130

2

• 130 <= 収縮期血圧<140

3

• 140 <= 収縮期血圧<160

4

• 160 <= 収縮期血圧

5

• それ以外

6

• ブランク

=IF(C2="",6,偽の場合)

• 160を超えたら5なので、

=IF(C2="",,IF(C2>160,5,偽の場合))

• 140を超えたら4

=IF(C2="",,IF(C2>160,5,IF(C2>140,4,偽の場合)))

• 130を超えたら3

=IF(C2="",,IF(C2>160,5,IF(C2>140,4,IF(C2>130,3, 偽の場合)))

• 120を超えたら2

=IF(C2="",,IF(C2>160,5,IF(C2>140,4,IF(C2>130,3, IF(C2>120,2,偽の場合)))

• 120以下の条件

=IF(C2="",,IF(C2>160,5,IF(C2>140,4,IF(C2>130,3, IF(C2>120,2,1))))))

138

138

=IFERROR(セル範囲,エラー時に表示する文字)

● エラーが発生したセルには「要確認」と表示する

=C8/D8

「販売数」が空欄のため、エラーとなっている

=IFERROR(C8/D8,"要確認")

エラーの場合に表示する内容を指定できた

	経費総額	販売数	経費/販売数
	千円	台	円
車種A	8,560	41	209
車種B	12,567	88	143
車種C	4,500		#DIV/0!

→

	経費総額	販売数	経費/販売数
	千円	台	円
車種A	8,560	41	209
車種B	12,567	88	143
車種C	4,500		要確認

139

139

日付・時間



140

140

日付と時刻の処理について

- Microsoft Excel では、日付は1900年1月1日を1とするシリアル値(連続番号)で格納され、時刻は一日の一部として小数値で格納されます。
- 日付と時刻は数値と見なされるため、加算や減算などの計算を行うことができます
 - たとえば、日付を他の日付から引いて、2つの日付の差を計算することができます。日付をシリアル値として表示したり、時刻を小数値として表示したりするには、セルの表示形式を「標準」表示形式に変更します。

下は、それぞれの日付とシリアル値を示しています。

日付	シリアル値
1900/1/1	1
1900/1/31	31
2001/2/1	37288




期間 DAYS 2つの日付から期間内の日数を求める
=DAYS(D3,C3)
DATEDIF 期間内の年数、月数、日数を求める
=datedif(C3,D3,"D")

"Y":期間内の満年数
"M":期間内の満月数
"D":期間内の日数

	A	B	C	D	E	F
1	海外旅行の期間					
2	国	場所	出国日	帰国日	期間(日)	
3	韓国	ソウル	2004/11/2	2004/11/6		
4	アメリカ	ハワイ	2010/9/1	2010/9/30		
5	イタリア	ローマ・ベネチア	2013/2/1	2013/2/12		
6	エジプト	カイロ	2016/12/26	2017/1/12		
7	オーストラリア	シドニー	2002/3/23	2002/4/30		
8	インド	カルカッタ	2007/6/24	2007/7/18		
9	ブラジル	リオデジャネイロ	2014/6/22	2014/9/1		
10						



参照



VLOOKUP

- 指定された 範囲 の左端の列で特定の値を検索し、範囲内の対応するセルの値を返します。
- VLOOKUP 関数は、比較する値がテーブルの左端の列に入力され行方向に配置されている場合、その位置から指定された列だけ右にある値を取り出す場合に使用します。

VLOOKUP (検索値、範囲、列番号、検索の型)

検索値: 範囲 の左端の列で検索する値を指定します。

範囲 : 目的のデータが含まれる範囲を指定します。

列番号: 表示する値の列の番号を指定します。
「範囲」で指定した左端を1とした相対値で表します。

検索の型 検索値 と完全に一致する値だけを検索するか、

- OTRUE または省略
- 検索値 が見つからない場合に、検索値 未満で最も大きい値が返されます。
 - 範囲 の左端の列のデータは、昇順に並べ替えておく必要があります。
- OFALSE
- 検索値 と完全に一致する値だけが検索され、見つからない場合は エラー値 #N/A が返されます。

VLOOKUP

	B	C	D	E	F	G	H	I	J
	チケット料金表								
	種類	料金							
		大人	中人	小人					
	18歳以上	中学・高校生	幼児・小学生						
47	1デーバスポート	7,400円	6,400円	4,800円					
48	2デーバスポート	13,200円	11,600円	8,600円					
49	3デーバスポート	17,800円	15,500円	11,500円					
50	4デーバスポート	22,400円	19,400円	14,400円					
51	アフターバスポート	4,200円	4,200円	4,200円					
52	スターライトバスポート	5,400円	4,700円	3,500円					
53	ギフトバスポート	74,000円	6,400円	4,800円					
	2018/12/7現在の価格								

(チケットの「種類」を選択すると「料金」が自動で表示さ

大人 中人 小人

3デーマジックバスポート 3デーマジックバスポート 3デーマジックバスポート

料金 17800 15500 11500

=VLOOKUP(J46,\$B\$47:\$E\$54,2,TRUE)

=VLOOKUP(J46,\$B\$47:\$E\$54,3,TRUE)

=VLOOKUP(J46,\$B\$47:\$E\$54,4,TRUE)

検索値: 検索する値 - 大人の列の種類

範囲: (チケットの)種類と料金が設定されている表の範囲を指定 (左参照)

列番号: 料金列は表の中の第2列目なので2
中人・小人はそれぞれ3、4列目となる。

VLOOKUP, XLOOKUP

VLOOKUPのように左端列だけでなく検索が可能
=XLOOKUP(検索値, 検索範囲, 戻り範囲, 見つからない場合, 一致モード, 検索モード)

1 検索値

2 検索範囲

3 戻り範囲

4 見つからない場合

VLOOKUP, XLOOKUP

	A	B	C	D	E
	御請求書				
1					
2	株式会社XXXXX御中				
3	請求日 令和3年7月14日				
4	請求番号 1245-001				
5	株式会社〇〇商会				
6	下記のとおり御見積申し上げます。				
7					
8	商品番号	商品名	単価	数量	金額
9	A103	=XLOOKUP(A9, 商品カタログ, 商品名)			
10		=XLOOKUP(A9, 商品カタログ, 単価)			
11					
12					
13					
14					
15					
16					
17					

5

VLOOKUP, XLOOKUP

	A	B	C	D	E
	御請求書				
1					
2	株式会社XXXXX御中				
3	請求日 令和3年7月14日				
4	請求番号 1245-001				
5	株式会社〇〇商会				
6	下記のとおり御見積申し上げます。				
7					
8	商品番号	商品名	単価	数量	金額
9	A103	=XLOOKUP(A9, 商品カタログ, 商品名)			
10		=XLOOKUP(A9, 商品カタログ, 単価)			
11					
12					
13					
14					
15					
16					
17					

7

	A	B	C	D
	商品カタログ			
1	商品名	単価 (税別)	商品番号	
2	クラフト封筒 赤色3号 100枚セット	720	A101	
3	クラフト封筒 赤色4号 100枚セット	600	A102	
4	クラフト封筒 赤色5号 100枚セット	1,000	A103	
5	クラフト封筒 赤色6号 100枚セット	800	A104	
6	クラフト封筒 赤色7号 100枚セット	2,000	B101	
7	レターファイル A4 10冊セット	1,800	B102	
8	リングファイル A4 10冊セット	2,500	B103	
9	リングファイル B5 10冊セット	2,000	B104	
10	ファイルボックス A4 10個セット	1,000	C101	

6 ドラッグ

表の編集,グラフ作成

「06_表の編集のまとめ」

- 罫線
- 連結

「07_グラフ作成」




149


印刷

- 範囲指定
- 改ページ







150




151




152




153



154




155



156

入力規則



157

157


AI演習の準備

158

158

Google Colaboratory


<https://colab.research.google.com/?hl=en-GB#>



159


159

How to access




160


160




161



162






163



164

1. Upload the python code file for today's exercise to Google Colaboratory.

Open file



Open New file (copy file for you)

Change file name

169

169

Where is the file created by Copy stored?

170

170

Check Your Google drive

If you upload your own code files, store them in this hierarchy or new folder(recommend)

171

171

Another hierarchy folder

Example.
Add the file "#01_NCD_stat_ncd.ipynb" to the [MyDrive] [NCD_biostat_course] hierarchy.

172

172

Attention. Contents in 「Sample folder」 disappear after the session.

Saved after the session ends.

Disappears after the session.

173

2. Use this file to begin your analysis

174

Importing files in Google Drive

In order to read files stored on Google Drive from colaboratory, it is necessary to mount the google drive (to make the connected device recognized and ready to use).

175

My Drive, a Google Drive, is added under “/content/drive”.

Click

from google.colab import drive
drive.mount('/content/drive')

```
[ ] from google.colab import drive
drive.mount('/content/drive')

1. Pattern 1
[ ] # Importing from Google drive.
import pandas as pd
df= pd.read_csv('/content/drive/MyDrive/20230224_biostat/darwin2.csv')
# Check (row, column)
df.shape
# First rows are displayed
df.head()
```

176

How to mount GoogleDrive

Execute the following commands to mount the Google Drive.

```
from google.colab import drive
drive.mount('/content/drive')
```



大学で使っているメールアドレスを選択

177

Drive mount

Permit this notebook to access your Google Drive files?

Connecting to Google Drive will permit code executed in this notebook to modify files in your Google Drive until access is otherwise revoked.

No thanks **Click** Connect to Google Drive



178

Google でログイン

Google Drive for desktop に再ログインしようとしています

Google Drive for desktop のプライバシーポリシーと利用規約を読み、Google Drive for desktop でお客様のデータがどのように処理、保護されるかをご確認ください。


変更は Google アカウント からいつでもできます。

詳しくは、Google でログインをご覧ください。

キャンセル **Click** 次へ

179

My Drive, a Google Drive, is added under "/content/drive".



```
from google.colab import drive
drive.mount('/content/drive')
```

180

Mounted at /content/drive

182


183

184

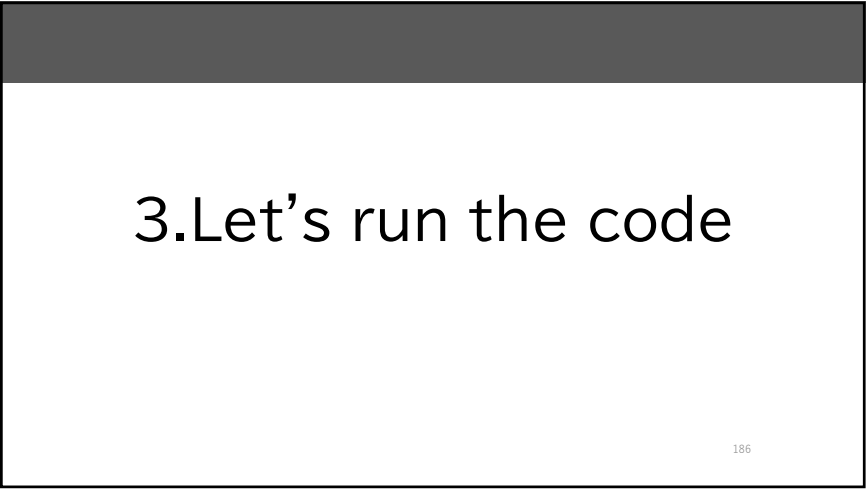
☐ Include private repos

Cancel


184



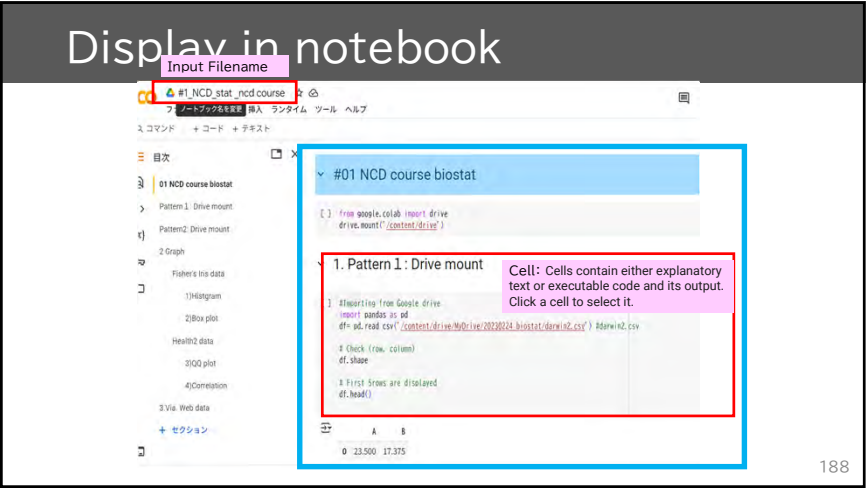
185



186



187



188

Display in notebook

0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Make Code cell

+コード+テキスト

[3] #Importing from Google Drive
import pandas as pd

dir_path = '/content/drive/MyDrive'
df = pd.read_csv(dir_path + 'Iris'

Check (row, column)
df.shape
First 5 rows are displayed
df.head()

When the cursor is pointed out, the "code" and "text" pop-up menus appear.

When each is selected, the cell new screen is displayed.

189

189

Loading packages

#Loading various packages
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns

To bring external into your current script.

matplotlib.pyplot is a library widely used for creating static, interactive, and animated visualizations in Python. as plt creates a shorter alias plt for convenience, so you can refer to it with plt instead of the full name.

pandas is a powerful library for data manipulation and analysis. It provides data structures like DataFrames for efficiently working with tabular data. as pd creates a shorter alias pd.

numpy is the fundamental package for scientific computing in Python. It offers tools for working with arrays, mathematical functions, and more. as np creates a shorter alias np.

seaborn is a library built on top of matplotlib that provides a high-level interface for creating informative and attractive statistical graphics. as sns creates a shorter alias sns.

190

190

Python

- Outstanding in frequency of use and range of applications
- Python has an extensive library and a thriving community (with a rich of educational materials).

基礎処理

可視化

画像

顔認識

自然言語処理

機械学習

深層学習

MeCab

GINZA

Japanese Language Text Analysis

SciPy

pandas

NumPy

matplotlib

seaborn

OpenCV

Linear Regression, Decision Tree, Random forest, gradient boost, XGBoost, Naive Bayes, SVM, Dimensionality Reduction Algorithms

Selenium(for scraping)

TensorFlow

Keras

Chainer

PYTORCH

2023/05/08

Academic meeting

191

191

1)Load dataset

192

192

How to load a dataset

コード

テキスト

▼ #01 NCD course biostat

```
[ ] from google.colab import drive
drive.mount('/content/drive')

Mounted at /content/drive
```

▼ 1. Pattern 1 : Drive mount

```
[ ] #Loading various packages
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns

df= pd.read_csv('/content/drive/MyDrive/NCD_biostat_course/Iris.csv') #Iris.csv

# Check (row, column)
df.shape
```

Iris.csv

193

193

Method1: “fpath” Google drive

1. Download the file from [Iris.csv]
https://drive.google.com/drive/folders/1MobO3Oc5V5jyDO9gOhjMS-08_YI9QC9?usp=sharing

2. Save the file in your google drive

3. Specify the hierarchy of 2.

Pattern1 `df= pd.read_csv ('/content/drive/MyDrive/NCD_biostat_course/Iris.csv')`

OR

Pattern2 `f_path = '/content/drive/MyDrive/NCD_biostat_course/'`
`df = pd.read_csv(f_path + 'Iris.csv')`

Your google drive

Name of Data file(CSV file)

194

194

▼ 1. Pattern 1 : Drive mount

```
[3] #Loading various packages
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns

df= pd.read_csv('/content/drive/MyDrive/NCD_biostat_course/Iris.csv') #Iris.csv

# Check (row, column)
df.shape

# First 5 rows are displayed
df.head()
```

This is your own hierarchy where you saved the file

195

195

```
#Loading various packages
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns

df= pd.read_csv('/content/drive/MyDrive/NCD_biostat_course/Iris.csv') #Iris.csv

# Check (row, column)
df.shape

# First 5 rows are displayed
df.head()
```

The first 5 lines are shown

	A	B	C	D	E
	gaku_l	gaku_w	kaben_l	kaben_w	group
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa
5	5.4	3.9	1.7	0.4	setosa
6	4.6	3.4	1.4	0.3	setosa
7	5.0	3.4	1.5	0.2	setosa
8	4.4	2.9	1.4	0.2	setosa
9	4.9	3.1	1.5	0.1	setosa
10	5.4	3.7	1.5	0.2	setosa
11	4.8	3.4	1.6	0.2	setosa

196

196

Method 2: via Github (direct)

```
fpath = 'https://raw.githubusercontent.com/harabou/NCD_biostat/refs/heads/main/%2301/Iris.csv'
```

```
df = pd.read_csv(fpath, header=0)
```


```
df.head()
```

This variable is then used by the `pd.read_csv()` function to read the data from the CSV file located at that URL into a pandas DataFrame named `df`.

This allows the user to work with the data in their Python code.

197

197




198

198

This will be the reference code


https://raw.githubusercontent.com/harabou/NCD_biostat/refs/heads/main/%2301/Iris.csv



```
gaku_l gaku_w kaben_l kaben_w group
0 5.1 3.5 1.4 0.2 setosa
1 4.9 3.0 1.4 0.2 setosa
2 4.7 3.2 1.3 0.2 setosa
3 4.6 3.1 1.5 0.2 setosa
4 5.0 3.6 1.4 0.2 setosa
5 5.4 3.9 1.7 0.4 setosa
6 4.6 3.4 1.4 0.3 setosa
7 5.0 3.4 1.5 0.2 setosa
8 4.4 2.9 1.4 0.2 setosa
9 4.9 3.1 1.5 0.1 setosa
```

199

199



200

200

2) Graph

Using Iris dataset

201

201

Graph –matplotlib–

```
x = np.random.normal(size = 1000)
fpath = 'https://raw.githubusercontent.com/harabou/DS-AI_course/main/%2301/Iris.csv'

df = pd.read_csv(fpath,header=0,
encoding='shift-jis')

#matplotlib plot
plt.style.use('ggplot')

plt.rcParams.update({'font.size':15})

%matplotlib inline
```

This line sets the plotting style to 'ggplot'. Styles control the visual appearance of your plots, and 'ggplot' is known for its clean and modern aesthetic, often used in data visualization.

This updates the default settings (rcParams) for matplotlib plots. Specifically, it sets the font size to 15, making the text in your plots larger and easier to read.

This is a "magic command" specific to Jupyter Notebooks. It ensures that your plots are displayed directly within the notebook output cells, rather than in separate windows.


202

202

Graph –seaborn–

```
x = np.random.normal(size = 1000)
df = pd.read_csv(fpath,header=0, encoding='shift-jis')

# use seaborn
sns.histplot(df.gaku_l)
```




203


203

Box plot

df.boxplot(patch_artist = True)




sns.boxplot(data=df)



204


204

```
df.boxplot(by='group',
patch_artist = True)
```



```
w = pd.melt(df, id_vars = ["group"])
display(w.head())

sns.boxplot(x = "variable", y = "value", data
= w, hue = "group")
```



205

205

Statistical indices

Using [health2.csv]

206

206

Health data

<via Google drive>
Download → your Mydrive

<via Github>
fpath =
'https://raw.githubusercontent.com/harabou/N
CD_biostat/refs/heads/main/%2301/health2.csv'

```
df = pd.read_csv(fpath,header=0)
df.head()
```

207

207


Q-Q plot

```
import scipy.stats as stats
from scipy.stats import norm
import matplotlib.pyplot as plt

sbp = df['sbp']
dbp = df['dbp']
salt = df['salt']
age = df['age']
```

```
fig, ax = plt.subplots(2, 2)
probplot(sbp, plot=ax[0, 0])
probplot(dbp, plot=ax[0, 1])
probplot(salt, plot=ax[1, 0])
probplot(age, plot=ax[1, 1])
plt.tight_layout()
plt.show()
```

import scipy.stats as stats:
This line imports the scipy.stats module,
which contains a wide range of statistical
functions, including those for creating Q-Q
plots. It's aliased as stats for easier use.



208

208

Correlation

```
import pandas as pd
df_subset =
pd.concat([df['sbp'],df['
salt'],df['dbp']], axis=1)

corr = df_subset.corr()
corr
```

```
from scipy.stats import spearmanr
correlation, pvalue =
spearmanr(df.sbp, df.dbp)
print(correlation)
```

	sbp	salt	dbp
sbp	1.000000	0.177644	0.718942
salt	0.177644	1.000000	0.153706
dbp	0.718942	0.153706	1.000000

0.719316718120455

209

209

Seaborn's plot

```
fpath =
'https://raw.githubusercontent.com/harabou
/NCD_biostat/refs/heads/main/%2301/health2
.csv'

df2 =
pd.read_csv(fpath, header=0,
encoding='shift-jis')

#Plotting using
seaborn
pg=sns.pairplot(df2)
plt.show(pg)
```

210

210

Seaborn's pair plot

```
pg2=sns.pairplot(df,hue='sex')
plt.show(pg2)
```

```
SBP_F = df[df['sex']=='F']['sbp']
SBP_M = df[df['sex']=='M']['sbp']
DBP_F = df[df['sex']=='F']['dbp']
DBP_M = df[df['sex']=='M']['dbp']
```

211

211

How to load data direct from the web

- (e.g.) Data from the internet Census: population by age (5-year age groups), sex - national (1920 - 2015) 'e-stat data'

```
import pandas as pd
fpath = 'https://www.e-stat.go.jp/stat-search/file-
download?statInId=000031524030&fileKind=1'

df = pd.read_csv(fpath,header=0, encoding='shift-jis')
df.head()
```

This is the same method as the loading method via Github datafile

212

212

e-Stat
政府統計の総合窓口

Japan in Statistics
e-Stat is a government statistics portal site where you can view Japanese statistics

Explore statistics

Use of statistical data

Advanced use of statistical data

Statistics related information

Useful Links

Home

Explore statistics

File

Selection criteria

File

Census

CSV

Dataset

csv

Search options

Search for categories and titles provided

Dataset information

Census / Time series data

View/Download

CSV

Address copy of LINK

Back to Dataset List

統計統計名

Census

Government Statistical Code

00200521

Survey Overview

The census is the country's most important statistical survey, covering all people and households living in Japan, and is conducted every five years. The actual population and household status of Japan obtained from the census is used not only by the national and local government organizations, but also widely by private companies and research institutions, and through such uses, it is useful for the lives of the people. The census provides results such as population by age, family structure, working people, and foreigners living in Japan.

提供統計名

Time series data

213

213

1 to 25 of 406 entries

Filter

?

Index	元号	和暦 (年)	西暦 (年)	年齢5歳階級	人口 (総数)	人口 (男)	人口 (女)
0	大正	9.0	1920.0	総数	55963053.0	28044185.0	27918868.0
1	大正	9.0	1920.0	0~4歳	7457715.0	3752627.0	3705088.0
2	大正	9.0	1920.0	5~9歳	6856920.0	3467156.0	3389764.0
3	大正	9.0	1920.0	10~14歳	6101567.0	3089225.0	3012342.0
4	大正	9.0	1920.0	15~19歳	5419057.0	2749022.0	2670035.0
5	大正	9.0	1920.0	20~24歳	4609310.0	2316479.0	2292831.0
6	大正	9.0	1920.0	25~29歳	3923949.0	2008005.0	1915944.0
7	大正	9.0	1920.0	30~34歳	3609450.0	1833443.0	1776007.0
8	大正	9.0	1920.0	35~39歳	3410738.0	1707771.0	1702967.0
9	大正	9.0	1920.0	40~44歳	3243764.0	1640254.0	1603510.0
10	大正	9.0	1920.0	45~49歳	2658567.0	1340404.0	1318163.0
11	大正	9.0	1920.0	50~54歳	2234762.0	1122240.0	1112522.0
12	大正	9.0	1920.0	55~59歳	1840093.0	912085.0	928008.0
13	大正	9.0	1920.0	60~64歳	1655805.0	803033.0	852772.0
14	大正	9.0	1920.0	65~69歳	1312537.0	614479.0	698058.0

214

214

TIPS ① error handling

How to deal with code errors

```
dir_path = '/content/drive/MyDrive/NCD_biostat_course'
df = pd.read_csv(dir_path + 'iris.csv')

# Check (row, column)
df.shape
# First 5 rows are displayed
df.head()
```

FileNotFoundError: [Errno 2] No such file or directory: '/content/drive/MyDrive/NCD_biostat_course/iris.csv'

File not found error

215

215

4 frames

```
from google.colab import drive
drive.mount('/content/drive')

dir_path = '/content/drive/MyDrive/NCD_biostat_course'
df = pd.read_csv(dir_path + 'iris.csv')

# Check (row, column)
df.shape
# First 5 rows are displayed
df.head()
```

FileNotFoundError: [Errno 2] No such file or directory: '/content/drive/MyDrive/NCD_biostat_course/iris.csv'

File not found error

Suggested Changes

```
# Importing from Google drive
import pandas as pd

dir_path = '/content/drive/MyDrive/NCD_biostat_course/' # Added a trailing slash to the dir_path
df = pd.read_csv(dir_path + 'iris.csv')

# Check (row, column)
df.shape
# First 5 rows are displayed
df.head()
```

次のステップ: エラーの説明

Click on [Error Description]

216

216

第1日目 の課題(1)

再掲

- 1. 血圧区分(変数のカテゴリー化)、箱ひげ図の作成ができる
→血圧区分ごとの食塩摂取量について、箱ひげ図を作成
- 2. 血圧(SBP,DBP)、年齢、食塩摂取について、散布図、相関を検討し、4変数の関係性について、気づいた点を記述せよ。
適宜、必要なグラフを使用し説明すること
ヒント:
血圧同士の相関は???
食塩摂取と血圧の相関は???
年齢と収縮期血圧、拡張期血圧の散布図、相関は???

217

次回 (2日目)の実習内容

- 1 仮説検定の基礎
- 2 t検定, Wilcoxon検定, カイ2乗検定, マクネマー検定
重回帰分析, ロジスティック回帰, 検査データの解析
- 3 調査データ解析(1):
 - ・調査票の作成
社会調査, 調査票の作り方
 - ・データ入力



218