

保健統計学実習

第3日目

- 第7回 分散分析
- 第8回 重回帰分析
- 第9回 ロジスティック回帰、検査データの解析

滋賀医科大学NCD疫学研究センター
医療統計学部門

原田 亜紀子
(aharada@belle.shiga-med.ac.jp)

講義・演習スケジュール

回	日	内容
1	8/27(木)	1 R, EZR の使い方, データセットの読み込み, 頻度集計
		2 記述統計, 相関
		3 エクセルの基礎, Python 設定, 基本コード
2	8/28(金)	4 仮説検定の基礎, カイ2乗検定, マクネマー検定
		5 t 検定, Wilcoxon 検定, サンプルサイズ設計
		6 調査データ解析
3	9/1(火)	7 分散分析
		8 重回帰分析
		9 ロジスティック回帰, Poisson 回帰
4	9/2(水)	10 生存時間解析
		11 クラスター分析
		12 AI Deep learning 演習(1) * Python Collaboratory 使用
5	9/4(金)	13 AI Deep learning 演習(2) * Python Collaboratory 使用
		14 AI Deep learning 演習(3) * Python Collaboratory 使用
		15 解析実習まとめ(復習・課題の時間)

第7回 分散分析

解析手法の選択 データの型と解析の目的

	データの型		
	2値	連続	生存時間
解析の目的	集計・記述		
	1変量 頻度集計	ヒストグラム 要約統計量	Kaplan-Meier法
	2変量 分割表	散布図、相関係数	
	群比較	χ^2 検定	t検定
		Fisher 直接確率検定	Wilcoxon検定
	多群比較	コクランマンテル 検定	分散分析
モデルあてはめ		ロジスティック回帰	重回帰分析
			Cox回帰

分散分析


A病院, B病院, C病院でのある手術の手術時間について病院間の時間について差があるかを比較したい。

A	B	C
500	400	350
420	420	400
650	460	320
550	540	280
480	390	490



分散分析

赤と青の比較




分散分析表			
	偏差平方和	自由度	分散
全体変動	全体偏差平方和 S _t	n - 1 f _t	全体分散 V _t = S _t / f _t
群間変動	群間偏差平方和 S _a	群数 - 1 f _a	群間分散 V _a = S _a / f _a
群内変動	群内偏差平方和 S _e	n - 群数 f _e	群内分散 V _e = S _e / f _e

群内変動（誤差変動）より、施設間の分散が大きければ施設による差がある（右の方が群内変動が小さい）
分散比（群間変動と群内変動の比）をF検定で評価

分散分析

要因	自由度	平方和	平均平方	F 値	Pr > F
Model	2	57773.3333	28886.6667	4.89	0.0281
Error	12	70960.0000	5913.3333		
Corrected Total	14	128733.3333			



分散分析

$$\sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x})^2 = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2 + \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2$$

データと総平均の差の2乗和 (Sum of Square)

総平均と各水準の差の2乗和

データと各水準の差の2乗和

総変動
SS_T

水準間変動
SS_A

水準内変動 (誤差変動)
SS_E

$$\frac{SS_A}{SS_E}$$

水準間変動が、各水準内の変動より大きい小さいかを検定する

9

9

10

10

11

11

12

12

```
summary.anova
  平均 標準偏差  P値
shisetsu=A 520 86.31338 0.0261
shisetsu=B 442 60.99180
shisetsu=C 368 81.05554

> TukeyHSD(AnoVaModel.8, "factor(shisetsu)")
  Tukey multiple comparisons of means
    95% family-wise confidence level

fit: aov(formula = jikan ~ factor(shisetsu), data = dat)

factor(shisetsu)
diff      lwr      upr    p adj
3-A -78 -207.7507  51.75073 0.2815823
2-A -152 -281.7507 -22.24827 0.0221445
2-B -74 -203.7507  55.75073 0.3158631

> summary(AnoVaModel.8)
              Df Sum Sq Mean Sq F value Pr(>F)
factor(shisetsu) 2  57773   28887   4.885 0.0261 *
Residuals      12  70960    5913

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

施設別の平均時間

多重比較
Tukey

施設で差があるが、どの施設とどの施設で差があるかはこの検定からは明らかでない

群間での差を知りたい

ボンフェローニ

```
> pairwise.t.test(Dataset$jikan, Dataset$shisetsu, var.equal=TRUE, p.adj="bonferroni")

Pairwise comparisons using t tests with pooled SD

data: Dataset$jikan and Dataset$shisetsu

      A      B
B 0.404 -
C 0.026 0.462

P value adjustment method: bonferroni
```

ノンパラメトリック Kruskal-Wallis検定

```
summary.anova <- NULL
summary.anova <- data.frame(
  rownames(summary.anova) <-
  colnames(summary.anova) <-
  summary.anova
group.factor <- factor(hosp)
res <- aov(jikan ~ group.factor, data=summary.anova)
summary(ggth(res, linct=mcp(group.factor="Dunnnett")))
```

ノンパラメトリック 多重比較

• 3群以上の比較およびその多重比較はどのように行うか？

	パラメトリック	ノンパラメトリック	略説
2群	Student の t 検定	Wilcoxon 検定	多重比較調整無しでの比較
	Tukey の HSD 検定	Steel-Dwass 検定	ペアワイズな比較
	Dunnnett の多重比較検定	Steel 検定	コントロール群との比較
	-	Dunn 検定 (全てのペア)	Bonferroni 型の多重比較
	-	Dunn 検定 (コントロール群との比較)	Bonferroni 型の多重比較
3群	Hsu の MCB	-	任意の基準値 (最適値) との比較
	分散分析 F検定	Kruskal-Wallis検定	

```
Kruskal-Wallis rank sum test

data: jikan by factor(shisetsu)
Kruskal-Wallis chi-squared = 6.5183, df = 2, p-value = 0.03842

> cat(gettextRcmdr("Kruskal-Wallis test"), " ", gettextRcmdr("p-value"),
+ ", sep=")
3群以上の間の比較(Kruskal-Wallis検定) P値 = 0.0384

> Steel.Dwass(hosp$jikan, hosp$shisetsu)
      t      p
A:B 1.676233 0.21433221
A:C 2.193378 0.07228892
B:C 1.466704 0.30703807

> Steel(hosp$jikan, hosp$shisetsu)
      t rho  p.value
A:B 1.676233 0.5 0.16504251
A:C 2.193378 0.5 0.05237534
```

分散分析いろいろ

さきほどの例は、分散分析の中でシンプルな例でした。。。。

<分散分析を行う際の視点>

1) 研究の目的(どの群を比較したいと考えているか)

2) 時系列的な変化をみているか

3) 水準が1つか、2つか

1)–3)を確認して、解析方法を検討する



シンプルな例ばかりではありません

18


データの型：①一元配置分散分析

One-way Analysis of variance (ANOVA)



Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B,C)のいずれかが投与された。



Data structure P : 被験者

薬剤A P P P P P P P P P P

薬剤B P P P P P P P P P P

薬剤C P P P P P P P P P P

A・B・Cの比較を行いたい
時点ごとの測定はない

19


データの型：②繰り返し測定

Repeated measures ANOVA



Clinical Question

N名の神経障害性疼痛患者に対して、新薬の除痛薬を投与し、投与直前、30分後、60分後、90分後のVASの変化を調査した。



Data structure

	直前	30分後	60分後	90分後
Patient.1				
Patient.2				
Patient.3				
...				
Patient.N				

時点ごとの評価
薬は1種類(比較はない)

20

データの型：③反復測定

Repeated measures ANOVA

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B)のいずれかが投与され、投与直前、30分後、60分後、90分後のVASの変化を調査した。

対象

R

薬剤A

被験者

直前 30 60 90

n人の被験者に対して測定

薬剤B

被験者

直前 30 60 90

n人の被験者に対して測定

直前 30分後 60分後 90分後

薬剤A

Patient.1

Patient.2

...

Patient.N

薬剤B

Patient.1

Patient.2

...

Patient.N

時点ごとの評価
薬も比較

データの型：④二元配置分散分析

Two-way ANOVA

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B,C)のいずれかが投与された。この試験では、年齢(65歳以上、65歳未満)を割付調整因子とした。

対象

R

薬剤A

65歳未満 65歳以上

薬剤B

65歳未満 65歳以上

薬剤C

65歳未満 65歳以上

Data structure

P : 被験者

薬剤A

65歳未満 65歳以上

P P P P P P P P P P P P

薬剤B

65歳未満 65歳以上

P P P P P P P P P P P P

薬剤C

65歳未満 65歳以上

P P P P P P P P P P P P

薬の比較も
対象者属性(年齢)の比較も

データセットの形式

• 対応あり(反復測定されている)かどうか
データセットの配列

分散分析・反復測定(対応あり)データ

dog	COL1	COL2	COL3	COL4	COL5
1	900	792	792	768	873
2	1510	1189	1109	1028	1277
3	1540	1082	1049	1148	1310
4	1082	885	902	885	1311
5	1180	885	754	754	951
6	1311	984	1000	984	1279

分散分析・対応なし・混合モデルデータ

time	inu	y
1	1	900
2	1	792
3	1	792
4	1	768
5	1	873
1	2	1510
2	2	1189
3	2	1109
4	2	1028
5	2	1277
1	3	1540
2	3	1082
3	3	1049
4	3	1148
5	3	1310
1	4	1082
2	4	885
3	4	902
4	4	885
5	4	1311
1	5	1180
2	5	885
3	5	754
4	5	754
5	5	951
1	6	1311
2	6	984
3	6	1000
4	6	984
5	6	1279

データの型：①一元配置分散分析

One-way Analysis of variance (ANOVA)

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B,C)のいずれかが投与された。

対象

R

薬剤A

薬剤B

薬剤C

Data structure

P : 被験者

薬剤A

P P P P P P P P P P P P

薬剤B

P P P P P P P P P P P P

薬剤C

P P P P P P P P P P P P

A・B・Cの比較を行いたい
時点ごとの測定はない(対応はない)

例題1

データの型: ①一元配置分散分析
毒性実験: ラットへの投与

データセット
ANOVA_wide.sav
ANOVA_long.sav

・毒性試験

ANOVA wide.sav → 縦長データセットで解析する必要あり。変換してみる

Group	dose	Hb(mg/ml)									
A1	0	153	153	152	156	158	141	151	150	148	157
A2	5	158	152	152	152	151	151	157	147	155	146
A3	10	153	146	138	152	140	146	156	142	147	153
A4	20	137	139	141	141	143	133	147	144	151	156
A5	40	142	126	134	143	139	134	141	139	124	136

ラット



25

变换方法

[アクティブデータセット]-[変数の操作]-[複数の変数を縦に積み重ねた…]

The screenshot shows the RStudio interface. The R console contains the following code:

```
test[Dataset$1,jikan, Dataset$anovaModel.i2, "factor"]$hiisetu<-7; height<-7; par(wd=1, SD (anovaModel.i2, "factor")$r <- factor(Dataset$hiisetu ~ jikan, group=factor, data=ctires, linct=acp(group,fa
```

The Environment pane shows a data frame 'test' with 100 rows and 5 columns: jikan, Dataset, anovaModel.i2, factor, and SD. The Variables list pane shows a list of variables: jikan, Dataset, anovaModel.i2, factor, and SD.

26

ANOVA wide.sav

dos	VAR00001	VAR00002	VAR00003	VAR00004	VAR00005	VAR00006	VAR00007	VAR00008	VAR00009	VAR00010
A1	153	153	152	156	158	141	151	150	148	157
A2	158	152	152	152	151	151	157	147	155	146
A3	153	146	138	152	140	146	156	142	147	153
A4	137	139	141	141	143	133	147	144	151	156
A5	142	126	134	143	139	134	141	139	124	136

27

縦データを使用して解析

[統計解析]-[連続変数の解析]-[3群以上の間の平均値の比較]

R コマダー

ファイル 編集 アクティブデータセット 統計解析 グラフと表 ツール ヘルプ 標準メニュー

R データセット: Dataset

Rスクリプト Rマークダウン

```
summary.anova <- data.frame(
rownames(summary.anova) <-
colnames(summary.anova) <-
summary.anova
pairwise.t.test(Dataset$wei
group.factor <- factor(Data
res <- aov(weight ~ group, data=Dataset
summary(glsht(res, linct=mcp(group.factor="Dunnett
```

名義変数の解析

連続変数の解析

ノンパラメトリック検定

生存期間の解析

検定の正確度の評価

マッチペア解析

メタアナリシスとメタ計算

必要サンプルサイズの計算

連続変数の要約

外れ値の検定と除外 (Smirnov-Grubbs検定)

正規性の検定 (Kolmogorov-smirnov検定)

平均値の信頼区間の計算

1標本の平均値の検定

2群の等分散性の検定 (F検定)

2群間の平均値の比較 (t検定)

対応のある2群間の平均値の比較 (paired 検定)

3群以上の等分散性の検定 (Bartlett検定)

3群以上の平均値の比較 (一元配置分散分析 one-way ANOVA)

対応のある2群以上の間の平均値の比較 (反復(経時)測定分散分析)

複数の因子での平均値の比較 (多元配置分散分析 multi-way ANOVA)

連続変数で補正した2群以上の間の平均値の比較 (共分散分析 ANCOVA)

相関係数の検定 (Pearsonの線形相関係数)

線形回帰 (単回帰、重回帰)

線形適合効果モデル

出力

Simultaneous Tests for General Linear Hypothesis

Multiple Comparisons of Means: Dunnett Contrasts

Fit: aov(formula = weight ~ group.factor, data = Dataset)

28

たて型になったデータセットを使用



[分析]-[平均の比較]-[一元配置分散分析]

多重比較

一元配置分散分析

```
> summary(AovModel.10)
factor(dose)  Df Sum Sq Mean Sq F value    Pr(>F)    
Residuals    45  1477    32.8     14.13 0.000000151 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


463.9/32.82 = 14.13
```

$$\sum \sum (Y_{ij} - \bar{Y})^2 = \sum n_i (\bar{Y}_i - \bar{Y})^2 + \sum \sum (Y_{ij} - \bar{Y}_i)^2$$

平方和sum of squares 全体 モデルbetween 誤差within
自由度DF $\sum n_i - 1$ $k - 1$ $n - k$
degrees of freedom
平均平方 mean squares = SS/DF
F = model MS/error MS

```
> summary.anova
平均 標準偏差 P値
dose=A1 151.9 4.954235 0.000000151
dose=A2 152.1 3.842742
dose=A3 147.3 6.092801
dose=A4 143.2 6.746192
dose=A5 135.8 6.494442
```

多重比較



A1基準

A1 0
A2 5
A3 10
A4 20
A5 40

(整理) 分散分析 一般的な手順

1. 研究デザイン・データの型
2. データセット配置
3. 分析法の選択
(SPSSのコマンドの場合)
 - 平均の比較: 一元配置分散分析
 - 線型回帰: 一変量
反復測定
多変量
 - 混合モデル: 線型
4. 等分散性の確認
5. 分散分析結果(F値確認)
 - 交互作用含む場合⇒交互作用が有意な場合は 下位検定へ
6. 多重比較
7. 対比

データの型： ②一元配置分散分析(反復測定)

Repeated measures ANOVA

Clinical Question

N名の神経障害性疼痛患者に対して、新薬の除痛薬を投与し、投与直前、30分後、60分後、90分後のVASの変化を調査した。

対象 → 新薬投与

直前 30 60 90

被験者 → n人の被験者に対して測定

Data structure

	直前	30分後	60分後	90分後
Patient.1				
Patient.2				
Patient.3				
...				
Patient.N				

時点ごとの評価
薬は1種類(比較はない)

犬の血流測定 反復測定データ

データセット dog.sav

仮説:
血流は治療前(時点1)から減少し、治療後(時点5)には元に戻るか?

	1	2	3	4	5
Dog	900	792	792	768	873
	1510	1189	1109	1028	1277
	1540	1082	1049	1148	1310
	1082	885	902	885	1311
	1180	885	754	754	951
	1311	984	1000	984	1279

Time

データセットの形式

データセット dog.sav

• 対応あり(反復測定されている)かどうか
データセットの配列

分散分析・反復測定(対応あり)データ

dog	COL1	COL2	COL3	COL4	COL5
1	900	792	792	768	873
2	1510	1189	1109	1028	1277
3	1540	1082	1049	1148	1310
4	1082	885	902	885	1311
5	1180	885	754	754	951
6	1311	984	1000	984	1279

分散分析・対応なしデータ
混合モデル

time	inu	y
1	1	900
2	1	792
3	1	792
4	1	768
5	1	873
1	2	1510
2	2	1189
3	2	1109
4	2	1028
5	2	1277
1	3	1540
2	3	1082
3	3	1049
4	3	1148
5	3	1310
1	4	1082
2	4	885
3	4	902
4	4	885
5	4	1311
1	5	1180
2	5	885
3	5	754
4	5	754
5	5	951
1	6	1311
2	6	984
3	6	1000
4	6	984
5	6	1279

ヨコデータを使用して解析

[統計解析]-[連続変数の解析]-[対応のある2群以上の平均値の比較]

群は選択しない

“Time”として、t1-t5データを対応させる

2群ずつの比較(post-hoc検定)は比較する群別因子が1つの場合のみ実施される。

2群ずつの比較(Bonferroniの多重比較)

2群ずつの比較(Holmの多重比較)

モデル解所用に解析結果をアクティブモデルとして残す

一部のサンプルだけを解析対象にする場合の条件式。例: age > 50 & Sex == 0 & age < 50 | Sex == 1

<全ての有効なケース>

反復測定結果(SPSSでの出力)

被験者内効果の検定

ソース	タイプ III 平方和	自由度	平均平方	F 値	有意確率
血液	539884.133	4	134971.033	18.004	<.001
Greenhouse-Geisser	539884.133	2.190	246492.852	18.004	<.001
Huynh-Feldt	539884.133	3.965	136150.610	18.004	<.001
下限	539884.133	1.000	539884.133	18.004	.008

②

Mauchly の球面性検定

測定変数: MEASURE_1	Mauchly の W	近似カイニム	有意確率
血液	.059	9.679	.432

① モークリーの球面性検定

球面性検定が棄却されない→球面性の仮定が成り立つと判断
“②球面性の仮定”の数値をみる

球面性検定が棄却される→ “②’ Greenhouse-Geisser ε
Huynh-Feldt ε” で判断

EZR出力

Univariate Type III Repeated-Measures ANOVA Assuming Sphericity

	Sum Sq	num Df	Error SS	den Df	F value	Pr(>F)
(Intercept)	33104407	1	687833	5240.643	0.000020218	***
Time	539884	4	149932	20	18.004	0.000002077 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Mauchly Tests for Sphericity ① モークリーの球面性検定

Test statistic	p-value
Time	0.058838 0.43236

球面性検定が棄却されない
→球面性の仮定が成り立つと判断
“球面性の仮定”の数値をみる

Greenhouse-Geisser and Huynh-Feldt Corrections for Departure from Sphericity

	GG eps	Pr(>F[GG])
Time	0.54757	0.0002865 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

球面性検定が棄却されたなら こっちを
→ “②’ Greenhouse-Geisser ε
Huynh-Feldt ε” で判断

HF eps Pr(>F[HF])

	HF eps	Pr(>F[HF])
Time	0.9913362	0.00000228006

(補足)球面性？

- 球面性の仮定:分散の等質性の仮定に相当するもので、複合対称性という仮定の一部
 - 複合対称性(compound symmetry)
 - 条件間で分散が等しいこと、条件群の任意の対から作られる共分散が等しいことの両方が成り立つ状態
 - ただし、複合対称性はかなり厳しい基準で、実際のデータでは満たされないことが多い
 - また、この仮定は分散分析を適切に行うための十分条件だが、必要条件でない。
- 球面性の仮定(sphericity assumption;球形仮定, 球状性仮定)
 - 少しゆるい基準になっており、すべての条件間の差の分散が等しいことを仮定
 - 分散分析を適切に行うための必要十分条件である
- 球面？
 - データが3次元に分布するとして、x軸の分散がy軸、z軸よりも大きい場合を考えてみると、この楕円はx軸の方向に伸びたラグビーボールのような形。
 - すべての主軸の長さが等しくなれば、この楕円は球の形に近づく
 - 分布がどの方向に対しても等しければ、そのプロットは球に近づく

反復測定

Plot of Means

Time	Mean	Lower CI	Upper CI
t1	1250	1000	1500
t2	950	800	1100
t3	900	750	1050
t4	900	750	1050
t5	1150	950	1350

分散分析 一般的な手順


- 研究デザイン・データの型
- データセット配置
- 分析法の選択
 - (SPSSのコマンドの場合)
 - 平均の比較: 一元配置分散分析
 - 線型回帰: 一変量
 - 反復測定
 - 多変量
 - 混合モデル: 線型
 - 等分散性の確認** → 正規性、等分散性が成り立たないとき
 - 分散分析結果(F値確認)
 - 交互作用含む場合 → 交互作用が有意な場合は 下位検定へ
 - 多重比較
 - 対比

ノンパラメトリック検定
(対応あり) フリードマン検定

41

フリードマン検定

[統計解析]-[ノンパラメトリック検定]-[対応のある3群以上の間の比較]



```
res <- Anova(AnovaModel.2, idata=time, idesign="Time", type="III")
summary(res, multivariate=FALSE)
pairwise.pairredt.test(with(TempDF, cbind(t1, t2, t3, t4, t5)), group=NULL, "Dataset", p.adjust.met
```

出力

```
GG eps Pr>F[GG]
Time 0.54757 0.0002865 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


42

データの型: ③反復測定(二元配置)

データセット
bp.sav

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B)のいずれかが投与され。投与直前、30分後、60分後、90分後のVASの変化を調査した。




Repeated measures two-way ANOVA

時点ごとの評価
薬の比較もあり

43

反復測定2群の比較

データセット
bp.sav




異なる薬剤(D1,D2)があり、投与後の時点ごと(T0, T1, T3)の血圧値を測定

dose	obs	pre	T1	T3
D1	R1	119	113	114
D1	R2	110	115	112
D1	R3	123	126	111
D1	R4	130	127	100
D1	R5	121	115	124
D1	R6	135	125	115
D2	S1	125	109	113
D2	S2	108	98	104
D2	S3	133	118	117
D2	S4	125	114	110
D2	S5	113	107	106
D2	S6	126	118	110

前値に個人差があり、D2群(赤・破線)が短期的な効果は大きい、時点3での両群の差は小さいデータ

44

データの配置





データセット
bp.sav

45


解析手順

“Time”として、t0, t1, t3データを対応させる



46

結果



球面性検定が棄却されない→球面性の仮定が成り立つと判断
“球面性の仮定”の数値をみる


モークリーの球面性検定

球面性検定が棄却される→ “②”
Greenhouse-Geisser ε
Huynh-Feldt ε”で判断

47


交互作用とは？

- 主効果：血圧の作用
- 交互作用：薬剤の用量により血圧の反応が異なる



例) チキンの違いが味付けか？
(チキンの評価)

	クリスピー	普通
辛口	79.666...	72.666...
普通	71.00	74.333...



クリスピーチキンのときは辛口がよく、普通のチキンのときは普通味のほうがいい(交互作用)

48

交互作用が有意の場合は 下位検定へ(SPSS)

今回は交互作用は有意でないの、下位検定は行わないが。。。 [EM平均]-[単純主効果の比較]

49

単純主効果(SPSS)

単純主効果(SPSS)

測定変数名: MEASURE_1

ペアごとの比較

time	(I) dose	(J) dose	平均値の差 (I-J)	標準誤差	有意確率 ^a	95% 平均差信頼区間 ^a
1	D1	D2	1.333	5.207	.803	-10.268 12.935
	D2	D1	-1.333	5.207	.803	-12.935 10.268
2	D1	D2	9.500 ^b	4.099	.043	.366 18.634
	D2	D1	-9.500 ^b	4.099	.043	-18.634 -.366
3	D1	D2	2.667	3.694	.487	-5.564 10.897
	D2	D1	-2.667	3.694	.487	-10.897 5.564

推定周辺平均に基づいた。
* 平均値の差は .05 水準で有意です。
b. 多重比較の調整: Bonferroni.

測定変数名: MEASURE_1

ペアごとの比較

dose	(I) time	(J) time	平均値の差 (I-J)	標準誤差	有意確率 ^a	95% 平均差信頼区間 ^a
D1	1	2	2.833	2.012	.568	-2.941 8.607
	1	3	10.333	4.022	.084	-1.211 21.877
	2	3	-2.833	2.012	.568	-8.607 2.941
2	1	2	7.500	3.956	.262	-3.853 18.853
	1	3	-10.333	4.022	.084	-21.877 1.211
	2	3	-7.500	3.956	.262	-18.853 3.853
D2	1	2	11.000 ^b	2.012	<.001	5.226 16.774
	1	3	11.667 ^b	4.022	.047	1.23 23.211
	2	3	-11.000	2.012	<.001	-16.774 -5.226
3	1	2	.667	3.956	1.000	-10.686 12.020
	1	3	-11.667 ^b	4.022	.047	-23.211 -.123
	2	3	-.667	3.956	1.000	-12.020 10.686

推定周辺平均に基づいた。
* 平均値の差は .05 水準で有意です。
b. 多重比較の調整: Bonferroni.

Time2で群間に差がある。
D2において、T1とT2、T1とT3に差がある

50

多重比較

Pairwise comparisons using Paired t-test

```
data: Dataset
t0 t1
t1 0.0020 -
t3 0.0094 0.5251
P value adjustment method: bonferroni
```

Bonferroni

Pairwise comparisons using Paired t-test

```
data: Dataset
t0 t1
t1 0.0020 -
t3 0.0062 0.1750
P value adjustment method: holm
```

Holm

51

データの型: ④二元配置分散分析

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A, B, C)のいずれかが投与された。この試験では、年齢(65歳以上、65歳未満)を割付調整因子とした。

Data structure

	65歳未満	65歳以上
薬剤A	P P P P P	P P P P P
薬剤B	P P P P P	P P P P P
薬剤C	P P P P P	P P P P P

薬の比較
対象者属性(年齢)の比較

52

二元配置分散分析

データセット
2way.sav

スコア

A	M	8.18	7.24	7.00	7.00	8.00									
	F	7.69	9.69	8.89	6.94	2.13	7.26	5.87	7.20	6.81	6.67	6.98	7.07	5.00	
B	M	12.90	16.60	9.81	7.84	9.42	10.67	10.83							
	F	8.35	3.84	4.62	9.29	6.43									
C	M	12.40	14.00	11.60	13.90	11.20	13.21								
	F	12.20	9.41	2.40	9.78	7.00									

薬剤

- 41名(男性18名, 女性23名)
- 3種類の鎮痛薬(A,B,C)を投与し、痛みのスコアを用い評価
- 薬剤間での差を評価したい
- 男性、女性とで効果の差があるかも比較したい
- 薬剤により、性別による効果の違いがあるかも比較したい

53

二元配置分散分析

データセット
2way.sav

54

二元配置分散分析

55

二元配置

56


```
> tapply(TempDF$score, list(drug=TempDF$drug, sex=Temp
sex
drug      F      M
A 6.784615  7.48400
B 6.506000 11.15286
C 8.158000 12.71833

> tapply(TempDF$score, list(drug=TempDF$drug, sex=Temp
sex
drug      F      M
A 1.824293  0.5654025
B 2.935685  2.8531370
C 3.709167  1.1779714

> Anova(AnovaModel.22, type="III")
Anova Table (Type III tests)

Response: score
              Sum Sq Df F value    Pr(>F)
(Intercept)  2826.55  1 569.0539 < 2.2e-16 ***
Factor1.drug    68.44  2   6.8892  0.003001 **
Factor2.sex     99.49  1  20.0295  0.00007734 ***
Factor1.drug:Factor2.sex 33.60  2   3.3825  0.045392 *
Residuals     173.85 35
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

二元配置分散分析(EZR出力)

sex	drug A	drug B	drug C
F	6.78	6.51	8.16
M	7.48	11.15	12.72

薬剤、性別、薬剤・性別の交互作用が有意
薬剤Aの痛みを予防する効果が大きく、B,Cと比較し有意
薬剤 A に比べて薬剤 B,薬剤 C における性差が顕著であり、男性の痛みの程度が高い

二元配置分散分析(SPSS出力)

被験者間効果の検定

ソース	タイプ III 平方和	自由度	平均平方	F 値	有意確率
修正モデル	219.342 ^a	5	43.868	8.832	<.001
切片	2826.550	1	2826.550	569.054	<.001
Drug	68.439	2	34.220	6.889	.003
Sex	99.489	1	99.489	20.029	<.001
Drug * Sex	33.602	2	16.801	3.382	.045
誤差	173.849	35	4.967		
総和	3437.948	41			
修正総和	393.191	40			

a. R2 = .558 (調整済み R2 値 = .495)

多重比較

Dunnnett の t (2 サイドの)*

(I) Drug	(J) Drug	平均値の差 (I-J)	標準誤差	有意確率	95% 信頼区間
B	A	2.2378 ^a	.83059	.021	.3134 4.1621
C	A	3.6666 ^a	.85294	<.001	1.8904 5.6427

観測平均値に基づいています。
観差値は平均平方 (誤差) = 4.967 です。
* 平均値の差は 0.05 水準で有意です。
a. Dunnnett の t 検定は対照として 1 つのグループを扱い、それに対する他のすべてのグループと比較します。

薬剤、性別、薬剤・性別の交互作用が有意
薬剤Aの痛みを予防する効果が大きく、B,Cと比較し有意
薬剤 A に比べて薬剤 B,薬剤 C における性差が顕著であり、男性の痛みの程度が高い

交互作用が有意⇒下位検定

[EM平均]-[単純主効果の比較]

1 変量: 検定済み平均

因子と交互作用 (I): drug, sex, drug*sex

平均値の表示 (J): drug*sex

単純主効果の比較 (K): drug, sex, drug*sex

検定済み平均 (L): drug*sex

結果: 3 個 (3 変数中)

下位検定

ペアごとの比較

従属変数: score		95% 平均差信頼区間 ^b				
sex	(i) drug (j) drug	平均値の差 (i-j)	標準誤差	有意確率 ^a	下限	上限
F	A B	.279	1.173	1.000	-2.670	3.228
	A C	-1.373	1.173	.749	-4.322	1.576
	B A	-.279	1.173	1.000	-3.228	2.670
	B C	-1.652	1.410	.747	-5.196	1.892
	C A	1.373	1.173	.749	-1.576	4.322
	C B	1.652	1.410	.747	-1.892	5.196
M	A B	-3.669 ^a	1.305	.024	-6.950	-.387
	A C	-5.234 ^a	1.350	.001	-8.628	-1.841
	B A	3.669	1.305	.024	-.387	6.950
	B C	-1.565	1.240	.645	-4.683	1.552
	C A	5.234 ^a	1.350	.001	1.841	8.628
	C B	1.565	1.240	.645	-1.552	4.683


推定周辺平均に基づいた
^a 平均値の差は 0.05 水準で有意です。
^b 多重比較の調整: Bonferroni.

ペアごとの比較

従属変数: score		95% 平均差信頼区間 ^b				
drug	(i) sex (j) sex	平均値の差 (i-j)	標準誤差	有意確率 ^a	下限	上限
A	F M	-.699	1.173	.555	-3.080	1.682
	M F	.699	1.173	.555	-1.682	3.080
B	F M	-4.647 ^a	1.305	.001	-7.296	-1.998
	M F	4.647 ^a	1.305	.001	1.998	7.296
C	F M	-4.560 ^a	1.350	.002	-7.300	-1.821
	M F	4.560 ^a	1.350	.002	1.821	7.300

推定周辺平均に基づいた
^a 平均値の差は 0.05 水準で有意です。
^b 多重比較の調整: Bonferroni.

第8回 重回帰分析



解析の手順 線形モデルのあてはめとモデル診断

なぜ線形モデルを使うのか？

- データ削減
- 予測式を算出したい ← 決定係数、残差の検討を丁寧にを行う
- パラメータ値の解釈(従属変数に対する独立変数の影響) ← 偏回帰係数の有意性を重視してモデルを作る

仮定は正しいか？

- $y = x + \text{誤差}$
- 誤差の変動: 平均は0, 分散は等しい, 独立, ほぼ正規分布

回帰診断

- 残差の検討と影響度分析

線形回帰

- xに対するyの線形回帰
- y: 応答, 従属変数
- x: 説明変数, 独立変数

予測 $\hat{y} = a + bx$

残差 $y - \hat{y}$





Fig.1 : (General) liner model

yという結果に対して、原因と考えられるxがどのように影響しているかを検討する手法


(例) 握力 = $a + b_1 \times (\text{年齢}) + b_2 \times (\text{性別}) + b_3 \times (\text{体重})$

回帰と最小二乗法



残差が最小となるよう、係数を推定する
 $y = b_0 + b_1x_{11} + \dots + b_px_{pn}$

実測値 (y)	予測値 ($\hat{y}$)	誤差 e_j
y_1	$b_0 + b_1x_{11} + \dots + b_px_{p1}$	$y_1 - \hat{y}_1$
y_2	$b_0 + b_1x_{12} + \dots + b_px_{p2}$	$y_2 - \hat{y}_2$
y_n	$b_0 + b_1x_{1n} + \dots + b_px_{pn}$	$y_n - \hat{y}_n$




- 1. モデルのあてはまり
- 2. 変数選択によるモデル構築
- 3. モデルの解釈・評価

線形モデルフィッティング
Anscombe's quartet

データセット
Ans1.csv~Ans4.csv
Ans1.sav~Ans4.sav

- 単純な記述統計量はほぼ同じだが、分布が大きく異なり、グラフにすると大きく異なって見える4つのデータセット。
- これらは、統計学者Francis Anscombeによって、データを分析する前にグラフ化することの重要性と、外れ値やその他の影響力のある観測値が統計的性質に及ぼす影響の両方を示すために、1973年に作成されたものです。




	I		II		III		IV	
	X_1	Y_1	X_2	Y_2	X_3	Y_3	X_4	Y_4
	10	8.04	10	9.14	10	7.46	8	6.58
	8	6.95	8	8.14	8	6.77	8	5.76
	13	7.58	13	8.74	13	12.74	8	7.71
	9	8.81	9	8.77	9	7.11	8	8.64
	11	8.33	11	9.25	11	7.81	8	8.47
	14	9.96	14	8.10	14	8.84	8	7.04
	6	7.24	6	6.13	6	6.08	8	5.25
	4	4.26	4	3.10	4	5.39	19	12.5
	12	10.84	12	9.13	12	8.15	8	5.56
	7	4.82	7	7.26	7	6.42	8	7.91
	5	5.69	5	4.74	5	5.73	8	6.89
AVG	9	7.50	9	7.50	9	7.50	9	7.50
VAR	11	4.127	11	4.128	11	4.123	11	4.123
CORREL		0.816		0.816		0.816		0.817

線形モデルフィッティング
Anscombe's quartet

データセット
Ans1.csv~Ans4.csv
Ans1.sav~Ans4.sav


- 形状は全く異なるが、要約統計では類似している4つのデータセット




	I		II		III		IV	
	X_1	Y_1	X_2	Y_2	X_3	Y_3	X_4	Y_4
	10	8.04	10	9.14	10	7.46	8	6.58
	8	6.95	8	8.14	8	6.77	8	5.76
	13	7.58	13	8.74	13	12.74	8	7.71
	9	8.81	9	8.77	9	7.11	8	8.64
	11	8.33	11	9.25	11	7.81	8	8.47
	14	9.96	14	8.10	14	8.84	8	7.04
	6	7.24	6	6.13	6	6.08	8	5.25
	4	4.26	4	3.10	4	5.39	19	12.5
	12	10.84	12	9.13	12	8.15	8	5.56
	7	4.82	7	7.26	7	6.42	8	7.91
	5	5.69	5	4.74	5	5.73	8	6.89
AVG	9	7.50	9	7.50	9	7.50	9	7.50
VAR	11	4.127	11	4.128	11	4.123	11	4.123
CORREL		0.816		0.816		0.816		0.817

モデル診断をやってみよう

回帰分析を行う



69



70

偏回帰係数、標準偏回帰係数

- 偏回帰係数
- 偏回帰係数は重回帰モデルにおける独立変数の係数である
 - 他の独立変数の影響を除外した回帰係数となる

- 標準偏回帰係数(β)
- 平均0、分散1に標準化した単位に依存しない係数(変数間の比較が行えるようにする)
 - 各独立変数が従属変数にどのくらい影響しているかを評価できる



標準偏回帰係数

- 標準偏回帰係数(A_i) a_i S_x:xの標準偏差, SD_y:yの標準偏差

$$A_i = a_i \times \frac{SD_x}{SD_y} = 0.50 \times (3.31 / 2.03) = 0.815$$



- 標準化したデータセットで重回帰
 - z <- scale(Ans1)
 - z <- data.frame(z)データセットZで重回帰分析を実施

	回帰係数推定値	95%信頼区間下限	95%信頼区間上限	標準誤差	t統計量	P値
(Intercept)	-1.673724e-17	-0.4151695	0.4151695	0.1835281	-9.119714e-17	1.000000000
x	8.164205e-01	0.3809871	1.2518540	0.1924859	4.241455e+00	0.002169629



$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$\hat{R}^2 = 1 - \frac{n-1}{n-p-1}(1-R^2)$$



参考: 影響度・残差関連の指標

MODEL Option or Statistic	Formula	
PRED ($\hat{Y}_i$)	$X_i b$	予測値
RES (r_i)	$Y_i - \hat{Y}_i$	残差
H (h_i)	$x_i (X'X)^{-1} x_i'$	デコ比: 説明変数空間での外れ度、何個の回帰係数を決定しているか<1
STDP	$\sqrt{h_i \sigma^2}$	
STDI	$\sqrt{(1+h_i) \sigma^2}$	
STDR	$\sqrt{(1-h_i) \sigma^2}$	
LCL	$\hat{Y}_i - t_{\alpha/2} \text{STDI}$	
LCLM	$\hat{Y}_i - t_{\alpha/2} \text{STDP}$	
UCL	$\hat{Y}_i + t_{\alpha/2} \text{STDI}$	
UCLM	$\hat{Y}_i + t_{\alpha/2} \text{STDP}$	
STUDENT	$\frac{r_i}{\sigma_i}$	基準化した残差
RSTUDENT	$\frac{\text{STDR}_i}{\sigma_i}$	基準化した残差 (分散を当該obsを除いて計算)
COOKD	$\frac{1}{p} \frac{\text{STUDENT}^2 \text{STDP}^2}{\text{STDR}^2}$	Cook's D (当該obsを除いたときのあてはめ結果の全体としての変化)
COVRATIO	$\frac{\det((\hat{\sigma}_{ij}^2(X_{ij} - \bar{X}_{ij}))^{-1})}{\det(\hat{\sigma}_{ij}^2(X_{ij} - \bar{X}_{ij}))^{-1}}$	
DFBETIS	$\frac{(\hat{Y}_i - \bar{Y}_{(i)})}{(b_{(i)} - b_{(i)})}$	これを2乗しpで割り分散を置き換えたものがCook's D
DFBETAS _j	$\frac{(b_j - b_{(i)})}{\hat{\sigma}_{(i)} \sqrt{(X'X)^{-1}_{jj}}}$	当該obsを除いた時の個々の回帰係数の変化
PRESS(predr)	$\frac{r_i}{1-h_i}$	

77

data=ans2

モデルの要約^b

モデル	R	R2乗	調整済み R2乗	推定値の標準誤差	Durbin-Watson
1	.816 ^a	.666	.629	1.23721	2.188

a. 予測値: (定数)、 X_1
b. 従属変数 y

分散分析^a


モデル	平方和	自由度	平均平方	F値	有意確率
1	回帰 27.500	1	27.500	17.966	.002 ^b
	残差 13.776	9	1.531		
合計	41.276	10			

a. 従属変数 y
b. 予測値: (定数)、 X_1

係数^a

モデル	B	非標準化係数		標準化係数		t値	有意確率	Bの95.0%信頼区間	
		標準誤差	ベータ	下限	上限				
1	(定数)	3.001	1.125			2.667	.026	.455	5.547
	X_1	.500	.118	.816		4.239	.002	.233	.767

a. 従属変数 y



78

lm(y ~ x)

```
Call:
lm(formula = y ~ x, data = ANS2)


Residuals:
    Min       1Q   Median       3Q      Max
-1.9009  -0.7609   0.1291   0.9491   1.2691

Coefficients:
(Intercept)    3.001    1.125    2.667    0.02576 *
x              0.500    0.118    4.239    0.00218 **


Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.237 on 9 degrees of freedom
Multiple R-squared:  0.6662, Adjusted R-squared:  0.6292
F-statistic: 17.97 on 1 and 9 DF, p-value: 0.002179
```


Residuals vs Fitted




Normal Q-Q



Scale-Location



Residuals vs Leverage



79

data=ans3

モデルの要約^b

モデル	R	R2乗	調整済み R2乗	推定値の標準誤差	Durbin-Watson
1	.816 ^a	.666	.629	1.23631	2.144

a. 予測値: (定数)、 X_1
b. 従属変数 y

分散分析^a


モデル	平方和	自由度	平均平方	F値	有意確率
1	回帰 27.470	1	27.470	17.972	.002 ^b
	残差 13.756	9	1.528		
合計	41.226	10			

a. 従属変数 y
b. 予測値: (定数)、 X_1


係数^a


モデル	B	非標準化係数		標準化係数		t値	有意確率	Bの95.0%信頼区間		ゼロ次	相関	部分	共線性の統計量	
		標準誤差	ベータ	下限	上限			許容度	VIF					
1	(定数)	3.002	1.124			2.670	.026	.459	5.546					
	X_1	.500	.118	.816		4.239	.002	.233	.766	.816	.816	.816	1.000	1.000

a. 従属変数 y



80





85

1. モデルのあてはまり
2. 変数選択によるモデル構築
3. モデルの解釈・評価

86


変数選択

相関の高い変数をモデルに含めると係数が不安定になる(多重共線性)。

<対策>

- ① 変数の選択
 - ALL(全変数を一度に入力)
 - FORWARD(前方、増加)
 - BACKWARD(後方、減少)
 - STEPWISE(増加/減少)を使用する。
- ② 合成変数の作成
- ③ 事前情報の利用(ベイズ型)

87



88

演習 変数選択

“select.csv”データは、 $y=x1+x2+x3$ +誤差($x1, x2, x3$ は独立)というモデルで作られています。

- $x4$ は $x1$ と高い相関がある
- $x5$ は $x2$ と高い相関がある
- $x6$ - $x15$ は互いに独立であり、 y とも独立である。

変数選択を適用して、どのような結果が得られるか確認してください。

$x1$ - $x15$ を用いてモデルを作成する。相関の高い変数を含む場合、どのような変数が選択されるのか

データセット
select.csv
select.sav

89

• AICの値をもとに

```
Call:
lm(formula = y ~ x1 + x2 + x3, data = TempDF)

Residuals:
    Min       1Q   Median       3Q      Max
-2.4259 -0.7411  0.1107  0.6243  2.4522

Coefficients:
(Intercept) 0.0003582 0.1077994 0.003 0.997
x1          1.0127592 0.1134334 8.928 2.99e-14 ***
x2          1.0043876 0.1057964 9.493 1.82e-15 ***
x3          0.8505119 0.1024469 8.302 6.50e-13 ***

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.053 on 96 degrees of freedom
Multiple R-squared:  0.7171, Adjusted R-squared:  0.7083
F-statistic: 81.13 on 3 and 96 DF,  p-value: < 2.2e-16
```

90

• P値をもとに

-----最終モデル

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0003582008	0.1077994	0.003322845	9.973557e-01
x1	1.0127591938	0.1134334	8.928231348	2.982089e-14
x2	1.0043875576	0.1057964	9.493397871	1.823853e-15
x3	0.8505119339	0.1024469	8.301979590	6.496778e-13

91

重回帰分析 注意点


1. 目的の再確認
 - 1) 予測式を算出したい
→ 決定係数や残差の検討を詳細に
 - 2) パラメータ値の解釈(従属変数に対する独立変数の影響)
→ 偏回帰係数の有意性を重視してモデルを構築する
→ 仮説に合わせた変数の投入(強制投入)
2. 標本数と独立変数の数
独立変数1つに対し $n \geq 20 \sim 30$ 程度が目安
3. 外れ値のチェック
4. 独立変数間の相関
5. 正規分布からのズレが大きい場合は変数変換(対数変換など)

92

第9回 ロジスティック回帰

93

一般線形モデル 一般化線形モデル



94

一般線形モデル→一般化線形モデル

GLMは正規分布だけでなく、指数族(二項、ガンマ、ポアソンなど)の分布も扱うことができます！




Fig.1 :一般線形モデル




Fig.2 :一般化線形モデル(例:ポアソン)

95

GLMは以下の3つの要素で構成される

1. 確率分布の指数族
指数族(二項、ガンマ、ポアソンなど)
2. 線形予測量
 $\eta = X\beta$
線形予測量(η)は独立変数の情報をモデルに取り込む量である。
 η は未知パラメータ β の線形結合(したがって「線形」)で表され、線形結合の係数は独立変数の行列 X として表される。
3. リンク関数
ある式を線形に変換する関数。

96

Link function

式を線形に変換する関数

Distribution	Support				Variance	Mean function
Normal	real: $(-\infty, +\infty)$					
Exponential						
Gamma	real: $(0, +\infty)$					$\mu(\theta)^{-1}$
Inverse Gaussian	real: $(0, +\infty)$					$\mu(\theta)^{-3/2}$
Poisson	integer: $0, 1, 2, \dots$	Discrete variable	Bernoulli	binomial	logit	$\mu(1 - \mu)$
Bernoulli	integer: $\{0, 1\}$		Binomial	binomial	logit	$\mu(1 - \mu) \cdot \theta$
Binomial	integer: $0, 1, \dots, K$		Poisson	poisson	log	μ
Categorical	K-vector of integer element in the v		Gamma	gamma	log かな?	μ^2
Multinomial	K-vector of integer: $\{0, N\}$		Normal	gaussian	identity	一定

Probability Distribution → glm() の family → Frequently used link functions

97

回帰モデルの拡張

- 0-1データに対するロジスティック回帰
- 頻度データに対するポアソン回帰
- 生存時間データに対するCox回帰
- 一般化推定方程式 (Generalized Estimating Equation)
 - 反復測定データに対するGEE
- 個人差、階層、繰り返しを扱うことができるモデル (混合モデル)
 - 線型:
 - 一般化線型:
 - 非線型:

98

Logistic regression

ロジスティック回帰では、従属変数はオッズの自然対数であるロジットである、

$$\log(\text{odds}) = \text{logit}(P) = \ln\left(\frac{P}{1-P}\right)$$

ロジットとはオッズの対数であり、オッズはPの関数である。ロジスティック回帰では、次のようになる。

$$\text{logit}(P) = \ln\left(\frac{P}{1-P}\right) = a + bX$$
$$\frac{P}{1-P} = e^{a+bx}$$
$$P = \frac{e^{a+bx}}{1 + e^{a+bx}}$$

99

Example

データセット 神経痛(N=60)

高齢者における神経痛の鎮痛剤に関する研究

痛みの有無と薬剤の関連を検討

Neuralgia.csv
Neuralgia.sav

- 従属変数: 痛みの消失率(痛みの有無:有、無)
- 独立変数: 治療法(Treatment: P(プラセボ)、A、B)
- 共変量:
- Sex(性別:F、M)
- 年齢(治療開始時の年齢:連続変数)
- Duration(罹病期間:連続量(月))

100

Logistic regression

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	15.574390	6.591008	2.363	0.01813 *
Age	-0.262093	0.097012	-2.702	0.00690 **
Duration	0.005693	0.032992	0.178	0.85905
Sex[T.F]	1.632202	0.786206	2.301	0.02138 *
Treatment[T.B]	3.708542	1.140577	3.251	0.00115 **
Treatment[T.A]	3.181690	1.016021	3.132	0.00174 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 81.503 on 59 degrees of freedom
 Residual deviance: 48.736 on 54 degrees of freedom
 AIC: 60.736

Number of Fisher Scoring iterations: 5

$$\ln\left(\frac{p}{1-p}\right) = a + bX$$


$$\frac{p}{1-p} = e^{a+bX}$$

odds


	オッズ比	95%信頼区間下限	95%信頼区間上限	P値
(Intercept)	5810000.000	14.200	2.37e+12	0.01810
Age	0.769	0.636	9.31e-01	0.00690
Duration	1.010	0.943	1.07e+00	0.85900
Sex[T.F]	6.250	1.310	2.97e+01	0.02140
Treatment[T.B]	40.800	4.360	3.81e+02	0.00115
Treatment[T.A]	24.100	3.290	1.76e+02	0.00174

$e^{3.1817} = 24.0974$
 $e^{3.7085} = 40.7942$


104




105




106




107




108




109



110



111



112

課題3-1

脳動脈瘤保有による破裂のリスクを評価したい

- N=1027のデータ(data=rapture)
- 下記変数
 - Rupture:動脈瘤破裂の有無
 - Male:男性
 - Age:年齢
 - Number aneurysm:動脈瘤の個数
 - Hypertension:高血圧
 - Hyperlipidemia:脂質異常
 - fh.SAH:SAHの家族歴
 - Bifurcation:分岐部に瘤あり
 - Bleb:嚢胞上の構造あり
 - MCA:中大脳動脈
 - VABA椎骨脳底動脈瘤
 - Size:大きさ
- Logistic回帰を用い、動脈瘤破裂のリスク因子の特定、破裂予測モデルを構築する
 - ROC曲線、予測確率プロットなどを示せ

Poisson解析

Poisson regression

分布:Poisson分布、リンク関数:log

- ポアソン回帰は、カウント(計数)データや分割表をモデル化するために用いられる回帰分析の一般化線形モデル形式である。
- ポアソン回帰は、応答変数Y がポアソン分布を持っていて、その期待値の対数が未知パラメータの線形結合によってモデル化できると仮定する。
- これは、希少事象に適している。
 - 稀な事象
 - 保険金請求率
 - 機器の故障
 - 犯罪の発生

Poisson distribution


- 歪んでいる
- 非負の値のみをとる
- 分散は平均に等しい

$$f(k; \lambda) = \Pr(X=k) = \frac{\lambda^k e^{-\lambda}}{k!},$$

where

- K is the number of occurrences (k=0,1,2 · · ·)
- λ is equal to the expected value (E(x)) of X and also to its variance (V(E))

$$\lambda = E(X) = \text{Var}(X).$$



過(剰)分散Over-dispersion

- 結果変数の分散が期待値より大きい
- ポアソン分布の分散の理論値は、期待値と等しい。
- 過分散は、標準誤差の過小評価やカイ二乗統計量の過大評価につながることがある。
注) 過分散の場合、仮定したモデルでは実際のデータより誤差が小さく推定され有意差が出やすくなる。

→過分散のチェックが必要 “Residual deviance(残差逸脱度)”

$$\lambda = E(X) = \text{Var}(X).$$

(仮定) 平均と分散が等しい

- なぜ過大分散が起こるのか？
 - モデルに含まれていない重要な効果がある場合、平均値の差を十分に説明できない。
 - 外れ値が存在する。
 - 変数間に正の相関がある

117

117

過分散の対応

- モデルの誤差の調整
 - Dispersion parameter
$$\hat{\phi} = \frac{\text{Pearson}\chi^2}{\text{Residual degrees of freedom}} = \frac{\sum_i (y_i - \hat{\mu}_i)^2 / \hat{\mu}_i}{\text{Residual degrees of freedom}}$$
- Poisson分布よりばらつきの大きな負の二項分布を用いる

118

118

例:Open water swimmerの耳の感染

- ニューサウスウェールズ州水道局が1990年に行った「サーフヘルス調査(Pilot Surf/Health Study)」によるものである。
- この研究の目的は、特に、ビーチで泳ぐ人が、ビーチで泳がない人よりも耳の感染症にかかるリスクが高いかどうかを判断することでした。
- データセット(ear_infection)には、5つの変数と287のオブザベーションが含まれる

Variable	Variable Name	Variable Type	Variable Values
Frequent Ocean Swimmer	fos	Categorical	1=Yes 2=No
Location	location	Categorical	1=Non-beach 4=Beach
Age Group	agegroup	Ordinal	2=15 to 19 years 3=20 to 24 years 4=25 to 29 years
Sex	sex	Categorical	1=Male 2=Female
Number of Ear Infections	numearinfections	Continuous	0-17

セーヌ川に許容水準超す大腸菌、水泳には危険レベル ナポリ五輪





119

119

耳の感染頻度

earinfection.csv
earinfection.sav



120

120

一般化線形モデル

[標準メニュー]-[統計量]-[モデルへの適合]-[一般化線形モデル]

R コマンド

データセット: Dataset

Rスクリプト Rマークダウン

```
summary(GLM.4, dispersion=db)

#####ヒストグラム#####
windows(width=7, height=7); par(lwd=1, las=1, family="sans")
res <- hist(Dataset$infections, breaks="scott", plot=FALSE)
temp.y <- Dataset[Dataset$swimmer=="Fred", $infections]
temp.h <- hist(temp.y, breaks=res$breaks, plot=FALSE)$counts
temp.y <- Dataset[Dataset$swimmer=="Oocas", $infections]
temp.h <- rbind(temp.h, hist(temp.y, breaks=res$breaks, plot=FALSE)$counts)
barplot(temp.h, beside=TRUE, space=c(0, 0.4), names.arg=res$breaks[-length(res$breaks)], las=1, col="red", border="black",
        breaks <- NULL,
        colnames(temp.h) <- breaks
        rownames(temp.h) <- levels(as.factor(Dataset$swimmer))
temp.h
```

出力

GLM.4

統計量

モデルへの適合

一般化線形モデル

一般化線形モデル

モデル名を入力: GLM.5

変数 (ダブルクリックして式に入れる)

age (因子)
gender (因子)
infections
location (因子)
swimmer (因子)

モデル式

Operators (click to formula): + * / %in% ^ ()

スプライン/多項式: B-spline 自然 直交 通常の スプラインの自由度: 5

infections ~ age + gender + location + swimmer

Indices or names of row(s) to remove
< use all valid cases >

部分集合の表現
< 全ての有効なケース >

Weights
< 変数が選択されていません >

リンク関数 (ダブルクリックで選択)

リンク関数

gaussian
binomial
poisson
gamma
inverse.gaussian
quasibinomial
quasipoisson

identity
log
sqrt

従属変数: infections
独立変数: age gender location swimmer

Poisson回帰

分布: Poisson分布
リンク関数: log

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
     family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      Estimate Std. Error z value Pr(>|z|)
age[T.20-24]    -0.37442    0.12836  -2.917   0.00354 **
age[T.25-29]    -0.18973    0.13009  -1.458   0.14473
gender[T.Male]  -0.08985    0.11231  -0.800   0.42371
location[T.NonBeach] 0.53454    0.10688   5.011 0.00000054269 ***
swimmer[T.Oocas] 0.61149    0.10500   5.823 0.0000000577 ***

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

[Dispersion parameter for poisson family taken to be 1]

Null deviance: 824.51 on 288 degrees of freedom
Residual deviance: 755.43 on 281 degrees of freedom
AIC: 1135.6

Number of Fisher Scoring iterations: 6

> exp(coef(GLM.5)) # Exponentiated coefficients
(Intercept)      age[T.20-24]      age[T.25-29]      gender[T.Male]      location[T.NonBeach]      swimmer[T.Oocas]
0.8446066      0.6676857      0.8271832      0.9140681      1.7066565      1.8431889
```

年齢

20-24 vs. -19 0.688
25-29 vs. -19 0.827

男vs.女 0.91

場所

海以外vs 海 1.71
頻度

たまにvs.頻回 1.84

過分散

デヴィアンス/DF=755.43/281=2.698
または
Pearsonカイ2乗/DF=3.379853

1を超える場合過分散

過分散の対応

Rcode: Diversion parameter

過分散(pearsonカイ2乗/DF)

sum(residuals(GLM.1,type="pearson")^2)/GLM.5\$df.residual

補正計算

dp <- sum(residuals (GLM.5,type="pearson")^2) / GLM.5\$df.res

summary(GLM.5, dispersion=dp)

過分散調整

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
     family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      -0.12261    0.25197   -0.487   0.62653
age[T.20-24]     -0.37442    0.23599   -1.587   0.11260
age[T.25-29]     -0.18973    0.23917   -0.793   0.42762
gender[T.Male]    -0.08985    0.20648   -0.435   0.66345
location[T.NonBeach] 0.53454    0.19613    2.725   0.00642 **
swimmer[T.Occas]  0.61149    0.19304    3.168   0.00154 **

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 3.379853)

Null deviance: 824.51  on 286  degrees of freedom
Residual deviance: 755.43  on 281  degrees of freedom
AIC: 1139.8
```

125

過分散調整

調整なし

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
     family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      -0.12261    0.13706   -0.895   0.37100
age[T.20-24]     -0.37442    0.12836   -2.917   0.00354 **
age[T.25-29]     -0.18973    0.13009   -1.458   0.14473
gender[T.Male]    -0.08985    0.11231   -0.800   0.42371
location[T.NonBeach] 0.53454    0.10668    5.011   0.00000054269 ***
swimmer[T.Occas]  0.61149    0.10500    5.823   0.00000000577 ***
```

調整あり

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
     family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      -0.12261    0.25197   -0.487   0.62653
age[T.20-24]     -0.37442    0.23599   -1.587   0.11260
age[T.25-29]     -0.18973    0.23917   -0.793   0.42762
gender[T.Male]    -0.08985    0.20648   -0.435   0.66345
location[T.NonBeach] 0.53454    0.19613    2.725   0.00642 **
swimmer[T.Occas]  0.61149    0.19304    3.168   0.00154 **
```


平均が決まれば分散も決まってしまうため、実際のばらつきとの間に解離があることが多いため、過分散のチェックが必要

過分散の場合、仮定したモデルでは、
・実際よりも誤差が小さく推定され
・Zvalueが大きくなり有意差が出やすくなる

$SE(\beta_1) = \sqrt{(0.105)^2 \times 3.3799} = 0.19305$

3.3799 = Pearson/DF 1を超えていると過分散

126



過分散の対応

1. モデルの誤差の調整

- Dispersion parameter

$$\hat{\phi} = \frac{Pearson\chi^2}{Residual\ degrees\ of\ freedom}$$
$$= \frac{\sum_i (y_i - \hat{\mu}_i)^2 / \hat{\mu}_i}{Residual\ degrees\ of\ freedom}$$

2. Poisson分布よりばらつきの大きな負の二項分布を用いる

128

負の二項分布

```
##negative binominal
install.packages("MASS")
library(MASS)

result_nb<-glm.nb(infections~age + gender + location
+ swimmer, data=Dataset)

summary(result_nb)
exp(coef(result_nb)) # Exponentiated coefficients
```

129

129

負の二項

```
Call:
glm.nb(formula = infections ~ age + gender + location + swimmer,
data = Dataset, init.theta = 0.5759778332, link = log)

Coefficients:
(Intercept)      Estimate Std. Error z value Pr(>|z|)
age[T.20-24]    -0.06082    0.23914  -0.254  0.79924
age[T.25-29]    -0.42924    0.23433  -1.832  0.06898
age[T.25-29]    -0.26250    0.24050  -1.091  0.27506
gender[T.Male]   -0.14002    0.20789  -0.674  0.50063
location[T.NonBeach] 0.54554    0.19605   2.783  0.00539 **
swimmer[T.Occas] 0.60305    0.18965   3.180  0.00147 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(0.576) family taken to be 1)

Null deviance: 289.90  on 286  degrees of freedom
Residual deviance: 269.13  on 281  degrees of freedom
AIC: 904.69

> exp(coef(result_nb)) # Exponentiated coefficients
(Intercept)      age[T.20-24] age[T.25-29] gender[T.Male] location[T.NonBeach] swimmer[T.Occas]
0.9409927      0.8510050      0.7691229      0.8693440      1.7255406      1.8276788
```

水泳頻度と場所が有意
リスク比
たまにvs.頻回 1.83
海以外vs.海 1.73

130

130

ゼロ過剰Poisson

```
Zero-inflation model coefficients (binomial with logit link):
      Estimate Std. Error z value Pr(>|z|)
(Intercept)    0.381059    0.334142   1.140   0.2541
age[T.20-24]   -0.004427    0.344180  -0.013   0.9897
age[T.25-29]   -0.024362    0.345686  -0.070   0.9438
gender[T.Male] -0.036735    0.300468  -0.122   0.9027
location[T.NonBeach] -0.725336    0.284673  -2.548   0.0108 *
swimmer[T.Occas] -0.189300    0.277742  -0.682   0.4955
---
```

場所が有意
リスク比
海以外vs.海 1.73

131

131

ゼロ過剰負の二項分布

```
Zero-inflation model coefficients (binomial with logit link):
      Estimate Std. Error z value Pr(>|z|)
(Intercept)   -2.3466    1.7221  -1.363   0.173
age[T.20-24]   0.5716    1.0841   0.527   0.598
age[T.25-29]   0.4764    0.9716   0.490   0.624
gender[T.Male]  1.2528    1.1912   1.052   0.293
location[T.NonBeach] -12.9315    323.6701  -0.040   0.968
swimmer[T.Occas] 0.7042    0.8637   0.797   0.426
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Theta = 0.7894
Number of iterations in BFGS optimization: 56
Log-likelihood: -440.9 on 13 Df

132

132

AIC

- Poisson AIC: 1139.8
- 負の二項分布 AIC: 904.69
- ゼロ過剰Poisson AIC: 966.2640
- ゼロ過剰負の二項分布 AIC: 907.8795

133

R code ゼロ過剰Poisson, NB

```
## Zero-inflated Poisson
install.packages("pscl")
library(pscl)

result.zi <- zeroinfl(infections~age + gender + location + swimmer, data=Dataset)
summary(result.zi)

## Zero-inflated negative binominal
result.zinb <- zeroinfl(infections~age + gender + location + swimmer,
data=Dataset,dist="negbin")
summary(result.zinb)

## AIC
c(AIC.model1=AIC(GLM.1), AIC.model2=AIC(result.nb), AIC.model3=AIC(result.zi),
AIC.model4=AIC(result.zinb))
```

134

課題3-2

- 1987 年と 1988 年に実施された米国医療費調査 (NMES) データ (data=nmes)。
 - メディケア の対象となっている 66 歳以上の個人データ
 - 4,406 名 19変数
- 下記変数を使用し、医療機関受診回数との関連を検討する
 - 従属変数 Visits:医療機関訪問回数
 - 独立変数
 - Hospital 入院期間
 - Health 主観的健康"poor", "average" (reference category), "excellent"
 - Chronic 慢性疾患の有無
 - Adl ADL "limited" or not "normal"
 - Age Age in years (divided by 10) 10歳階級
 - Gender (M, F)
 - Married 結婚しているか(Y,N)
 - School 教育年数
 - Income 世帯収入(USD 10,000)
 - Insurance private insuranceに加入しているか(Y,N)

135

第3日目

1. Logistic 脳動脈瘤 例題

2. Poisson NEMS1988 例題

3. 調査票:各自の調査票の作成

- 調査票を作成
- リンク先を入力
- コード表の作成

} いずれか提出(追加課題)

136

136