

保健統計学実習

第3日目

第7回 分散分析
第8回 重回帰分析
第9回 ロジスティック回帰、検査データの解析

滋賀医科大学NCD疫学研究センター
医療統計学部門

原田 亜紀子
(aharada@belle.shiga-med.ac.jp)

1

講義・演習スケジュール

回	日	内容
1	8/27(木)	1 R, EZR の使い方, データセットの読み込み, 頻度集計 2 記述統計, 相関
2	8/28(金)	3 エクセルの基礎, Python 設定, 基本コード 4 仮説検定の基礎, カイ2乗検定, マクネマー検定 5 t 検定, Wilcoxon 検定, サンプルサイズ設計 6 調査データ解析
3	9/1(火)	7 分散分析 8 重回帰分析 9 ロジスティック回帰, Poisson 回帰
4	9/2(水)	10 生存時間解析 11 クラスター分析 12 AI Deep learning 演習(1) * Python Collaboratory 使用
5	9/4(金)	13 AI Deep learning 演習(2) * Python Collaboratory 使用 14 AI Deep learning 演習(3) * Python Collaboratory 使用 15 解析実習まとめ(復習・課題の時間)

2

第7回 分散分析

3

解析手法の選択 データの型と解析の目的

	データの型		
	2値	連続	生存時間
解析の目的	集計・記述		
	1変量 頻度集計	ヒストグラム 要約統計量	Kaplan-Meier法
	2変量 分割表	散布図、相関係数	
	群比較	χ^2 検定 Fisher 直接確率検定	t検定 Wilcoxon検定 ログランク検定
	多群比較	コクランマンテル 検定	分散分析 ログランク検定
モデルあてはめ	ロジスティック回帰	重回帰分析	Cox回帰

4

分散分析


A病院, B病院, C病院でのある手術の手術時間について病院間の時間について差があるかを比較したい。

A	B	C
500	400	350
420	420	400
650	460	320
550	540	280
480	390	490



分散分析

赤と青の比較




分散分析表			
	偏差平方和	自由度	分散
全体変動	全体偏差平方和 S _t	n-1 f _t	全体分散 V _t = S _t / f _t
群間変動	群間偏差平方和 S _a	群数-1 f _a	群間分散 V _a = S _a / f _a
群内変動	群内偏差平方和 S _e	n-群数 f _e	群内分散 V _e = S _e / f _e

群内変動（誤差変動）より、施設間の分散が大きければ施設による差がある（右の方が群内変動が小さい）
分散比（群間変動と群内変動の比）をF検定で評価

分散分析

要因	自由度	平方和	平均平方	F 値	Pr > F
Model	2	57773.3333	28886.6667	4.89	0.0281
Error	12	70960.0000	5913.3333		
Corrected Total	14	128733.3333			



分散分析

$$\sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x})^2 = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2 + \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2$$

データと総平均の差の2乗和 (Sum of Square)

総平均と各水準の差の2乗和

データと各水準の差の2乗和

総変動
SS_T

水準間変動
SS_A

水準内変動 (誤差変動)
SS_E

$$\frac{SS_A}{SS_E}$$

水準間変動が、各水準内の変動より大きい小さいかを検定する

(参考)証明

$$x_{ij} - \bar{x} = (\bar{x}_i - \bar{x}) + (x_{ij} - \bar{x}_i) \cdots \text{(式 1)}$$

式 1 を2乗して*i, j*についての和をとる

$$\sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x})^2 = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2 + \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2 + \sum_{i=1}^k \sum_{j=1}^n 2 \cdot n_i (\bar{x}_i - \bar{x})(x_{ij} - \bar{x}_i) \cdots \text{(式 2)}$$

式 2 で $\sum_{i=1}^k (\bar{x}_i - \bar{x}) = 0, \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i) = 0$ である

$$\sum_{i=1}^k \sum_{j=1}^n 2 \cdot n_i (\bar{x}_i - \bar{x})(x_{ij} - \bar{x}_i) = 2 \sum_{i=1}^k \sum_{j=1}^n n_i \bar{x}_i (x_{ij} - \bar{x}_i) - 2 \sum_{i=1}^k \sum_{j=1}^n n_i \bar{x} (x_{ij} - \bar{x}_i) = 0$$

$$\sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x})^2 = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2 + \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2$$

分散分析 病院データ

データセット
hospital.csv
hospital.sav

1	500	A
2	420	A
3	650	A
4	550	A
5	480	A
6	400	B
7	420	B
8	460	B
9	540	B
10	390	B
11	350	C
12	400	C
13	320	C
14	280	C
15	490	C

統計分析

3群以上の平均値の比較 (ANOVA)

```
> group.sds <- c(group.sds, bar.sds[3])
> group.p <- c(group.p, "")
> summary(AnovaModel.0)
Df Sum Sq Mean Sq F value Pr(>F)
factor(shopsetsu) 2 57773 28887 4.885 0.0281 *
Residuals 12 70860 5913
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary-anova <- NULL
```

分散分析
検定の多重性の問題

t検定での繰り返し検定-----($\times$)
A-B, B-C, A-Cで3回検定を行うとA-Cで有意差あり($p=0.02$)
→これでよいのか?

検定は何回も繰り返すと本来は有意差がないのに、確率的にどこかに有意差が出てしまう。
(例)
検定回数が2回 $1 - (1 - 0.05)^2 = 0.0975$
2回とも有意差なしの確率

検定回数が3回 $1 - (1 - 0.05)^3 = 0.143$
→14%の確率で、本当に差がなくても少なくともどれか1つで
有意差ありとなる

検定の多重性の問題

A	B	C
500	400	350
420	420	400
650	460	320
550	540	280
480	390	490

上記検定でA-Cは有意

多重比較の方法
○Bonferroni
あらかじめ設定した有意水準を、比較する回数で割った値を「個々の比較の」有意水準とする(例えば $\alpha=0.05/3=0.017$)
○Dunnnett
基準のグループとその他のグループを比較
○Tukey
すべての組み合わせで比較をしたい

多重比較

モデル名を入力: AnovaModel.10
複数の選択はCtrlキーを押しながらクリック。
目的変数(1つ選択)
ikan
比較する群(1つ以上選択)
ikan
shisetsu
グラフ
○棒
○折れ線
○箱ひげ
☒ はい(一元配置分散分析)
☐ いいえ(Welch検定)
! Welch検定の場合は多重比較やモデルの保存は行われません。
! 2群ずつの比較(post-hoc検定)は比較する群別因子が1つの場合のみ実施される。
☐ 2群ずつの比較(Bonferroniの多重比較)
☐ 2群ずつの比較(Holmの多重比較)
☐ 2群ずつの比較(Tukeyの多重比較)
☒ 2群ずつの比較(Dunnnettの多重比較)
! アルファベット順で一番若い群が対照群となる。変更したい場合は因子水準を再順序化する。
☐ モデル解算時に解析結果をアクティブモデルとして残す
! 一部のサンプルだけを解析対象にする場合の条件式。例: age>50 & Sex==0 & age<50 | Sex==1
<全ての有効なケース>

ヘルプ リセット OK キャンセル 適用

多重比較の方法
①Tukey
すべての組み合わせで比較をしたい
②Bonferroni
あらかじめ設定した有意水準を、比較する回数で割った値を「個々の比較の」有意水準とする(例えば $\alpha=0.05/3=0.017$)
③Dunnnett
基準のグループとその他のグループを比較

```
summary.anova
  平均 標準偏差  P値
shisetsu=A 520 86.31338 0.0281
shisetsu=B 442 60.99180
shisetsu=C 368 81.05554

> TukeyHSD(AnovaModel.8, "factor(shisetsu)")
  Tukey multiple comparisons of means
    95% family-wise confidence level


fit: aov(formula = jikan ~ factor(shisetsu), data = dat)

factor(shisetsu)
  diff      lwr      upr    p adj
3-A -78 -207.7507  51.75073 0.2815823
3-A -152 -281.7507 -22.24827 0.0221445
3-B -74 -203.7507  55.75073 0.3158631

> summary(AnovaModel.8)
              Df Sum Sq Mean Sq F value Pr(>F)
factor(shisetsu) 2  57773   28887   4.885 0.0281 *
Residuals      12  70960    5913

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

施設別の平均時間



多重比較
Tukey

施設で差があるが、どの施設とどの施設で差があるかはこの検定からは明らかでない

群間での差を知りたい

ボンフェローニ

```
> pairwise.t.test(Dataset$jikan, Dataset$shisetsu, var.equal=TRUE, p.adj="bonferroni")


Pairwise comparisons using t tests with pooled SD

data: Dataset$jikan and Dataset$shisetsu

      A      B
B 0.404 -
C 0.026 0.462

P value adjustment method: bonferroni
```

ノンパラメトリック Kruskal-Wallis検定



ノンパラメトリック 多重比較

• 3群以上の比較およびその多重比較はどのように行うか？

	パラメトリック	ノンパラメトリック	略説
2群	Student の t 検定	Wilcoxon 検定	多重比較調整無しでの比較
	Tukey の HSD 検定	Steel-Dwass 検定	ペアワイズな比較
	Dunnett の多重比較検定	Steel 検定	コントロール群との比較
	-	Dunn 検定 (全てのペア)	Bonferroni 型の多重比較
	-	Dunn 検定 (コントロール群との比較)	Bonferroni 型の多重比較
3群	Hsu の MCB	-	任意の基準値 (最適値) との比較
	分散分析 F検定	Kruskal-Wallis検定	

Kruskal-Wallis

```
Kruskal-Wallis rank sum test
data: jikan by factor(shisetsu)
Kruskal-Wallis chi-squared = 6.5183, df = 2, p-value = 0.03842

> cat(gettextRcmdr("Kruskal-Wallis test"), " ", gettextRcmdr("p.va
+ , sep=" "))
3群以上の間の比較(Kruskal-Wallis検定) P値 = 0.0384

> Steel.Dwass(hosp$jikan, hosp$shisetsu)
      t      p
A:B 1.676233 0.21433221
A:C 2.193378 0.07228892
B:C 1.466704 0.30703807

> Steel(hosp$jikan, hosp$shisetsu)
      t rho  p.value
A:B 1.676233 0.5 0.16504251
A:C 2.193378 0.5 0.05237534
```

分散分析いろいろ

さきほどの例は、分散分析の中でシンプルな例でした。。。。

<分散分析を行う際の視点>

- 1) 研究の目的(どの群を比較したいと考えているか)
- 2) 時系列的な変化をみているか
- 3) 水準が1つか、2つか



1)–3)を確認して、解析方法を検討する

シンプルな例ばかりではありません

データの型: ①一元配置分散分析

One-way Analysis of variance (ANOVA)

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B,C)のいずれかが投与された。

Data structure (P: 被験者)

薬剤A: P P P P P P P P P P P P

薬剤B: P P P P P P P P P P P P

薬剤C: P P P P P P P P P P P P

A・B・Cの比較を行いたい
時点ごとの測定はない

データの型: ②繰り返し測定

Repeated measures ANOVA

Clinical Question

N名の神経障害性疼痛患者に対して、新薬の除痛薬を投与し、投与直前、30分後、60分後、90分後のVASの変化を調査した。

Data structure

	直前	30分後	60分後	90分後
Patient.1				
Patient.2				
Patient.3				
⋮				
Patient.N				

時点ごとの評価
薬は1種類(比較はない)

データの型： ③反復測定

Repeated measures ANOVA

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B)のいずれかが投与され、投与直前、30分後、60分後、90分後のVASの変化を調査した。

対象

R

薬剤A

被験者

直前 30 60 90

n人の被験者に対して測定

薬剤B

被験者

直前 30 60 90

n人の被験者に対して測定

直前 30分後 60分後 90分後

薬剤A

Patient.1

Patient.2

...

Patient.N

薬剤B

Patient.1

Patient.2

...

Patient.N

時点ごとの評価
薬も比較

21

データの型： ④二元配置分散分析

Two-way ANOVA

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B,C)のいずれかが投与された。この試験では、年齢(65歳以上、65歳未満)を割付調整因子とした。

対象

R

薬剤A

65歳未満 65歳以上

薬剤B

65歳未満 65歳以上

薬剤C

65歳未満 65歳以上

Data structure

P : 被験者

薬剤A

65歳未満 65歳以上

P P P P P P P P P P P P

薬剤B

65歳未満 65歳以上

P P P P P P P P P P P P

薬剤C

65歳未満 65歳以上

P P P P P P P P P P P P

薬の比較も
対象者属性(年齢)の比較も

22

データセットの形式

• 対応あり(反復測定されている)かどうか
データセットの配列

分散分析・反復測定(対応あり)データ

dog	COL1	COL2	COL3	COL4	COL5
1	900	792	792	768	873
2	1510	1189	1109	1028	1277
3	1540	1082	1049	1148	1310
4	1082	885	902	885	1311
5	1180	885	754	754	951
6	1311	984	1000	984	1279

分散分析・対応なし・混合モデルデータ

time	inu	y
1	1	900
2	1	792
3	1	792
4	1	768
5	1	873
1	2	1510
2	2	1189
3	2	1109
4	2	1028
5	2	1277
1	3	1540
2	3	1082
3	3	1049
4	3	1148
5	3	1310
1	4	1082
2	4	885
3	4	902
4	4	885
5	4	1311
1	5	1180
2	5	885
3	5	754
4	5	754
5	5	951
1	6	1311
2	6	984
3	6	1000
4	6	984
5	6	1279

23

データの型： ①一元配置分散分析

One-way Analysis of variance (ANOVA)

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B,C)のいずれかが投与された。

対象

R

薬剤A

薬剤B

薬剤C

Data structure

P : 被験者

薬剤A

P P P P P P P P P P P P

薬剤B

P P P P P P P P P P P P

薬剤C

P P P P P P P P P P P P

A・B・Cの比較を行いたい
時点ごとの測定はない(対応はない)

24

例題1

データの型: ①一元配置分散分析
毒性実験: ラットへの投与

データセット
ANOVA.wide.sav
ANOVA.long.sav

• 毒性試験

ANOVA.wide.sav → 縦長データセットで解析する必要あり。変換してみる



Group	dose	Hb(mg/ml)
A1	0	153 153 152 156 158 141 151 150 148 157
A2	5	158 152 152 152 151 151 157 147 155 146
A3	10	153 146 138 152 140 146 156 142 147 153
A4	20	137 139 141 141 143 133 147 144 151 156
A5	40	142 126 134 143 139 134 141 139 124 136


ラット



25

変換方法


[アクティブデータセット]-[変数の操作]-[複数の変数を縦に積み重ねた...]




データセット名: anova.long
積み重ねた変数: Hb
識別変数: obs

26

ANOVA.wide.sav








27

縦データを使用して解析

[統計解析]-[連続変数の解析]-[3群以上の間の平均値の比較]



Simultaneous Tests for General Linear Hypotheses
Multiple Comparisons of Means: Dunnett Contrasts
Fit: aov(formula = weight ~ group.factor, data = Dataset)

28

[分析]-[平均の比較]-[一元配置分散分析]



29

```
> summary(AnovaModel.1D)
```

	Df	Sum Sq	Mean Sq	F	value	Pr(>F)
factor(dose)	4	1856	463.9	14.13	0.000000151	***
Residuals	45	1477	32.8			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$463.9/32.82 = 14.13$

$$\sum \sum (Y_{ij} - \bar{Y})^2 = \sum n_i (\bar{Y}_i - \bar{Y})^2 + \sum \sum (Y_{ij} - \bar{Y}_i)^2$$


平方和	sum of squares	全体	モントリbetween	誤差within
自由度DF	$\Sigma n_i - 1$		k-1	n-k
degrees of freedom				
平均平方	mean squares	= SS/DF		
F		= model MS/error MS		

```
> summary.anova
```

	平均	標準偏差	P値
dose=A1	151.8	4.954235	0.00000151
dose=A2	152.1	3.842742	
dose=A3	147.3	6.092801	
dose=A4	143.2	6.746192	
dose=A5	135.8	6.494442	

30

A1基準



31

1. 研究デザイン・データの型
2. データセット配置
3. 分析法の選択
 - (SPSSのコマンドの場合)
 - ・ 平均の比較: 一元配置分散分析
 - ・ 線型回帰: 一変量
反復測定
多変量
 - ・ 混合モデル: 線型
4. 等分散性の確認
5. 分散分析結果(F値確認)
 - ・ 交互作用含む場合⇒交互作用が有意な場合は 下位検定へ
6. 多重比較
7. 対比

32

データの型： ②一元配置分散分析(反復測定)

Repeated measures ANOVA

Clinical Question

N名の神経障害性疼痛患者に対して、新薬の除痛薬を投与し、投与直前、30分後、60分後、90分後のVASの変化を調査した。

対象 → 新薬投与

直前 30 60 90

被験者 → n人の被験者に対して測定

Data structure

	直前	30分後	60分後	90分後
Patient.1				
Patient.2				
Patient.3				
...				
Patient.N				

時点ごとの評価
薬は1種類(比較はない)

犬の血流測定 反復測定データ

データセット dog.sav

仮説:
血流は治療前(時点1)から減少し、治療後(時点5)には元に戻るか?

	1	2	3	4	5
Dog	900	792	792	768	873
	1510	1189	1109	1028	1277
	1540	1082	1049	1148	1310
	1082	885	902	885	1311
	1180	885	754	754	951
	1311	984	1000	984	1279

データセットの形式

データセット dog.sav

• 対応あり(反復測定されている)かどうか
データセットの配列

分散分析・反復測定(対応あり)データ

dog	COL1	COL2	COL3	COL4	COL5
1	900	792	792	768	873
2	1510	1189	1109	1028	1277
3	1540	1082	1049	1148	1310
4	1082	885	902	885	1311
5	1180	885	754	754	951
6	1311	984	1000	984	1279

分散分析・対応なしデータ
混合モデル

time	inu	y
1	1	900
2	1	792
3	1	792
4	1	768
5	1	873
1	2	1510
2	2	1189
3	2	1109
4	2	1028
5	2	1277
1	3	1540
2	3	1082
3	3	1049
4	3	1148
5	3	1310
1	4	1082
2	4	885
3	4	902
4	4	885
5	4	1311
1	5	1180
2	5	885
3	5	754
4	5	754
5	5	951
1	6	1311
2	6	984
3	6	1000
4	6	984
5	6	1279

ヨコデータを使用して解析

[統計解析]-[連続変数の解析]-[対応のある2群以上の平均値の比較]

群は選択しない

“Time”として、t1-t5データを対応させる

反復測定結果(SPSSでの出力)

被験者内効果の検定

ソース	タイプ III 平方和	自由度	平均平方	F 値	有意確率
血圧	539884.133	4	134971.033	18.004	<.001
Greenhouse-Geisser	539884.133	2.190	246422.852	18.004	<.001
Huynh-Feldt	539884.133	3.965	136150.610	18.004	<.001
下限	539884.133	1.000	539884.133	18.004	.008

②

Mauchly の球面性検定

測定変数: MEASURE_1	Mauchly の W	近似カイニム	自由度	有意確率
血圧	.059	9.679	9	.432

① モークリーの球面性検定

球面性検定が棄却されない→球面性の仮定が成り立つと判断
“②球面性の仮定”の数値をみる

球面性検定が棄却される→“②’ Greenhouse-Geisser ε Huynh-Feldt (ホイン・フェルト) ε” で判断

EZR出力

Univariate Type III Repeated-Measures ANOVA Assuming Sphericity

	Sum Sq	num Df	Error SS	den Df	F value	Pr(>F)
(Intercept)	33104407	1	687833	5240.643	0.000020218	***
Time	539884	4	149932	20	18.004	0.000002077 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

① モークリーの球面性検定

Mauchly Tests for Sphericity

Test statistic	p-value
Time	0.058838 0.43236

球面性検定が棄却されない
→球面性の仮定が成り立つと判断
“球面性の仮定”の数値をみる

Greenhouse-Geisser and Huynh-Feldt Corrections for Departure from Sphericity

	GG eps	Pr(>F[GG])
Time	0.54757	0.0002865 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

球面性検定が棄却されたなら こっちを
→ “②’ Greenhouse-Geisser ε Huynh-Feldt ε” で判断

HF eps Pr(>F[HF])

	HF eps	Pr(>F[HF])
Time	0.9913362	0.00000228006

(補足)球面性？

- 球面性の仮定:分散の等質性の仮定に相当するもので、複合対称性という仮定の一部
 - 複合対称性(compound symmetry)
 - 条件間で分散が等しいこと、条件群の任意の対から作られる共分散が等しいことの両方が成り立つ状態
 - ただし、複合対称性はかなり厳しい基準で、実際のデータでは満たされないことが多い
 - また、この仮定は分散分析を適切に行うための十分条件だが、必要条件でない。
- 球面性の仮定(sphericity assumption;球形仮定, 球状性仮定)
 - 少しゆるい基準になっており、すべての条件間の差の分散が等しいことを仮定
 - 分散分析を適切に行うための必要十分条件である
- 球面？
 - データが3次元に分布するとして、x軸の分散がy軸、z軸よりも大きい場合を考えてみると、この楕円はx軸の方向に伸びたラグビーボールのような形。
 - すべての主軸の長さが等しくなれば、この楕円は球の形に近づく
 - 分布がどの方向に対しても等しければ、そのプロットは球に近づく

反復測定

Plot of Means

Time	Mean	Lower Bound	Upper Bound
t1	1250	1000	1500
t2	950	800	1100
t3	900	750	1050
t4	900	750	1050
t5	1150	950	1350

分散分析 一般的な手順


- 研究デザイン・データの型
- データセット配置
- 分析法の選択
 - (SPSSのコマンドの場合)
 - 平均の比較: 一元配置分散分析
 - 線型回帰: 一変量
 - 反復測定
 - 多変量
 - 混合モデル: 線型
 - 等分散性の確認** → 正規性、等分散性が成り立たないとき
 - 分散分析結果(F値確認)
 - 交互作用含む場合 → 交互作用が有意な場合は 下位検定へ
 - 多重比較
 - 対比

ノンパラメトリック検定
(対応あり) フリードマン検定

41

フリードマン検定

[統計解析]-[ノンパラメトリック検定]-[対応のある3群以上の間の比較]



```
res <- Anova(AnovaModel.2, idata=time, idesign="Time", type="III")
summary(res, multivariate=FALSE)
pairwise.pairw.test(with(TempDF, cbind(t1, t2, t3, t4, t5)), group=NULL, "Dataset", p.adjust.met
```

出力

```
GG eps Pr>F[GG]
Time 0.54757 0.0002865 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


42

データの型: ③反復測定(二元配置)


データセット bp.sav

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A,B)のいずれかが投与され、投与直前、30分後、60分後、90分後のVASの変化を調査した。



Repeated measures two-way ANOVA




時点ごとの評価
薬の比較もあり

43

反復測定2群の比較

データセット bp.sav



異なる薬剤(D1,D2)があり、投与後の時点ごと(T0, T1, T3)の血圧値を測定

dose	obs	pre	T1	T3
D1	R1	119	113	114
D1	R2	110	115	112
D1	R3	123	126	111
D1	R4	130	127	100
D1	R5	121	115	124
D1	R6	135	125	115
D2	S1	125	109	113
D2	S2	108	98	104
D2	S3	133	118	117
D2	S4	125	114	110
D2	S5	113	107	106
D2	S6	126	118	110

前値に個人差があり、D2群(赤・破線)が短期的な効果は大きい、時点3での両群の差は小さいデータ

44

データの配置
[統計解析] - [連続変数の解析]
- [対応のある2群以上の間の平均値の比較(反復(経時)効果分散分析)]

データセット
bp.sav

統計解析

連続変数の解析

対応のある2群以上の間の平均値の比較(反復(経時)効果分散分析)

連続変数の解析

対応のある2群以上の間の平均値の比較(反復(経時)効果分散分析)

出力

```
Test statistic p-value
Time 0.56172 0.074618
Factor1:dose:Time 0.56172 0.074618

Greenhouse-Geisser and Huynh-Feldt Corrections
for Departure from Sphericity
GG eps Pr(>F[GG])
Time 0.69528 0.003562 **
Factor1:dose:Time 0.69528 0.233152
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

解析手順

“Time”として、t0, t1, t3データを対応させる

Plot of Means

結果

Univariate Type III Repeated-Measures ANOVA Assuming Sphericity

Sum Sq num Df Error SS den Df F value Pr(>F)

(Intercept) 487437 1 1009.39 10 4829.0277 9.283e-15 ***

Factor1:dose 182 1 1009.39 10 1.8055 0.2087370

Time 742 2 717.44 20 10.3430 0.0008238 ***

Factor1:dose:Time 115 2 717.44 20 1.6052 0.2256882

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Test statistic p-value

Time 0.56172 0.074618

Factor1:dose:Time 0.56172 0.074618

Greenhouse-Geisser and Huynh-Feldt Corrections for Departure from Sphericity

GG eps Pr(>F[GG])

Time 0.69528 0.003562 **

Factor1:dose:Time 0.69528 0.233152

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

HF eps Pr(>F[HF])

Time 0.721787 0.002458004

Factor1:dose:Time 0.721787 0.231725468

球面性検定が棄却されない→球面性の仮定が成り立つと判断

“球面性の仮定”の数値をみる

モークリーの球面性検定

球面性検定が棄却される→“②” Greenhouse-Geisser ε Huynh-Feldt ε”で判断

47

交互作用とは？

主効果: 血圧の作用

交互作用: 薬剤の用量により血圧の反応が異なる

例) チキンの違いが味付けか？ (チキンの評点)

	クリスピー	普通
辛口	79.666...	72.666...
普通	71.00	74.333...

辛口

普通

クリスピー

普通


クリスピーチキンのときは辛口がよく、普通のチキンのときは普通味のほうがいい(交互作用)

48

12

交互作用が有意の場合は 下位検定へ(SPSS)

今回は交互作用は有意でないので、下位検定は行わないが。。。[EM平均]-[単純主効果の比較]



49

49

単純主効果(SPSS)

測定変数名: MEASURE_1

ペアごとの比較

time	(I) dose	(J) dose	平均値の差 (I-J)	標準誤差	有意確率 ^a	95% 平均差信頼区間 ^b
1	D1	D2	1.333	5.207	.803	-10.268 12.935
	D2	D1	-1.333	5.207	.803	-12.935 10.268
2	D1	D2	9.500 [*]	4.099	.043	.366 18.634
	D2	D1	-9.500 [*]	4.099	.043	-18.634 -.366
3	D1	D2	2.667	3.694	.487	-5.564 10.897
	D2	D1	-2.667	3.694	.487	-10.897 5.564

推定周辺平均に基づいた。
* 平均値の差は .05 水準で有意です。
b. 多重比較の調整: Bonferroni.

測定変数名: MEASURE_1

ペアごとの比較

dose	(I) time	(J) time	平均値の差 (I-J)	標準誤差	有意確率 ^a	95% 平均差信頼区間 ^b
D1	1	2	2.833	2.012	.568	-2.941 8.607
	3	1	-2.833	2.012	.568	-8.607 2.941
2	1	3	-7.500	3.956	.262	-15.413 0.413
	3	1	7.500	3.956	.262	0.413 15.413
D2	1	2	11.000 [*]	2.012	<.001	5.226 16.774
	3	1	-11.000 [*]	2.012	<.001	-16.774 -5.226
3	1	3	.667	3.956	1.000	-10.686 12.020
	2	3	-11.667 [*]	4.022	.047	-23.211 9.877

推定周辺平均に基づいた。
* 平均値の差は .05 水準で有意です。
b. 多重比較の調整: Bonferroni.

Time2で群間に差がある。
D2において、T1とT2、T1とT3に差がある

50

50

多重比較

Pairwise comparisons using Paired t-test

```
data: Dataset
t0 t1
t1 0.0020 -
t3 0.0094 0.5251
P value adjustment method: bonferroni
```

Bonferroni

Pairwise comparisons using Paired t-test

```
data: Dataset
t0 t1
t1 0.0020 -
t3 0.0062 0.1750
P value adjustment method: holm
```

Holm

51

51

データの型: ④二元配置分散分析

Clinical Question

神経障害性疼痛患者がランダムに割り付けられ、3種類の除痛薬(A, B, C)のいずれかが投与された。この試験では、年齢(65歳以上、65歳未満)を割付調整因子とした。

Data structure

	65歳未満	65歳以上
薬剤A	PPPPPP	PPPPPP
薬剤B	PPPPPP	PPPPPP
薬剤C	PPPPPP	PPPPPP

薬の比較
対象者属性(年齢)の比較

52

52

二元配置分散分析

データセット
2way.sav

スコア

A	M	8.18	7.24	7.00	7.00	8.00													
	F	7.69	9.69	8.89	6.94	2.13	7.26	5.87	7.20	6.81	6.67	6.98	7.07	5.00					
B	M	12.90	16.60	9.81	7.84	9.42	10.67	10.83											
	F	8.35	3.84	4.62	9.29	6.43													
C	M	12.40	14.00	11.60	13.90	11.20	13.21												
	F	12.20	9.41	2.40	9.78	7.00													

薬剤

- 41名(男性18名, 女性23名)
- 3種類の鎮痛薬(A,B,C)を投与し、痛みのスコアを用い評価
- 薬剤間での差を評価したい
- 男性、女性とで効果の差があるかも比較したい
- 薬剤により、性別による効果の違いがあるかも比較したい

53

二元配置分散分析

データセット
2way.sav

54

二元配置分散分析
[統計解析]-[連続変数の解析]-[複数の因子での平均値の比較]

55

二元配置

56

二元配置分散分析

```
> tapply(TempDF$score, list(drug=TempDF$drug, sex=Temp
sex
drug      F      M
A 6.784615  7.48400
B 6.506000 11.15286
C 8.158000 12.71833

> tapply(TempDF$score, list(drug=TempDF$drug, sex=Temp
sex
drug      F      M
A 1.824293  0.5654025
B 2.935685  2.8531370
C 3.709167  1.1779714

> Anova(AnovaModel.22, type="III")
Anova Table (Type III tests)

Response: score
              Sum Sq Df F value    Pr(>F)
(Intercept)  2826.55  1 569.0539 < 2.2e-16 ***
Factor1.drug    68.44  2   6.8892  0.003001 **
Factor2.sex     99.49  1  20.0295  0.00007734 ***
Factor1.drug:Factor2.sex 33.60  2   3.3825  0.045392 *
Residuals     173.85 35
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

57

二元配置分散分析(EZR出力)

薬剤、性別、薬剤・性別の交互作用が有意
薬剤Aの痛みを予防する効果が大きく、B,Cと比較し有意
薬剤 A に比べて薬剤 B,薬剤 C における性差が顕著であり、男性の痛みの程度が高い

58

二元配置分散分析(SPSS出力)

ソース	タイプ III 平方和	自由度	平均平方	F 値	有意確率
修正モデル	219.342 ^a	5	43.868	8.832	<.001
切片	2826.550	1	2826.550	569.054	<.001
Drug	68.439	2	34.220	6.889	.003
Sex	99.489	1	99.489	20.029	<.001
Drug * Sex	33.602	2	16.801	3.382	.045
誤差	173.849	35	4.967		
総和	3437.948	41			
修正総和	393.191	40			

a. R2 値 = .558 (調整済み R2 値 = .495)

Dunnnett の t (2 サイドの*)		標準誤差	有意確率	95% 信頼区間		
				下側	上側	
B	A	2.2378 ^a	.83059	.021	.3134	4.1621
C	A	3.6666 ^a	.85294	<.001	1.8904	5.6427

観測平均値に基づいています。
観差値は平均平方 (誤差) = 4.967 です。
* 平均値の差は 0.05 水準で有意です。
a. Dunnnett の t 検定は対照として 1 つのグループを扱い、それに対する他のすべてのグループと比較します。

薬剤、性別、薬剤・性別の交互作用が有意
薬剤Aの痛みを予防する効果が大きく、B,Cと比較し有意
薬剤 A に比べて薬剤 B,薬剤 C における性差が顕著であり、男性の痛みの程度が高い

59

交互作用が有意⇒下位検定

[EM平均]-[単純主効果の比較]

60

下位検定

ペアごとの比較

従属変数: score	sex	(i) drug	(j) drug	平均値の差 (i-j)	標準誤差	有意確率 ^a	95% 平均差信頼区間 ^b
F	A	B		.279	1.173	1.000	-2.670 3.228
		C		-1.373	1.173	.749	-4.322 1.576
		B	A		-.279	1.173	1.000
	B	C		-1.652	1.410	.747	-5.196 1.892
		A	B		1.373	1.173	.749
	C	B	A		1.652	1.410	.747
M		A	B		-3.669 ^a	1.305	.024
	C		-5.234 ^a	1.350	.001	-8.628 -1.841	
	B	A		3.669	1.305	.024	1.387 6.950
B	A	C		-1.565	1.240	.645	-4.683 1.552
	C	A		5.234 ^a	1.350	.001	1.841 8.628
	B	C		1.565	1.240	.645	-1.552 4.683

ペアごとの比較

従属変数: score	drug	(i) sex	(j) sex	平均値の差 (i-j)	標準誤差	有意確率 ^a	95% 平均差信頼区間 ^b
A	F	M		-.699	1.173	.555	-3.080 1.682
		M	F		.699	1.173	.555
B	F	M		-4.647 ^a	1.305	.001	-7.296 -1.998
		M	F		4.647 ^a	1.305	.001
C	F	M		-4.560 ^a	1.350	.002	-7.300 -1.821
		M	F		4.560 ^a	1.350	.002

推定周知平均に基づいた

^a 平均値の差は 0.05 水準で有意です。

^b 多重比較の調整: Bonferroni.

課題(余力のある人むけ)

下記のデータセット(chickenwts)を用い、餌(えさ)の違いによる、鶏の成長(体重:weight)について考察する。

- 餌4群の体重について、箱ひげ図をプロットする(オス、メス別に)
- 2群ごとの体重の比較を行う(オス、メス併せて) 一元配置分散分析を行う
多重比較(TukeyのHSD検定)を行うこと
- オス・メス、餌、交互作用を考慮した二元配置分散分析を行う
適宜、交互作用プロット、最小2乗平均プロットなども示し、
鶏の成長に影響する因子を考察する

『 chickenwts 』 データ

- ・49羽の鶏を孵化直後にランダムに4群に分けて異なる餌を与える
 - ・餌(feed):
 - ・カゼイン、肉の配合餌、大豆、ヒマワリの種
 - ・オス(sex=1)・メス(sex=2)
- ・6週後の体重:weight

第8回 重回帰分析

解析の手順

線形モデルのあてはめとモデル診断

なぜ線形モデルを使うのか？

- ・ データ削減
- ・ 予測式を算出したい
- ・ パラメータ値の解釈(従属変数に対する独立変数の影響)

決定係数、残差の検討を丁寧に行う

仮定は正しいか？

- ・ $y = x + \text{誤差}$
- ・ 誤差の変動:平均は0, 分散は等しい, 独立, ほぼ正規分布

偏回帰係数の有意性を重視してモデルを作る

回帰診断

- ・ 残差の検討と影響度分析

線形回帰

- xに対するyの線形回帰
- y: 応答, 従属変数
- x: 説明変数, 独立変数

- 予測 $\hat{y} = a + bx$
- 残差 $y - \hat{y}$





Fig.1 : (General) liner model


yという結果に対して、原因と考えられるxがどのように影響しているかを検討する手法
(例) 握力 = a + b₁×(年齢)+b₂×(性別)+b₃×(体重)

回帰と最小二乗法



残差が最小となるよう、係数を推定する
 $y = b_0 + b_1x_{11} + \dots + b_px_{pn}$

実測値(y)	予測値($\hat{y}$)	誤差 e_j
y_1	$b_0 + b_1x_{11} + \dots + b_px_{p1}$	$y_1 - \hat{y}_1$
y_2	$b_0 + b_1x_{12} + \dots + b_px_{p2}$	$y_2 - \hat{y}_2$
y_n	$b_0 + b_1x_{1n} + \dots + b_px_{pn}$	$y_n - \hat{y}_n$




1. モデルのあてはまり
2. 変数選択によるモデル構築
3. モデルの解釈・評価

線形モデルフィッティング
Anscombe's quartet

データセット
Ans1.csv~Ans4.csv
Ans1.sav~Ans4.sav

- 単純な記述統計量はほぼ同じだが、分布が大きく異なり、グラフにすると大きく異なっている4つのデータセット。
- これらは、統計学者Francis Anscombeによって、データを分析する前にグラフ化することの重要性と、外れ値やその他の影響力のある観測値が統計的性質に及ぼす影響の両方を示すために、1973年に作成されたものです。




	I		II		III		IV	
	X _i	Y _i	X _i	Y _i	X _i	Y _i	X _i	Y _i
10	8.04	10	9.14	10	7.46	8	5.58	
8	6.95	8	8.14	8	6.77	8	5.76	
13	7.58	13	8.74	13	12.74	8	7.71	
9	8.81	9	8.77	9	7.11	8	8.84	
11	8.33	11	9.26	11	7.81	8	8.47	
14	9.96	14	8.10	14	8.84	8	7.04	
6	7.24	6	6.13	6	6.08	8	5.25	
4	4.26	4	3.10	4	5.39	19	12.5	
12	10.84	12	9.13	12	8.15	8	5.56	
7	4.82	7	7.26	7	6.42	8	7.91	
5	5.68	5	4.74	5	5.73	8	6.89	
AVG	9	7.50	9	7.50	9	7.50	9	7.50
VAR	11	4.127	11	4.128	11	4.123	11	4.123
CORREL	0.816		0.816		0.816		0.817	

線形モデルフィッティング
Anscombe's quartet

データセット
Ans1.csv~Ans4.csv
Ans1.sav~Ans4.sav

形状は全く異なるが、要約統計では類似している4つのデータセット




	I	II	III	IV				
X _i	Y _i	X _i	Y _i	X _i	Y _i			
10	8.04	10	9.14	10	7.46	8	6.58	
8	6.95	8	8.14	8	6.77	8	5.76	
13	7.58	13	8.74	13	12.74	8	7.71	
9	8.81	9	8.77	9	7.11	8	8.84	
11	8.33	11	9.26	11	7.81	8	8.47	
14	9.96	14	8.10	14	8.84	8	7.04	
6	7.24	6	6.13	6	6.08	8	5.25	
4	4.26	4	3.10	4	5.39	19	12.5	
12	10.84	12	9.13	12	8.15	8	5.56	
7	4.82	7	7.26	7	6.42	8	7.91	
5	5.82	5	4.74	5	5.73	8	6.89	
AVG	9	7.50	9	7.50	9	7.50		
VAR	11	4.127	11	4.128	11	4.123	11	4.123
CORREL		0.816		0.816		0.816		0.817

モデル診断をやってみよう

69


回帰分析を行う
[統計解析]-[連続変数の解析]-[線形回帰]



Model	Sum of Squares	df	Mean Square	F	Sig.	Adjusted R Square	Adjusted Total Sum of Squares
1	10.000	1	10.000	17.99	.00021	.816	9.999

70

目的(従属)変数:Y 説明(独立)変数:X



	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.0001	1.1247	2.687	0.02573 *
X	0.50001	0.1179	4.241	0.00217 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.237 on 9 degrees of freedom
Multiple R-squared: 0.6885, Adjusted R-squared: 0.6295
F-statistic: 17.99 on 1 and 9 DF, p-value: 0.00217

分散分析
F値 17.99 P値 0.00217

```
> multreg.table
回帰係数推定値 95%信頼区間下限 95%信頼区間上限 標準誤差 t統計量
(Intercept) 3.0000909 0.4557389 5.5444468 1.1247468 2.687348
X 0.5000909 0.2339701 0.7668117 0.1179055 4.241455
(Intercept) 0.025734651
X 0.002169629
```

71

R, R², 調整済みR²

重相関係数(R)

- 重回帰式から得られる予測値と実測値の相関係数
- 1に近いほどあてはまりがよい
- 変数の数が多いと1に近づく(変数の数の影響をうける)

決定係数(R²)

- 重回帰モデルの適合性を評価する指標
- 変数の数が多いと1に近づく(変数の数の影響をうける)

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

自由度調整済み重相関係数・決定係数

- 独立変数の数、nを補正した指標

$$\hat{R}^2 = 1 - \frac{n-1}{n-p-1} (1-R^2)$$

72

偏回帰係数、標準偏回帰係数

偏回帰係数

- 偏回帰係数は重回帰モデルにおける独立変数の係数である
- 他の独立変数の影響を除外した回帰係数となる

標準偏回帰係数(β)

- 平均0、分散1に標準化した単位に依存しない係数(変数間の比較が行えるようにする)
- 各独立変数が従属変数にどのくらい影響しているかを評価できる

73

標準偏回帰係数

- 標準偏回帰係数(A_i) a_i S_x:xの標準偏差, S_{Dy}:yの標準偏差

$$A_i = a_i \times \frac{SD_x}{SD_y}$$
$$= 0.50 \times (3.31 / 2.03) = 0.815$$

- 標準化したデータセットで重回帰
 - z <- scale(Ans1)
 - z <- data.frame(z)データセットZで重回帰分析を実施

回帰係数推定値

95%信頼区間下限

95%信頼区間上限

標準誤差

t統計量

P値

(Intercept)

-1.673724e-17

-0.4151695

0.4151695

0.1835281

-9.119714e-17

1.0000000000

x

8.164205e-01

0.3809871

1.2518540

0.1924859

4.241455e+00

0.002169629

74

data=ans1

モデルの要約^b

モデル	R	R ² 調整済み R ² 調整済み	推定値の標準誤差	Durbin-Watson
1	0.816 ^a	0.667	0.629	1.23660

分散分析^a

モデル	平方和	自由度	平均平方	F 値	有意確率	
1	回帰	27.510	1	27.510	17.990	0.002 ^b
	残差	13.763	9	1.529		
	合計	41.273	10			

係数^a

モデル	非標準化係数 B	標準化係数 ベータ	t 値	有意確率	B の 95.0% 信頼区間 下限	上限	ゼロ次	相関 偏	部分	共線性の統計量 許容度	VIF
1	(定数)	3.000	1.125	2.667	0.028	0.456	5.544				
	x	0.500	0.118	0.816	4.241	0.002	0.233	0.767	0.816	0.816	1.000

a. 従属変数 y

b. 予測値: (定数)、x。

15

75

EZR

ID3, 9, 10あたりが予測から乖離している

lm(y ~ x)

残差

- 予測値の大小によって残差の分布に違いがないかをみる
- 0を中心に上下に均等に分布しているか確認する

Q-Qプロット

- 残差が正規分布であれば直線になる

RSTUDENT

- 残差をその標準偏差推定値で割ったもの。
- 値が±3を超えている場合は異常値である。

LEVERAGE

- 説明変数空間における外れ値

Cook's D

- 問題のオペレーションを除外したときのリグレッションの変化
- 4/nを超える場合は注意

Cook' Dでは、ID3, 9の影響度が大きい

76

19

参考: 影響度・残差関連の指標

MODEL Option or Statistic	Formula	
PRED ($\hat{Y}_i$)	$X_i b$	予測値
RES (r_i)	$Y_i - \hat{Y}_i$	残差
H (h_i)	$x_i (X'X)^{-1} x_i'$	デコ比: 説明変数空間での外れ度、何個の 回帰係数を決定しているか<1
STDP	$\sqrt{h_i \sigma^2}$	
STDI	$\sqrt{(1+h_i) \sigma^2}$	
STDR	$\sqrt{(1-h_i) \sigma^2}$	
LCL	$\hat{Y}_i - t_{\alpha/2} \text{STDI}$	
LCLM	$\hat{Y}_i - t_{\alpha/2} \text{STDP}$	
UCL	$\hat{Y}_i + t_{\alpha/2} \text{STDI}$	
UCLM	$\hat{Y}_i + t_{\alpha/2} \text{STDP}$	
STUDENT	$\frac{r_i}{\text{STDR}_i}$	基準化した残差
RSTUDENT	$\frac{\text{STDR}_i}{\sigma_{i 0} \sqrt{1-h_i}}$	基準化した残差 (分散を当該obsを除いて計算)
COOKD	$\frac{1}{p} \frac{\text{STUDENT}^2 \text{STDR}^2}{\text{STDR}^2}$	Cook's D (当該obsを除いたときの あてはめ結果の全体としての変化)
COVRATIO	$\frac{\det((\hat{\sigma}_{(i)}^2 (X_{(i)} X_{(i)}')^{-1}))}{\det(\hat{\sigma}^2 (X'X)^{-1})}$	
DFBETIS	$\frac{(\hat{Y}_i - \hat{Y}_{(i)})}{(\hat{\sigma}_{(i)} \sqrt{h_i})}$	これを2乗しpで割り分散を置き換えたものがCook's D
DFBETAS _j	$\frac{b_j - b_{(i)j}}{\hat{\sigma}_{(i)} \sqrt{(X'X)^{-1}_{jj}}}$	当該obsを除いた時の個々の回帰係数の変化
PRESS(predr _i)	$\frac{r_i^2}{1-h_i}$	

77

Variance inflation factor (VIF)

従属変数y, 独立変数 x_1, x_2, x_3, x_4 で構築された重回帰モデルがあったとして、
 x_1 を従属変数、残りの x_2, x_3, x_4 を独立変数とした
重回帰モデルを構築し、重相関係数を求める

$$VIF = \frac{1}{(1 - R^2)}$$

(分母は"許容度"とよばれる)

VIF $\geq$ 10 となるような変数は除いた方がよい

78

data=ans2

モデルの要約^b

モデル	R	R ² 乗	調整済み R ² 乗	推定値の標準誤差	Durbin-Watson
1	.816 ^a	.666	.629	1.23721	2.188

a. 予測値: (定数), x_1
b. 従属変数 y

分散分析^a


モデル	平方和	自由度	平均平方	F 値	有意確率
1 回帰	27.500	1	27.500	17.966	.002 ^b
残差	13.776	9	1.531		
合計	41.276	10			

a. 従属変数 y
b. 予測値: (定数), x_1

係数^a

モデル	非標準化係数 B	標準誤差 標準誤差	標準化係数 ベータ	t 値	有意確率	B の 95.0% 信頼区間	
						下限	上限
1 (定数)	3.001	1.125		2.667	.026	.455	5.547
x_1	.500	.118	.816	4.239	.002	.233	.767

a. 従属変数 y



79

lm(y ~ x)


```
Call:
lm(formula = y ~ x, data = ans2)

Residuals:
    Min       1Q   Median       3Q      Max
-1.9009  -0.7809   0.1291   0.9491   1.2691


Coefficients:
(Intercept)   3.001    1.125    2.667    0.02576 *
x             0.500    0.118    4.239    0.00218 **

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 1.237 on 9 degrees of freedom
Multiple R-squared:  0.6662, Adjusted R-squared:  0.6292
F-statistic: 17.97 on 1 and 9 DF, p-value: 0.002179
```




80




81



82



83



84

ans1~ans4


- 4つの回帰について、これだけ異なるデータの集まりだが、同じような直線が引けてしまう
 - グラフを見ずに、平均、回帰係数などの数値だけみるとほぼ同じ
- 残差に系統的なパターンが残されているなら、さらにモデル化すべき

85

85

残差分析

システマティックパターンの有無を確認する。



86

86

- モデルのあてはまり
- 変数選択によるモデル構築
- モデルの解釈・評価

87

87

モデル構築の原則

まず、研究目的を確認すること！！

1)臨床予測モデルの構築

- 予測モデルの予測精度を最大化する
- 精度よく予測できるモデルを作る

2)交絡調整のための回帰モデル

- 関心のある治療効果のパラメータ推定のバイアスを最小化
- 先行研究などをもとに関連が示されている変数などを中心に構築
- DAG等で変数の関連をチェック
- 統計学的な変数選択方法は通常使用しない

88

88

変数選択

相関の高い変数をモデルに含めると係数が不安定になる(多重共線性)。

<対策>

- ① 変数の選択
 - ALL(全変数を一度に入力)
 - FORWARD(前方、増加)
 - BACKWARD(後方、減少)
 - STEPWISE(増加/減少)を使用する。
- ② 合成変数の作成
- ③ 事前情報の利用(ベイズ型)

多重共線性




図3.46 多重共線性

演習 変数選択


データセット
select.csv
select.sav

“select.csv”データは、 $y=x_1+x_2+x_3$ +誤差(x_1, x_2, x_3 は独立)というモデルで作られています。

- x_4 は x_1 と高い相関がある
- x_5 は x_2 と高い相関がある
- x_6 - x_{15} は互いに独立であり、 y とも独立である。

変数選択を適用して、どのような結果が得られるか確認してください。

x_1 - x_{15} を用いてモデルを作成する。相関の高い変数を含む場合、どのような変数が選択されるのか



最終モデル

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0003582008	0.1077994	0.003322845	9.973557e-01
x1	1.0127591938	0.1134334	8.928231348	2.982083e-14
x2	1.0043675576	0.1057964	9.493397871	1.623653e-15
x3	0.8505119339	0.1024469	8.301879590	6.496778e-13

• P値をもとに

93

重回帰分析 注意点

1. 目的の再確認

1) 予測式を算出したい
→ 決定係数や残差の検討を詳細に

2) パラメータ値の解釈(従属変数に対する独立変数の影響)
→ 偏回帰係数の有意性を重視してモデルを構築する
→ 仮説に合わせた変数の投入(強制投入)

2. 標本数と独立変数の数
独立変数1つに対し $n \geq 20 \sim 30$ 程度が目安

3. 外れ値のチェック

4. 独立変数間の相関

5. 正規分布からのズレが大きい場合は変数変換(対数変換など)

94

第9回

ロジスティック回帰

95

一般線形モデル
一般化線形モデル

Development of linear models

階層ベイズモデル

より柔軟な統計モデリング

一般化線形混合モデル

個人差や部位差などのランダム効果への対応

一般化線形モデル

正規分布以外の確率分布を扱う

一般線形モデル

Statistical Inference

MCMC

最尤法

Logistic Poisson

最小二乗法

Linear regression
Analysis of Variance

96

一般線形モデル→一般化線形モデル

GLMIは正規分布だけでなく、指数族(二項、ガンマ、ポアソンなど)の分布も扱うことができます！

確率分布は正規分布




Fig.1 :一般線形モデル

確率分布はポアソン分布




Fig.2 :一般化線形モデル(例:ポアソン)

97

GLMは以下の3つの要素で構成される

1. 確率分布の指数族

指数族(二項、ガンマ、ポアソンなど)

2. 線形予測量

$\eta = X\beta$

線形予測量(η)は独立変数の情報をモデルに取り込む量である。
 η は未知パラメータ β の線形結合(したがって「線形」)で表され、線形結合の係数は独立変数の行列 X として表される。

3. リンク関数

ある式を線形に変換する関数。

98

Link function

式を線形に変換する関数

Distribution	Support	Probability Distribution	family	frequently used link functions	Variance	Mean function
Normal	real: $(-\infty, +\infty)$					
Exponential	real: $(0, +\infty)$					
Gamma	real: $(0, +\infty)$					
Inverse Gaussian	real: $(0, +\infty)$					
Poisson	integer: $0, 1, 2, \dots$					
Bernoulli	integer: $\{0, 1\}$					
Binomial	integer: $0, 1, \dots, K$					
Categorical	K-vector of integer element in the v					
Multinomial	K-vector of integer: $\{0, K\}$					

99

回帰モデルの拡張

0-1データに対するロジスティック回帰

頻度データに対するポアソン回帰

生存時間データに対するCox回帰

一般化推定方程式(Generalized Estimating Equation)

- 反復測定データに対するGEE

個人差、階層、繰り返しを扱うことができるモデル(混合モデル)

- 線型:
- 一般化線型:
- 非線型:

100

25

101

101

102

102

103

103

104

二値変数に対する多変量解析(ロジスティック回帰)

モデル名を入力: GLM.7

変数 (ダブルクリックして式に入れる)

Age
Duration
Pain
Sex (因子)
Treatment (因子)

モデル式: + * : / %in% - + ()

目的変数 Pain ~ 説明変数 Age + Duration + Sex + Treatment

層別化因子は + strata(****)と入力する !!!
重み付け因子は + weights=****と入力する !!!
IPW補正では標準誤差のロバスト推定が必要

☐ 3レベル以上の因子についての因子全体のP値の計算(Wald検定)
☐ 主成分分析に結果結果をアクティブ変数として残す

☒ ROC曲線を表示する
☒ 基本的診断プロットを表示する
☐ 検出率-特異性曲線を表示する

☐ 傾向スコア変数を自動作成する
☐ 逆確率重みづけ(IPW)の変数を作成する
☐ 標準誤差のロバスト推定
☐ AICを用いたステップワイズの変数選択を行う。
☐ BICを用いたステップワイズの変数選択を行う。
☐ P値を用いたステップワイズの変数選択(減少法)を行う。
一部のサンプルだけを解析対象にする場合の条件式。例: age>50 & Sex==0 や age<50 | Sex==1
<全ての有効なケース>

ヘルプ リセット OK キャンセル 適用

105

Logistic regression

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	15.574390	8.581008	2.383	0.01813 *
Age	-0.262093	0.097012	-2.702	0.00690 **
Duration	0.005859	0.032992	0.178	0.85905
Sex[T.F]	1.832202	0.796206	2.301	0.02138 *
Treatment[T.B]	3.708542	1.140577	3.251	0.00115 **
Treatment[T.A]	3.181690	1.016021	3.132	0.00174 **

$\ln\left(\frac{p}{1-p}\right) = a + bX$

odds $\frac{p}{1-p} = e^{a+bX}$

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 81.503 on 59 degrees of freedom
Residual deviance: 48.736 on 54 degrees of freedom
AIC: 60.736

> odds

	オッズ比	95%信頼区間下限	95%信頼区間上限	P値
(Intercept)	5810000.000	14.200	2.37e+12	0.01810
Age	0.769	0.636	9.31e-01	0.00690
Duration	1.010	0.943	1.07e+00	0.85900
Sex[T.F]	6.250	1.310	2.97e+01	0.02140
Treatment[T.B]	40.800	4.360	3.81e+02	0.00115
Treatment[T.A]	24.100	3.290	1.76e+02	0.00174

Number of Fisher Scoring iterations: 5

$e^{3.1817} = 24.0974$
 $e^{3.7085} = 40.7942$

プラセボに対する[B]
プラセボに対する[A]

106

感度・特異度

in Negative Cases 健康群

True Negative 真陰性
True Positive 真陽性
False Positive 偽陽性
False Negative 偽陰性

Higher the threshold
Lower the threshold

in Positive Cases 疾患群

True Positive 真陽性
True Negative 真陰性
False Positive 偽陽性
False Negative 偽陰性

閾値を下げると感度が上がり、(1-特異性)が上がる

107

感度・特異度

		Disease		Predictive Value	
		⊕	⊖	⊕	⊖
Test	⊕	A True Positive (TP)	B False Positive (FP)	Positive Predictive Value (PPV) $\frac{TP}{TP + FP} = \frac{A}{A + B}$	Total Positive Results (A + B)
	⊖	C False Negative (FN)	D True Negative (TN)	Negative Predictive Value (NPV) $\frac{TN}{FN + TN} = \frac{D}{C + D}$	
Sensitivity & Specificity		Sensitivity $\frac{TP}{TP + FN} = \frac{A}{A + C}$	Specificity $\frac{TN}{FP + TN} = \frac{D}{B + D}$		
		All diseased patients (A + C)	All non-diseased patients (B + D)		

疾病を有する患者において真陽性となる割合
疾病側から
病気を有していない患者さんの真の陰性結果の割合を示しています。

108


陽性（陰性）的中度

		Disease		Predictive Value		陽性の場合、病気ありの割合
		⊕	⊖	⊕	⊖	
Test	⊕	A True Positive (TP)	B False Positive (FP)	Positive Predictive Value (PPV) $\frac{TP}{TP + FP} = \frac{A}{A + B}$	Total Positive Results (A + B)	検査側から
	⊖	C False Negative (FN)	D True Negative (TN)	Negative Predictive Value (NPV) $\frac{TN}{FN + TN} = \frac{D}{C + D}$	Total Negative Results (C + D)	
Sensitivity & Specificity		Sensitivity $\frac{TP}{TP + FN} = \frac{A}{A + C}$		Specificity $\frac{TN}{FP + TN} = \frac{D}{B + D}$		陰性で、病気でない割合
		All diseased patients (A + C)		All non-diseased patients (B + D)		

検査側から


109

ROC(Receiver Operating Characteristic)




110

ROC(Receiver Operating Characteristic)




111


ROC(Receiver Operating Characteristic)and AUC



112



113



114

課題3-1

脳動脈瘤保有による破裂のリスクを評価したい

- N=1027のデータ(data=rapture)

• 下記変数

- Rupture: 動脈瘤破裂の有無
- Male: 男性
- Age: 年齢
- Number aneurysm: 動脈瘤の個数
- Hypertension: 高血圧
- Hyperlipidemia: 脂質異常
- fh SAH: SAHの家族歴
- Bifurcation: 分岐部に瘤あり
- Bleb: 囊胞上の構造あり
- MCA: 中大脳動脈
- VABA: 椎骨基底動脈瘤
- Size: 大きさ

• Logistic回帰を用い、動脈瘤破裂のリスク因子の特定、破裂予測モデルを構築する

- ROC曲線、予測確率プロットなどを示せ

115

Poisson解析

116

Poisson regression

分布:Poisson分布、リンク関数:log

- ポアソン回帰は、カウント(計数)データや分割表をモデル化するために用いられる回帰分析の一般化線形モデル形式である。
- ポアソン回帰は、応答変数Y がポアソン分布を持っていて、その期待値の対数が未知パラメータの線形結合によってモデル化できると仮定する。
- これは、希少事象に適している。
 - 稀な事象
 - 保険金請求率
 - 機器の故障
 - 犯罪の発生

117

117

Poisson distribution


- 歪んでいる
- 非負の値のみをとる
- 分散は平均に等しい

$$f(k; \lambda) = \Pr(X=k) = \frac{\lambda^k e^{-\lambda}}{k!},$$

where

- k is the number of occurrences ($k=0,1,2 \dots$)
- λ is equal to the expected value $E(x)$ of X and also to its variance $V(E)$

$$\lambda = E(X) = \text{Var}(X).$$



118

118

過(剰)分散Over-dispersion

- 結果変数の分散が期待値より大きい
- ポアソン分布の分散の理論値は、期待値と等しい。
- 過分散は、標準誤差の過小評価やカイ二乗統計量の過大評価につながる可能性がある。
注) 過分散の場合、仮定したモデルでは実際のデータより誤差が小さく推定され有意差が出やすくなる。

→過分散のチェックが必要 “Residual deviance(残差逸脱度)”

- なぜ過大分散が起こるのか？
 - モデルに含まれていない重要な効果がある場合、平均値の差を十分に説明できない。
 - 外れ値が存在する。
 - 変数間に正の相関がある

$$\lambda = E(X) = \text{Var}(X).$$

(仮定) 平均と分散が等しい

119

119

過分散の対応

1. モデルの誤差の調整

Dispersion parameter

$$\hat{\phi} = \frac{\text{Pearson}\chi^2}{\text{Residual degrees of freedom}}$$
$$= \frac{\sum_i (y_i - \hat{\mu}_i)^2 / \hat{\mu}_i}{\text{Residual degrees of freedom}}$$

2. Poisson分布よりばらつきの大きな負の二項分布を用いる

120

120

30

例:Open water swimmerの耳の感染

- ニューサウスウェールズ州水道局が1990年に行った「サーフヘルス調査(Pilot Surf/Health Study)」によるものである。
- この研究の目的は、特に、ビーチで泳ぐ人が、ビーチで泳がない人よりも耳の感染症にかかるリスクが高いかどうかを判断することでした。
- データセット(ear_infection)には、5つの変数と287のオブザベーションが含まれる



Variable	Variable Name	Variable Type	Variable Values
Frequent Ocean Swimmer	fos	Categorical	1=Yes 2=No
Location	location	Categorical	1=Non-beach 4=Beach
Age Group	agegroup	Ordinal	2=15 to 19 years 3=20 to 24 years 4=25 to 29 years
Sex	sex	Categorical	1=Male 2=Female
Number of Ear Infections	numearinfections	Continuous	0-17

セーヌ川に許容水準超す大腸菌、水泳には危険レベル パリ五輪




耳の感染頻度

earinfection.csv
earinfection.sav



一般化線形モデル

[標準メニュー]-[統計量]-[モデルへの適合]-[一般化線形モデル]



一般化線形モデル

モデル名を入力: GLM5
変数 (ダブルクリックして式に入れる)
age (因子)
gender (因子)
infections (因子)
location (因子)
swimmer (因子)
モデル式
Operators (click to formula): + * / %in% ^ ()
スプライン多項式: (変数を選択して入力)
B-spline 自然 直交 通常の スプラインの自由度: 5 8
Infections ~ age + gender + location + swimmer
Indices or names of row(s) to remove
<use all valid cases>
部分集合の表現
<全ての有効なケース>
Weights
<変数が選択されていません>
リンク関数 (ダブルクリックで選択)
gaussian
binomial
poisson
Gamma
inverse.gaussian
quasibinomial
quasipoisson
リンク関数
identity
log
sqrt
Poisson回帰
分布:Poisson分布
リンク関数:log

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
    family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      Estimate Std. Error z value Pr(>|z|)
age[T.20-24]    -0.37442    0.12836  -2.917   0.00354 **
age[T.25-29]    -0.18973    0.13009  -1.458   0.14473
gender[T.Male]  -0.08985    0.11231  -0.800   0.42371
location[T.NonBeach] 0.53454    0.10668   5.011 0.00000054269 ***
swimmer[T.Occas] 0.61149    0.10500   5.823 0.00000000577 ***

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 824.51  on 286  degrees of freedom
Residual deviance: 755.43  on 281  degrees of freedom
AIC: 1139.8

Number of Fisher Scoring iterations: 6

> exp(coef(GLM.5)) # Exponentiated coefficients
      (Intercept)      age[T.20-24]      age[T.25-29]      gender[T.Male]      location[T.NonBeach]      swimmer[T.Occas]
      0.8846066      0.6876857      0.8271832      0.9140681      1.7066565      1.8431689
```

年齢
20-24 vs. -19 0.688
25-29 vs. -19 0.827

男vs.女 0.91

場所
海以外vs 海 1.71
頻度
たまにvs.頻回 1.84

過分散
デヴィアンス/DF=755.43/281=2.698
または
Pearsonカイ2乗/DF=3.379853

1を超える場合過分散

125

過分散の対応
Rcode: Diversion parameter

過分散(pearsonカイ2乗/DF)
sum(residuals(GLM.1,type="pearson")^2)/GLM.5\$df.residual

補正計算
dp <- sum(residuals (GLM.5,type="pearson")^2) / GLM.5\$df.res
summary(GLM.5, dispersion=dp)

R「#03 Poisson回帰実施コード.txt」を使用
Rスクリプト画面に貼って実行する。

126

過分散調整

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
    family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      Estimate Std. Error z value Pr(>|z|)
age[T.20-24]    -0.37442    0.25197  -0.487   0.62653
age[T.25-29]    -0.37442    0.23599  -1.587   0.11260
age[T.25-29]    -0.18973    0.23917  -0.793   0.42762
gender[T.Male]  -0.08985    0.20648  -0.435   0.66345
location[T.NonBeach] 0.53454    0.19613   2.725   0.00642 **
swimmer[T.Occas] 0.61149    0.19304   3.168   0.00154 **

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 3.379853)

Null deviance: 824.51  on 286  degrees of freedom
Residual deviance: 755.43  on 281  degrees of freedom
AIC: 1139.8
```

127

過分散調整

調整なし

```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
    family = poisson(log), data = Dataset)

Coefficients:
(Intercept)      Estimate Std. Error z value Pr(>|z|)
age[T.20-24]    -0.37442    0.13706  -0.895   0.37100
age[T.20-24]    -0.37442    0.12836  -2.917   0.00354 **
age[T.25-29]    -0.18973    0.13009  -1.458   0.14473
gender[T.Male]  -0.08985    0.11231  -0.800   0.42371
location[T.NonBeach] 0.53454    0.10668   5.011 0.00000054269 ***
swimmer[T.Occas] 0.61149    0.10500   5.823 0.00000000577 ***

SE(β1)=√(0.105)2× 3.3799 = 0.19305

調整あり



```
Call:
glm(formula = infections ~ age + gender + location + swimmer,
 family = poisson(log), data = Dataset)

Coefficients:
(Intercept) Estimate Std. Error z value Pr(>|z|)
age[T.20-24] -0.37442 0.25197 -0.487 0.62653
age[T.20-24] -0.37442 0.23599 -1.587 0.11260
age[T.25-29] -0.18973 0.23917 -0.793 0.42762
gender[T.Male] -0.08985 0.20648 -0.435 0.66345
location[T.NonBeach] 0.53454 0.19613 2.725 0.00642 **
swimmer[T.Occas] 0.61149 0.19304 3.168 0.00154 **
```


```

平均が決まれば分散も決まってしまうため、実際のばらつきとの間に解離があることが多いため、過分散のチェックが必要

過分散の場合、仮定したモデルでは、
・実際よりも誤差が小さく推定され
・Zvalueが大きくなり有意差が出やすくなる

3.3799 = Pearson/DF 1を超えていると過分散

128

Quasi-poisson

summary(GLM.4, dispersion=db)

#####ヒストグラム#####

windows(width=7, height=7); par(lwd=1, las=1, family="sans

res <- hist(Dataset\$infections, breaks="scott", plot=FALSE)

temp.y <- Dataset[Dataset\$swimmer=="freq", \$infections

temp.h <- hist(temp.y, breaks=res\$breaks, plot=FALSE)\$count

temp.y <- Dataset[Dataset\$swimmer=="Occas", \$infections

temp.h <- hist(temp.y, breaks=res\$breaks, plot=FALSE)\$count

temp.h <- rbind(temp.h, hist(temp.y, breaks=res\$breaks, plot=FALSE)\$count

barplot(temp.h, beside=TRUE, space=c(0, 0.4), names.arg=res\$breaks[-length(res\$breaks)], las=1, col="red", border="black", cex.lab=1.5, cex.main=1.5)

for (i in 1:(length(res\$breaks)-1)) [breaks[i] <- paste(res\$breaks[i],

breaks[i+1], sep=" - ")]

colnames(temp.h) <- breaks

rownames(temp.h) <- levels(as.factor(Dataset\$swimmer))

temp.h

統計量

グラフ

モデル

分布

ツール

ヘルプ

モデルへの適合

一般化線形モデル

129

129

Quasi-Poisson

標準誤差(SE)を過分散の程度に合わせて拡大修正し、正しいP値と信頼区間を計算

モデル名を入力: GLM.6

変数 (ダブルクリックして式に入れる)

age (因子)

gender (因子)

infections

location (因子)

swimmer (因子)

モデル式

infections ~ age + gender + location + swimmer

スプラインの曲線度: 5

スプラインの次数: 2

Indices or names of row(s) to remove

部分集合の削除

重み

リンク関数 (ダブルクリックで選択)

リンク関数

identity

log

sqrt

quasi-poisson

quasi-binomial

quasi-poisson

ヘルプ

リセット

OK

キャンセル

適用

従属変数:infections
独立変数:age gender location swimmer

Quasi-Poisson回帰
分布:quasi-poisson分布
リンク関数:log

130

130

耳の感染頻度

swimmer characteristics
Occasional/frequent swimmers

Location for swimming
Beach/Non-Beach

Counts

infections

swimmer

freq

Occas

Counts

infections

location

Beach

NonBeach

ゼロデータが多い

ゼロデータが多い

131

131

過分散の対応

1. モデルの誤差の調整

• Dispersion parameter

$$\hat{\phi} = \frac{Pearson\chi^2}{Residual\ degrees\ of\ freedom}$$
$$= \frac{\sum_i (y_i - \hat{\mu}_i)^2 / \hat{\mu}_i}{Residual\ degrees\ of\ freedom}$$

2. Poisson分布よりばらつきの大きな負の二項分布を用いる

132

132

33

負の二項分布

```
##negative binominal
install.packages("MASS")
library(MASS)

result_nb<-glm.nb(infections~age + gender + location
+ swimmer, data=Dataset)

summary(result_nb)
exp(coef(result_nb)) # Exponentiated coefficients
```

133

133

負の二項

```
Call:
glm.nb(formula = infections ~ age + gender + location + swimmer,
       data = Dataset, init.theta = 0.5759778332, link = log)

Coefficients:
(Intercept)      Estimate Std. Error z value Pr(>|z|)
age[T.20-24]    -0.06082   0.23914  -0.254  0.79924
age[T.25-29]    -0.42924   0.23433  -1.832  0.06898
age[T.25-29]    -0.26250   0.24050  -1.091  0.27506
gender[T.Male]   -0.14002   0.20789  -0.674  0.50063
location[T.NonBeach] 0.54554   0.19605   2.783  0.00539 **
swimmer[T.Occas] 0.60305   0.18965   3.180  0.00147 **

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(0.576) family taken to be 1)

Null deviance: 289.90  on 286  degrees of freedom
Residual deviance: 269.13  on 281  degrees of freedom
AIC: 904.69

> exp(coef(result_nb)) # Exponentiated coefficients
(Intercept)      age[T.20-24]      age[T.25-29]      gender[T.Male] location[T.NonBeach] swimmer[T.Occas]
0.9409927      0.8510050      0.7691229      0.8693440      1.7255406      1.8276788
```

水泳頻度と場所が有意
リスク比
たまにvs.頻回 1.83
海以外vs.海 1.73

134

134

ゼロ過剰Poisson

```
Zero-inflation model coefficients (binomial with logit link):
      Estimate Std. Error z value Pr(>|z|)
(Intercept)    0.381059   0.334142   1.140  0.2541
age[T.20-24]   -0.004427   0.344180  -0.013  0.9897
age[T.25-29]   -0.024362   0.345686  -0.070  0.9438
gender[T.Male] -0.036735   0.300468  -0.122  0.9027
location[T.NonBeach] -0.725336  0.284673  -2.548  0.0108 *
swimmer[T.Occas] -0.189300  0.277742  -0.682  0.4955
---
```

場所が有意
リスク比
海以外vs.海 1.73

135

135

ゼロ過剰負の二項分布

```
Zero-inflation model coefficients (binomial with logit link):
      Estimate Std. Error z value Pr(>|z|)
(Intercept)   -2.3466    1.7221  -1.363  0.173
age[T.20-24]   0.5716    1.0841   0.527  0.598
age[T.25-29]   0.4764    0.9716   0.490  0.624
gender[T.Male]  1.2528    1.1912   1.052  0.293
location[T.NonBeach] -12.9315  323.6701  -0.040  0.968
swimmer[T.Occas] 0.7042    0.8637   0.797  0.426

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Theta = 0.7894
Number of iterations in BFGS optimization: 56
Log-likelihood: -440.9 on 13 Df
```

136

136

AIC

- Poisson AIC: 1139.8
- 負の二項分布 AIC: 904.69
- ゼロ過剰Poisson AIC: 966.2640
- ゼロ過剰負の二項分布 AIC: 907.8795

137

137

R code ゼロ過剰Poisson, NB

```
## Zero-inflated Poisson
install.packages("pscl")
library(pscl)

result.zi <- zeroinfl(infections~age + gender + location + swimmer, data=Dataset)
summary(result.zi)

## Zero-inflated negative binominal
result.zinb <- zeroinfl(infections~age + gender + location + swimmer,
data=Dataset,dist="negbin")
summary(result.zinb)

## AIC
c(AIC.model1=AIC(GLM.1), AIC.model2=AIC(result.nb),AIC.model3=AIC(result.zi),
AIC.model4=AIC(result.zinb))
```

138

138

課題3-2

- 1987 年と 1988 年に実施された米国医療費調査 (NMES) データ (data=nmes)。
 - メディケア の対象となっている 66 歳以上の個人データ
 - 4,406 名 19変数
- 下記変数を使用し、医療機関受診回数との関連を検討する
 - 従属変数 Visits:医療機関訪問回数
 - 独立変数
 - Hospital 入院期間
 - Health 主観的健康"poor", "average" (reference category), "excellent"
 - Chronic 慢性疾患の有無
 - Adl ADL "limited" or not "normal"
 - Age Age in years (divided by 10) 10歳階級
 - Gender (M, F)
 - Married 結婚しているか(Y,N)
 - School 教育年数
 - Income 世帯収入(USD 10,000)
 - Insurance private insuranceに加入しているか(Y,N)

139

139

第3日目

1. Logistic 脳動脈瘤 例題

2. Poisson NEMS1988 例題

} いずれか提出(追加課題)

140

140

35