

保健統計学実習

第4日目	
第10回	生存時間解析
第11回	主成分分析、クラスター分析、潜在クラス分析
第12回	AI Deep learning演習(1) *Python Collaboratory使用

滋賀医科大学NCD疫学研究センター
医療統計学部門
原田 亜紀子
(aharada@belle.shiga-med.ac.jp)

講義・演習スケジュール

回	日	内容
1	8/27(木)	1 R, EZR の使い方, データセットの読み込み, 頻度集計
		2 記述統計, 相関
		3 エクセルの基礎, Python 設定, 基本コード
2	8/28(金)	4 仮説検定の基礎, カイ2乗検定, マクネマー検定
		5 t 検定, Wilcoxon 検定, サンプルサイズ設計
		6 調査データ解析
3	9/1(火)	7 分散分析
		8 重回帰分析
		9 ロジスティック回帰, Poisson 回帰
4	9/2(水)	10 生存時間解析
		11 クラスター分析
		12 AI Deep learning 演習(1) *Python Collaboratory 使用
5	9/4(金)	13 AI Deep learning 演習(2) *Python Collaboratory 使用
		14 AI Deep learning 演習(3) *Python Collaboratory 使用
		15 解析実習まとめ(復習・課題の時間)

第10回 生存時間解析

解析手法の選択 データの型と解析の目的

		データの型	
		2値	連続
解析の目的	集計・記述		
	1変量 頻度集計	ヒストグラム 要約統計量	Kaplan-Meier法
	2変量 分割表	散布図、相関係数	
	群比較	χ^2 検定	t検定
		Fisher 直接確率検定	Wilcoxon検定
	多群比較	コクランマンテル 検定	分散分析
	モデルあてはめ	ロジスティック回帰	重回帰分析

1)なぜ生存時間？ 例:タモキシフェンと乳がん再発

- 目的
 - 乳がん術後の補助療法としてタモキシフェンを投与することによる再発抑制効果を評価する
- 観察研究
 - タモキシフェン投与群と非投与群の比較
 - 交絡バイアスの存在
 - 例えば、リンパ節転移の影響
- エンドポイント
 - 手術日から乳がん再発までの時間(単位は年)

5

5

1)なぜ生存時間？ 乳がん再発「割合」の比較

- リンパ節転移の有無で層別

リンパ節 転移	TAM 投与	再発		合計
		あり	なし	
なし	あり	96(7.2%)	1239	1335
	なし	171(10.7%)	1424	1595
あり	あり	368(30.3%)	848	1216
	なし	253(33.3%)	507	760

リンパ節転移なし：リスク差=-0.035
リンパ節転移あり：リスク差=-0.030

再発ありで見た場合

6

6

タモキシフェンデータ:再発率

- リンパ節転移「なし」グループ

	再発数	人-年	再発率	(SE)
TAM あり	96	9713.77	0.010	(1.02×10 ⁻³)
投与 なし	171	12599.27	0.013	(0.99×10 ⁻³)

再発率の単位はいずれも、/年

リンパ節転移なし 0.010/0.013=0.77 (95%CI: 0.60,0.99)
リンパ節転移あり 0.94 (95%CI 0.80,1.10)

リンパ節転移「なし」グループ

- TAM投与群 S(t) = exp(-0.010 × t)
- TAM非投与群 S(t) = exp(-0.013 × t)

無再発生存曲線

0.0 0.2 0.4 0.6 0.8 1.0

Years after Operation

7

7

1)なぜ生存時間？ 疾病発生までの時間

- エンドポイント
 - 「一定期間中に疾病を発症するかどうか」よりも、「いつ疾病を発症したか」が問題
 - ある原点(例えば、治療開始やランダム化時点)から当該のイベント発症までの時間
- 再発までの時間を比較(TAM投与群と非投与群で)
- 打ち切りデータを考慮した治療効果の検定、推定

↓

このような目的のための解析

生存時間解析(Survival analysis)

8

8

2)生存時間解析とは？

- ある基準の時刻から、ある目的の反応が起きるまでの時間を解析対象とする
 - 観測対象とする個体に対し、一度だけ非再起的に起きる事象
- 打ち切り(censoring(脱落, 解析時点で生存))を解析で考慮する
 - * 打ち切り時点より後で死亡が起きる
 - イベントの発生はその時点以降という情報を持っている
 - 打ち切りを除外した解析は、バイアスをもたらす。

二つのタイプ:

ランダムな打ち切り: 情報のない打ち切り ……生存時間解析での仮定(重要な前提)
ランダムでない打ち切り: 情報のある打ち切り

A ← 転院(追跡不能) ←

B ← 再発 ←

C ← 再発 ←

D ← 再発 ←

E ← 再発 ←

研究開始 研究終了

3)生存時間解析に必要な情報

必要な情報: ①イベント有無、②イベント発生までの時間

生存時間解析

生存曲線を比較する

登録期間 追跡期間

2010 2016

研究開始 研究終了

「死亡」や「生存」などのアウトカム2値データ

追跡時間データ
・イベント発生までの時間(青)
または
・追跡中に観察された最後の時間(赤)

通常解析と生存時間解析の違い

データの要約方法

通常統計解析

生存時間解析

Estimate representative values of data such as means

Estimating survival curves

群間の比較方法

通常統計解析

生存時間解析

Comparison representative values of data such as means

Comparison of survival curves

4)生存時間分布の要約 ハザードの理解

生存期間を取り扱ううえで重要な測度(関数)

■ 生存時間関数

個体が少なくとも時点 t で生存する確率

時点 t まで生存した割合、
年次生存割合などは、生存時間関数を用いて計算する

$S(t) = \Pr(T > t)$

■ ハザード関数

個体が時点 t まで生存しているという仮定のもとで微小区間 $t \leq T < t + \Delta t$ で死亡する確率

時点 t における死亡リスク、
症例数設計などは、ハザード関数を用いて計算する

死亡する速度、強さ: 単位時間当たりの死亡数

$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t \leq T < t + \Delta t | T \geq t)}{\Delta t}$

■ 確率密度関数 (probability density function)

個体が微小区間 $t \leq T < t + \Delta t$ 内で死亡する確率


$f(t) = \frac{d}{dt} F(t) = -\frac{d}{dt} S(t)$

■ 累積ハザード関数 (cumulative hazard function)

ハザード関数の累積値

1)Kaplan-Meier法とは

- 2種類のデータが必要
 - ①「死亡」や「生存」などのアウトカム2値データ
 - ②観察時間データ
 - アウトカムが起こった被験者: アウトカムの起こった時間
 - アウトカムが起こらなかった被験者: 追跡中に観察された最後の時間
- 中央生存時間
 - Kaplan-Meier法で生存率がちょうど50%になる時間




Kaplan-Meier法による生命表

- 死亡までの時間を調査する小規模な前向きコホート研究を考えてみましょう。
- この研究(老化研究)には20人の参加者がおり、彼らは5年間にわたって登録され、死亡するか、研究が終了するか、あるいは研究から脱落するまで (lost to follow-up) 最長24年間追跡された
- この研究では、6人が死亡し、3人がフォローアップ(すなわち24年間)を完了している
- 残りの11人は、登録が遅れたり、追跡調査ができなくなったたりして、追跡期間が24年未満となっている


Participant Identification Number	Year of Death	Year of Last Contact
1		24
2	3	
3		11
4		19
5		24
6		13
7	14	
8		2
9		18
10		17
11		24
12		21
13		12
14	1	
15		10
16	23	
17		6
18	5	
19		9
20	17	

追跡年	Number at Risk N _t	死亡数 D _t	打ち切りC _t	生存確率 S _{t+1} = S _t * ((N _t - D _t) / (N _t - C _t))
0	20			1
1	20	1		1 * ((20 - 1) / 20) = 0.950
2	19		1	0.950 * ((19 - 0) / 19) = 0.950
3	18	1		0.950 * ((18 - 1) / 18) = 0.897
5	17	1		0.897 * ((17 - 1) / 17) = 0.844
6	16		1	0.844
9	15		1	0.844
10	14		1	0.844
11	13		1	0.844
12	12		1	0.844
13	11		1	0.844
14	10	1		0.760 * 0.844 * ((10 - 1) / 10) = 0.760
17	9	1	1	0.676 * 0.760 * ((9 - 1) / 9) = 0.676
18	7		1	0.676
19	6		1	0.676
21	5		1	0.676
23	4	1		0.507
24	3		3	0.507


Time, Years	Number at Risk N _t	Number of Deaths D _t	Number Censored C _t	Survival Probability S _t	Failure Probability 1 - S _t
0	20			1	0
1	20	1		0.950	0.050
2	19		1	0.950	0.050
3	18	1		0.897	0.103
5	17	1		0.844	0.156
6	16		1	0.844	0.156
9	15		1	0.844	0.156
10	14		1	0.844	0.156
11	13		1	0.844	0.156
12	12		1	0.844	0.156
13	11		1	0.844	0.156
14	10	1		0.760	0.240
17	9	1	1	0.676	0.324
18	7		1	0.676	0.324
19	6		1	0.676	0.324
21	5		1	0.676	0.324
23	4	1		0.507	0.493
24	3		3	0.507	0.493




17



18



19



20

生存時間解析

gehan.csv
gehan.sav

生存時間解析

生存曲線の記述と群間の比較(Logrank検定)

生存期間の傾向の検定(Logrank trend検定)

可逆性イベントの生存解析と累積発生率

生存期間に対する多変量解析(Cox比例ハザード回帰)

時間依存性変数を含む生存期間に対する多変量解析(Cox比例ハザード回帰)

累積発生率(観測イベントを含む)の記述と群間の比較(Gray検定)

累積発生率(観測イベントを含む)に対する多変量解析(Fine-Gray比例ハザード回帰)

時間依存性変数を含む累積発生率に対する多変量解析(Fine-Gray比例ハザード回帰)

```
> (res <- survdiff(Surv(week, remiss==1)~drug, data=Dataset, rho=0, na.action = na.omit))
Call:
survdiff(formula = Surv(week, remiss == 1) ~ drug, data = Dataset,
na.action = na.omit, rho = 0)

      N Observed Expected (O-E)^2/E (O-E)^2/V
drug=8-MP      21      9      19.3      5.46      16.8
drug=CONTROL    21     11     10.7      9.77      16.8
```

21

生存時間解析

生存曲線の記述と群間の比較(Logrank検定)

生存期間の変数(1つ選択)

イベント(1), 打ち切り(0)の変数(1つ選択)

変数の選択はCtrlキーを押しながらクリック、
削除する変数は選択(0~複数選択可)

層別化変数(0~1つ選択)

変数の単位

Post-hoc検定
(比較する群が2つの場合)

オプション

22

Log-rank

Number at risk	0	5	10	15	20	25	30	35
8-MP	21	15	11	8	5	4	1	
CONTROL	21	14	8	4	2	0	0	0

```
> (res <- survdiff(Surv(week, remiss==1)~drug, data=Dataset, rho=0, na.action = na.omit))
Call:
survdiff(formula = Surv(week, remiss == 1) ~ drug, data = Dataset,
na.action = na.omit, rho = 0)

      N Observed Expected (O-E)^2/E (O-E)^2/V
drug=8-MP      21      9      19.3      5.46      16.8
drug=CONTROL    21     11     10.7      9.77      16.8

Chisq= 16.8 on 1 degrees of freedom, p= 0.00004

> km.summary.table <- summary.km(survfit=km, survdiff=res)
> km.summary.table
      サンプル数 生存期間中央値 95%信頼区間  P値
drug=8-MP      21      23      13-NA 0.0000417
drug=CONTROL    21      8       4-11
```

23

23

一般化Wilcoxon (Peto-Peto-Wilcoxon)

Number at risk	0	5	10	15	20	25	30	35
8-MP	21	15	11	8	5	4	1	
CONTROL	21	14	8	4	2	0	0	0

```
> (res <- survdiff(Surv(week, remiss==1)~drug, data=Dataset, rho=1, na.action = na.omit))
Call:
survdiff(formula = Surv(week, remiss == 1) ~ drug, data = Dataset,
na.action = na.omit, rho = 1)

      N Observed Expected (O-E)^2/E (O-E)^2/V
drug=8-MP      21      9      12.00      3.94      14.5
drug=CONTROL    21     11     14.55      7.68      14.5

Chisq= 14.5 on 1 degrees of freedom, p= 0.0001

> km.summary.table <- summary.km(survfit=km, survdiff=res)
> km.summary.table
      サンプル数 生存期間中央値 95%信頼区間  P値
drug=8-MP      21      23      13-NA 0.000143
drug=CONTROL    21      8       4-11
```

24

24

Cox比例ハザードモデル 共変量調整

- 生存時間データのほかに、年齢や性別などの共変量を用いることで、共変量が生存時間に与える影響を調べることができる。

$$h(t|x) = \underbrace{h_0(t)}_{\text{ベースライン}} \underbrace{\exp(a_1x_1 + \dots + a_px_p)}_{\text{対数線形モデル}}$$

- $h_0(t)$ はベースラインハザード関数を、 x は各説明変数を、 a は各パラメーターの推定値を表す。

- ・ カテゴリ間におけるハザード比は、共変量にのみ依存し、時間には依存しない（比例ハザード性：時間によらず比が一定）

- Cox比例ハザードモデルではこの比例ハザード性を前提としている。

25

例)単純なモデル(共変量1つ 性別のみ)で

$$h(t) = h_0(t) \cdot \exp(\beta_1 z_1)$$


$z_1 = 0$: female, $z_1 = 1$: male

女性 $h_f(t) = h_0(t) \cdot \exp(\beta_1 \cdot 0) = h_0(t)$

男性 $h_m(t) = h_0(t) \cdot \exp(\beta_1 \cdot 1)$

$$\frac{h_m}{h_f} = \exp(\beta_1)$$

比例ハザード性が前提
 ベースラインハザードがキャンセル
 ベースラインハザードを設定する必要がない
 →比例ハザード性の確認と、成り立たない場合は
 原因特定と対応を考える必要がある



55

26

膀胱癌データの解析

pcancer.csv
pcancer.sav

N=83


STAGE ステージ:3(53.0%) 4(47.0%)

TREAT 術中照射なし:0(26.5%), あり1(73.5%)

AGE 研究登録時の年齢

27

Cox比例ハザード



28

Cox比例ハザード

モデル名を入力: CoxModel17

変数 (ダブルクリックして式に入れる)

AGE
Age_c (因子)
BU1
CASENO
CENSOR
CH
P
PS

モデル式:

説明変数 SEX + Age_c + STAGE + TREAT

時間 TIME イベント CENSOR

重み付け因子は、strata####と入力する !!!
重み付け因子は、weights####と入力する !!!
Cox回帰のPTW解析では標準誤差は自動的にロバスト推定される

☒ 3レベル以上の因子についてその因子全体のP値の計算(Wald検定)

☒ 比例ハザード仮定の検定を行う

☒ マルコフ連鎖モンテカルロ法によるシミュレーション

☒ ベースラインの生存曲線を表示

☐ モデル解析用に解析結果をアクティブ変数として残す

☐ サブグループ解析のForest plotを表示

☐ AICを用いたステップアップのモデル選択を行う

☐ BICを用いたステップアップのモデル選択を行う

☐ P値を用いたステップアップのモデル選択を行う

☐ 一部のサンプルだけを解析対象とする場合の条件式。例: age>50 & Sex=0 & p_age<50 | Sex=1

☐ 全ての有効なケース

Stage
Age (10歳階級カテゴリー)
を調整し、Treatの効果を検討する

29

	coef	exp(coef)	se(coef)	z	Pr(> z)
SEX[T,1]	-0.02280	0.97746	0.22800	-0.100	0.9204
Age_c[T,40-50]	0.69245	1.99861	1.06685	0.649	0.5163
Age_c[T,50-60]	0.06571	1.06791	1.05757	0.062	0.9505
Age_c[T,60-]	0.48168	1.61880	1.04505	0.461	0.6449
STAGE[T,4]	0.42166	1.52449	0.23345	1.806	0.0709
TREAT[T,1]	-0.61996	0.53796	0.27120	-2.286	0.0223 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	exp(coef)	exp(-coef)	lower .95	upper .95
SEX[T,1]	0.9775	1.0231	0.6252	1.5282
Age_c[T,40-50]	1.9986	0.5003	0.2470	16.1746
Age_c[T,50-60]	1.0679	0.9364	0.1344	8.4867
Age_c[T,60-]	1.6188	0.6177	0.2088	12.5528
STAGE[T,4]	1.5245	0.6560	0.9647	2.4090
TREAT[T,1]	0.5380	1.8589	0.3162	0.9154

治療効果が有意 HR=0.538 (95%CI 0.31-0.92)

30

治療効果のサブグループ解析

← 治療ありが生存に対して予防的

Subgroups	Hazard Ratio	HR	95%-CI
年齢が高い方	Age_c		
	40-50	1.66	[0.40; 6.85]
	50-60	0.44	[0.15; 1.28]
男性	SEX		
	0	0.38	[0.18; 0.80]
	1	0.86	[0.37; 2.02]
ステージ 4	STAGE		
	3	0.66	[0.29; 1.49]
	4	0.48	[0.22; 1.01]

31

第11回

クラスター分析

32

多変量解析

Multivariable: 結果変数は1つ 説明変数が多
Multivariate: 結果変数が2つ以上

Multivariate: 結果変数が2つ以上 第5日目

多変量解析

第4日目まで Multivariable: 結果変数は1つ 説明変数が多

要約

分類

予測

大量の入力データを数学的に効率的に処理し、回帰や分類の予測精度向上に役立てる。

入力（あるいは、出力でも可）の類似するグループを作り、管理を効率化する。

入力に対する出力の関係をモデル化（数式化）し、影響度の評価や出力の予測を行う。

主成分分析

因子分析

クラスター分析

判別分析

回帰分析

主成分分析

因子分析

クラスター分析

判別分析

回帰分析

従来の回帰分析に加えて、機械学習に分類される正則化回帰分析などがある。

33

クラスター分析

変数、対象者を分類する

34

クラスター分析

教師なし分類(クラスタリング)

変数のクラスタリング

数値変数の集合を不連続あるいは階層的なクラスタに分割する

k-means法によるクラスタリング …あらかじめ分類するクラスター数を決定
1つ以上の量的変数から計算された距離に基づいて、不連続なクラスター分析を行う

CLUSTER 距離に基づく階層的クラスタリング

単一連結、完全連結、平均連結、ウォード、セントロイド、密度

35

距離の決め方 いろいろあります

1. Ward法: 「各クラスターに属するケースの平均値を出し、その平均値から各ケースの差を求め、差を2乗したうえで、全クラスターを合算する」(平方和 指標 E)ものである。この値が最も低いものを融合の対象とする

2. グループ間平均連結法: ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)のそれぞれからひとつのケースを選択してできる組み合わせ(AD, AE, AF, BD, BE, BF, CD, CE, CF)の距離を平均し、その値を両クラスター間の距離であるとする。

3. グループ内平均連結法: ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)に属するすべてのケースから作る可能性のある2ケースの組み合わせ(AB, AC, AD, AE, AF, BC, BD, BE, BF, CD, CE, CF, DE, DF, EF)の距離を 平均し、その値を両クラスター間の距離であるとする。


4. 最近隣法: ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)のそれぞれからひとつのケースを選択してできる組み合わせのすべて(A D, AE, AF, BD, BE, BF, CD, CE, CF)の距離のうち最も短いものをもって、両クラスター間の 距離であるとする。

5. 最遠隣法: ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)のそれぞれからひとつのケースを選択してできる組み合わせのすべて (AD, AE, AF, BD, BE, BF, CD, CE, CF)の距離のうち最も長いものをもって、両クラスター間の距離であるとする。

6. 重心法: ひとつのクラスターについて、ケース間の距離の測定に用いる複数の変数の平均で クラスターの座標を求め、これをそのクラスターの重心とする。クラスターを構成するケース数で重み付けを行ったうえでクラスターの重心間の距離を求め、これが最も短いクラスター群を融合させる。

36


“変数”のクラスタリング



37

37

クラスター分析 階層的 対象者を分類



38

38

例:チョコレート・キャンディーデータ

データセット
Candy.Bars.csv
Candy.Bars.sav

各社のチョコレートキャンディ(75銘柄)の栄養素含有量のデータから、その特徴によりいくつかのクラスターに分けたい

- ・階層的クラスター分析
- ・K-means法



39

39

階層的クラスタリング

40

40

①階層クラスタリング Ward法

ブランド名	名前	サービング /pkg	オンス /pkg	カロリー	総脂肪 (g)	飽和 脂肪 (g)	コレステ ロール (g)	塩分 (mg)	炭水 化物 (g)	食物 繊維 (g)	糖分 (g)	タンバ ク質 (g)
M&M/Mars	Snickers Peanut Butter	1	2	310	20	7	5	150	28	1	23	6
Hershey	Cookies 'n' Mint	1	1.55	230	12	6	10	80	27	1	21	4
Hershey	Cadbury Dairy Milk	3.5	5	220	12	8	10	45	24	1	21	3
M&M/Mars	Snickers	3	3.7	170	8	3	5	85	21	1	17	3
Charms	Sugar Daddy	1	1.7	200	2.5	2.5	2	100	43	0	28	1
M&M/Mars	Twix Peanut Butter	1	1.71	260	16	5	5	130	26	2	17	5
Hershey	Twizzler	1	2.2	190	1.5	0	0	150	42	0	24	2
Tobler	Toblerone	1	1.23	190	11	7	5	25	21	0	19	2
Nestle	Crunch	1	1.55	230	12	7	5	60	28	1	23	3
Hershey	Almond Joy	2	3.22	230	13	8	2	85	25	3	17	2
Sherwood	Elana Mint	1	1.6	200	10	6	15	10	29	2	26	2
Hershey	Krackel	1	2.6	390	21	13	10	110	45	1	35	5

[標準メニュー]-[統計量]-[次元解析]
-[クラスター分析]-[階層的クラスタ分析]

データ

オプション

データセット
Candy bars.csv
Candy bars.sav

カロリー、たんぱく質、コレステロール、塩分、炭水化物、食物繊維、糖分

を選択

ワード法、ユークリッド距離

階層的クラスタリング

データ オプション

クラスターリングの方法

変数 (1つ以上選択)

糖質(g)
総脂肪(g)
炭水化物(g)
鉄分(mg)
総脂肪(g)

部分集合の表現

<全ての有効なケース>

オプション選択

クラスターリングの方法


○ クラウド法
○ 完全連結法(最長距離法)
○ McQuitty法
○ 重心法

距離の測定


○ ユークリッド距離
○ ユークリッド距離の平方
○ マンハッタン(市街地)距離
○ 変換しない

☒ デンドログラムを描く

階層的クラスタ



階層的クラスタ



[標準メニュー]-[統計量]-[次元解析]
-[クラスター分析]-[階層的クラスタ要約]

統計量

要約

階層的クラスタ要約

出力

階層的クラスタ要約の結果

クラスター数: 4

クラスターのサイズの表示: ☒

クラスターのバイロット: ☒

ヘルプ リセット OK キャンセル 適用

クラスターの要約(クラスター1~4)

INDICES: 1	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	256.3750	4.5000	4.4375	149.3125	0.9375	31.6875	23.0000
INDICES: 2	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	220.555556	4.333333	3.296236	84.444444	1.000000	30.333333	22.370370
INDICES: 3	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	218.4615385	5.8461538	2.5384615	30.8076923	0.9230769	28.6923077	23.3461538
INDICES: 4	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	415.000000	9.166667	6.666667	52.500000	2.333333	41.000000	31.666667

クラスター分類をデータセットに出力

統計量

要約

階層的クラスタ要約

出力

階層的クラスタ要約の結果

クラスター数: 4

クラスターのサイズの表示: ☒

クラスターのバイロット: ☒

ヘルプ リセット OK キャンセル 適用


データセットにクラスター区分をはきだす

結果	カロリー	コレステロールg	塩分mg	食物繊維g	タンパク質g	炭水化物g	糖分g
INDICES: 1	256.3750	4.5000	149.3125	0.9375	4.4375	31.6875	23.0000
INDICES: 2	220.555556	4.333333	84.444444	1.000000	3.296236	30.333333	22.370370
INDICES: 3	218.4615385	5.8461538	30.8076923	0.9230769	2.5384615	28.6923077	23.3461538
INDICES: 4	415.000000	9.166667	52.500000	2.333333	6.666667	41.000000	31.666667


クラスター1~4

Factor	hclus_label	1	2	3	4	p-value
カロリー	n	16	27	26	6	
コレステロールg	1	256.38 (37.41)	220.56 (37.48)	218.46 (24.77)	415.00 (19.75)	<0.001
タンパク質g	1	4.50 (4.75)	4.33 (4.80)	5.85 (5.06)	9.17 (4.82)	0.212
塩分mg	1	149.31 (24.45)	84.44 (14.83)	30.81 (14.46)	6.67 (2.25)	<0.001
食物繊維g	1	0.94 (0.77)	1.00 (0.88)	0.92 (0.89)	2.33 (1.21)	0.003
炭水化物g	1	31.69 (8.46)	30.33 (8.45)	28.69 (9.54)	41.00 (5.44)	0.024
糖分g	1	23.00 (6.46)	22.37 (6.71)	23.35 (6.29)	31.67 (2.80)	0.040


どのクラスター間で差があるか？
余裕があれば、多重比較で比較してみよう




49



50





51



52


1	2	3	4
M&M/Mars	Snickers Peanut Butter	Hershey Rolo	Hershey Cadbury Dairy Milk
M&M/Mars	Twix Peanut Butter	M&M/Mars 3 Musketeers	M&M/Mars M&M's Peanut
Hershey	Tazlitz	Hershey 5th Avenue	Hershey Elena Mocha
Hershey	Twix Caramel	M&M/Mars Milky Way	Hershey Bar None
Pearson	Peanut Nut Roll	Annabelle Abba-Zabba	Just Born Super Hot Tamales
Brown & Haley	Almond Roca	Hershey Cookies 'n' Mint	Myerson Big Cherry
Leaf	Payday	Nestle Crunch	Annabelle U-No (Green)
Nestle	Butterfinger	Hershey Almond Joy	M&M/Mars Skittles
Hershey	Reese's Peanut Butter Cup	M&M/Mars Mars	M&M/Mars Dove
Leaf	Baby Ruth	Hershey Reese's Peanut Butter Cup Crunchy	Annabelle U-No (Blue)
Leaf	Whoppers	Hershey Whoppers	Hershey Symphony (Blue)
Standard	Peanut Butter GooGoo	Hershey Cadbury Roast Almond	Tootsie Charleston Chew
M&M/Mars	Snickers Munch	M&M/Mars Milky Way Dark	Hershey Milk Chocolate
M&M/Mars	Whatchamacallit	Nabisco Planters Original Peanut Bar	M&M/Mars M&M's Plain
Leaf	Heath	M&M/Mars M&M's Peanut Butter	Hershey Cadbury Fruit & Nut
Annabelle	Big HunK	Hershey Reese's P'ieces	Hershey Kisses
		Hershey Reese's Nutragious	Hershey Symphony (Red)
		M&M/Mars Snickers	Tootsie Toblerone
		Charms Sugar Daddy	Sherwood Elena Mint
		Bit-O-Honey Bit-O-Honey	Nestle Raisinet
		Nestle 100 Grand	Adams & Brook Cup O Gold
		Hershey Skor	Hershey York Peppermint Patty
		M&M/Mars Milky Way Lite	Tootsie Jr Mints
		Weider Tiger Milk	Kisses Almond
		Weider Tiger Sport	M&M/Mars M&M's Almond
		Annabelle Look!	Nestle Chunky
		Hershey Cadbury Caramello	

[illegible]




チョコバーの分類(k-meansで)


1	2	3	4
Hershey Cadbury Dairy Milk	M&M/Mars Snickers Peanut Butter	Hershey Rolo	Hershey Krackel
M&M/Mars M&M's Peanut	M&M/Mars Twix Peanut Butter	Annabelle Abba-Zabba	Hershey Mr. Goodbar
Sherwood Elana Mokka	Hershey Twizzler	Hershey Cookies 'n' Mint	Hershey Golden Collection
Juli Born Super Hot Tamales	Hershey Twix Caramel	Nestle Crunch	Hershey KitKat
Myerson Big Cherry	Pearson Peanut Nut Roll	Hershey Almond Joy	Hershey Special Dark
Annabelle U-No (Green)	Brown & Haley Almond Roca	M&M/Mars Mars	Hershey Milk Chocolate Almond
M&M/Mars Skittles	Leaf Payday	Hershey Bar None	
M&M/Mars Dove	Nestle Butterfinger	Hershey Reese's Peanut Butter Cup Crunchy	
Annabelle U-No (Blue)	Hershey Reese's Peanut Butter Cup	Hershey Symphony (Blue)	
Tootsie Charleston Chew	Nestle Baby Ruth	Hershey Mound	
Hershey Milk Chocolate	M&M/Mars 3 Musketeers	Hershey Cadbury Roast Almond	
M&M/Mars M&M's Plain	Leaf Whoppers	M&M/Mars Milky Way Dark	
Hershey Cadbury Fruit & Nut	Hershey 5th Avenue	Nabisco Planters Original Peanut Bar	
Hershey Kisses	Standard Peanut Butter GooGoo	M&M/Mars M&M's Peanut Butter	
Hershey Symphony (Red)	M&M/Mars Snickers Munch	Hershey Reese's Pieces	
Weider Tiger Sport	M&M/Mars Milky Way	Hershey Reese's Nutrageous	
Hershey Cadbury Caramello	M&M/Mars Whatchamacallit	M&M/Mars Snickers	
Tobler Toblerone	Leaf Heath	Charm Sugar Daddy	
Sherwood Elana Mint	Annabelle Big Hunks	Bit-O-Honey Bit-O-Honey	
Nestle Raisinet		Nestle 100 Grand	
Adams & Bir Cup O' Gold		Hershey Skor	
Hershey York Peppermint Patty		M&M/Mars Milky Way Lite	
Tootsie Jr Mints		Weider Tiger Milk	
Hershey Kisses Almond		Annabelle Look!	
M&M/Mars M&M's Almond			
Nestle Chunky			



クラスター2~5



階層(Wards)法とK-means法




二つの方法での分類の一致度

		K-means			
		1	2	3	4
階層	1	0	16	0	0
	2	2	3	22	0
	3	24	0	2	0
	4	0	0	0	6

レポート課題: クラスター分析の例題

<Candyデータ>
階層クラスター、k-meansクラスターでの各クラスター別の平均値を比較してみる



「Candy_cluster_out.csv」に

- ・階層
- ・k-meansのクラスター情報
- ・チョコバーの属性

がまとめてある。

階層、k-meansのクラスターごとの特徴を比較してみる

→ ANOVA
箱ひげ図

本実習の課題

下記の1、2、3について取り組んで提出してもらい、これらを出席と合わせて評価に用います。

1. 各演習日の課題： 以下の課題を設定しています(4回分設定)。

①解析パッケージR・EZRを用いた解析実施報告

第1日目 血圧区分、箱ひげ図の作成

第2日目 t検定演習(トウモロコシの例)

第3日目 ロジスティックまたはPoisson演習課題

第4日目 クラスター分析

②Googleフォームを用いた調査 調査票の回答:回答する

調査票の作成:リンク先を送付

2.実習で実施した調査票の作成を通じ、解析を行う視点から、調査票作成時に注意すべき点を考察する。(全員)
例:調査項目の設定、コーディングなど

3. 卒業研究を行うまでに、経験、修得しておいたほうがよいこと (全員)

卒業研究でデータ解析を行うことを想定し、統計学、データ解析において、今後必要な知識、トレーニング(本演習の復習を含め)などをあげる。