

保健統計学実習

第4日目

第10回	生存時間解析
第11回	主成分分析、クラスター分析、潜在クラス分析
第12回	AI Deep learning演習(1) *Python Collaboratory使用

滋賀医科大学NCD疫学研究センター
医療統計学部門

原田 亜紀子
(aharada@belle.shiga-med.ac.jp)

第10回 生存時間解析

講義・演習スケジュール

回	日	内容
1	8/27(木)	1 R, EZR の使い方, データセットの読み込み, 頻度集計 2 記述統計, 相関 3 エクセルの基礎, Python 設定, 基本コード
2	8/28(金)	4 仮説検定の基礎, カイ2乗検定, マクネマー検定 5 t 検定, Wilcoxon 検定, サンプルサイズ設計 6 調査データ解析
3	9/1(火)	7 分散分析 8 重回帰分析 9 ロジスティック回帰, Poisson 回帰
4	9/2(水)	10 生存時間解析 11 クラスター分析 12 AI Deep learning 演習(1) *Python Collaboratory 使用
5	9/4(金)	13 AI Deep learning 演習(2) *Python Collaboratory 使用 14 AI Deep learning 演習(3) *Python Collaboratory 使用 15 解析実習まとめ(復習・課題の時間)

解析手法の選択
データの型と解析の目的

解析の目的	データの型		
	2値	連続	生存時間
	集計・記述		
	1変量 頻度集計	ヒストグラム 要約統計量	Kaplan-Meier法
群比較	2変量 分割表	散布図, 相関係数	
	χ^2 検定	t検定	ログランク検定
	Fisher 直接確率検定	Wilcoxon検定	
	多群比較	コクランマンテル 検定	分散分析 ログランク検定
モデルあてはめ	ロジスティック回帰	重回帰分析	Cox回帰

1)なぜ生存時間？ 例:タモキシフェンと乳がん再発

• 目的

• 乳がん術後の補助療法としてタモキシフェンを投与することによる再発抑制効果を評価する

• 観察研究

• タモキシフェン投与群と非投与群の比較

• 交絡バイアスの存在

• 例えば、リンパ節転移の影響

• エンドポイント

• 手術日から乳がん再発までの時間(単位は年)

5

タモキシフェンデータ:再発率

• リンパ節転移「なし」グループ

	再発数	人-年	再発率	(SE)
TAM あり	96	9713.77	0.010	(1.02 × 10 ⁻³)
投与 なし	171	12599.27	0.013	(0.99 × 10 ⁻³)

再発率の単位はいずれも、/年

リンパ節転移「なし」グループ

– TAM投与群 S(t) = exp(-0.010 × t)

– TAM非投与群 S(t) = exp(-0.013 × t)

無再発生存曲線

リンパ節転移なし 0.010 / 0.013 = 0.77 (95%CI: 0.60, 0.99)

リンパ節転移あり 0.94 (95%CI 0.80, 1.10)

7

1)なぜ生存時間？ 乳がん再発「割合」の比較

• リンパ節転移の有無で層別

リンパ節 転移	TAM 投与	再発		合計
		あり	なし	
なし	あり	96 (7.2%)	1239	1335
	なし	171 (10.7%)	1424	1595
あり	あり	368 (30.3%)	848	1216
	なし	253 (33.3%)	507	760

リンパ節転移なし：リスク差 = -0.035

リンパ節転移あり：リスク差 = -0.030

再発ありで見た場合

6

1)なぜ生存時間？ 疾病発生までの時間

• エンドポイント

• 「一定期間中に疾病を発症するかどうか」よりも、「いつ疾病を発症したか」が問題

• ある原点(例えば、治療開始やランダム化時点)から当該のイベント発症までの時間

• 再発までの時間を比較(TAM投与群と非投与群で)

• 打ち切りデータを考慮した治療効果の検定、推定

↓

このような目的のための解析

生存時間解析(Survival analysis)

8

2)生存時間解析とは？


- ある基準の時刻から、ある目的の反応が起きるまでの時間を解析対象とする
 - 観測対象とする個体に対し、一度だけ非再起的に起きる事象
- 打ち切り(censoring(脱落, 解析時点で生存))を解析で考慮する
 - *打ち切り時点より後で死亡が起きる
 - イベントの発生はその時点以降という情報を持っている
 - 打ち切りを除外した解析は、バイアスをもたらす。

二つのタイプ:

- ランダムな打ち切り: 情報のない打ち切り ...生存時間解析での仮定(重要な前提)
- ランダムでない打ち切り: 情報のある打ち切り


研究開始 研究終了

通常の解析と生存時間解析の違い



3)生存時間解析に必要な情報

必要な情報: ①イベント有無、②イベント発生までの時間



4)生存時間分布の要約 ハザードの理解

生存期間を取り扱ううえで重要な測度(関数)

■ 生存時間関数

個体が少なくとも時点 t で生存する確率

時点 t まで生存した割合、年次生存割合などは、生存時間関数を用いて計算する

$S(t) = \Pr(T > t)$

■ ハザード関数

個体が時点 t まで生存しているという仮定のもとで微小区間 $t \leq T < t + \Delta t$ で死亡する確率

時点 t における死亡リスク、症例数設計などは、ハザード関数を用いて計算する

死亡する速度、強さ: 単位時間当たりの死亡数

$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t \leq T < t + \Delta t | T \geq t)}{\Delta t}$

■ 確率密度関数 (probability density function)

個体が微小区間 $t \leq T < t + \Delta t$ 内で死亡する確率


$f(t) = \frac{d}{dt} F(t) = -\frac{d}{dt} S(t)$

■ 累積ハザード関数 (cumulative hazard function)

ハザード関数の累積値

1)Kaplan-Meier法とは

- 2種類のデータが必要
 - ①「死亡」や「生存」などのアウトカム2値データ
 - ②観察時間データ
 - アウトカムが起こった被験者:
アウトカムの起こった時間
 - アウトカムが起こらなかった被験者:
追跡中に観察された最後の時間
- 中央生存時間
 - カプランマイヤー曲線で生存率がちょうど50%になる時間



13

13

追跡年	Number at Risk N_i	死亡数 D_i	打ち切り C_i	生存確率 $S_{i-1} = S_i^* ((N_{i-1}-D_{i-1})/N_{i-1})$
0	20			1
1	20	1		$1^* ((20-1)/20) = 0.950$
2	19		1	$0.950^* ((19-0)/19) = 0.950$
3	18	1		$0.950^* ((18-1)/18) = 0.897$
5	17	1		$0.897^* ((17-1)/17) = 0.844$
6	16		1	0.844
9	15		1	0.844
10	14		1	0.844
11	13		1	0.844
12	12		1	0.844
13	11		1	0.844
14	10	1		$0.760 \cdot 0.844^* ((10-1)/9) = 0.760$
17	9	1	1	$0.676 \cdot 0.760^* ((9-1)/8) = 0.676$
18	7		1	0.676
19	6		1	0.676
21	5		1	0.676
23	4	1		0.507
24	3		3	0.507

15

15

Kaplan-Meier法による生命表

- 死亡までの時間を調査する小規模な前向きコホート研究を考えてみましょう。
- この研究(老化研究)には20人の参加者がおり、彼らは5年間にわたって登録され、死亡するか、研究が終了するか、あるいは研究から脱落するまで (lost to follow-up) 最長24年間追跡された
- この研究では、6人が死亡し、3人がフォローアップ(すなわち24年間)を完了している
- 残りの11人は、登録が遅れたり、追跡調査ができなくなったりして、追跡期間が24年未満となっている

Participant Identification Number	Year of Death <i>Death n=6</i>	Year of Last Contact <i>24</i>
1		24
2	3	
3		11
4		19
5		24
6		13
7	14	
8		2
9		18
10		17
11		24
12		21
13		12
14	1	
15		10
16	23	
17		6
18	5	
19		9
20	17	


14

14


Time, Years	Number at Risk N_i	Number of Deaths D_i	Number Censored C_i	Survival Probability S_i	Failure Probability $1-S_i$
0	20			1	0
1	20	1		0.950	0.050
2	19		1	0.950	0.050
3	18	1		0.897	0.103
5	17	1		0.844	0.156
6	16		1	0.844	0.156
9	15		1	0.844	0.156
10	14		1	0.844	0.156
11	13		1	0.844	0.156
12	12		1	0.844	0.156
13	11		1	0.844	0.156
14	10	1		0.760	0.240
17	9	1	1	0.676	0.324
18	7		1	0.676	0.324
19	6		1	0.676	0.324
21	5		1	0.676	0.324
23	4	1		0.507	0.493
24	3		3	0.507	0.493

16


16




17



19



18



20

生存時間解析

gehan.csv
gehan.sav

R コマンド

ファイル 編集 アクティブデータセット 統計解析 グラフと表 ツール ヘルプ 標準メニュー

データセット: Dataset

R スクリプト R マークダウン

for (i in 1:length(km\$strat))
for (j in 1:length(km\$strat))
title(xlab = "Number at risk",
legend = "topright", legend,
res <- NULL
(res <- survdiff(Surv(week,
km.summary.table <- summary.km(survfit=km, survdiff=res))
km.summary.table

出力

> (res <- survdiff(Surv(week,remiss==1)~drug, data=Dataset, rho=0, na.action = na.omit))
Call:
survdiff(formula = Surv(week, remiss == 1) ~ drug, data = Dataset,
na.action = na.omit, rho = 0)

	N	Observed	Expected	(O-E)^2/E	(O-E)^2/V
drug=6-MP	21	9	19.3	5.46	16.8
drug=CONTROL	21	21	10.7	9.77	16.8

生存期間の解析

生存曲線の記述と群間の比較(Logrank検定)

検定の正確性の評価

生存期間の傾向の検定(Logrank trend検定)

可逆性イベントの生存解析と累積発生率

生存期間に対する多変量解析(Cox比例ハザード回帰)

時間依存性変数を含む生存期間に対する多変量解析(Cox比例ハザード回帰)

累積発生率(観測イベントを含む)の記述と群間の比較(Gray検定)

累積発生率(観測イベントを含む)に対する多変量解析(Fine-Gray比例ハザード回帰)

時間依存性変数を含む累積発生率に対する多変量解析(Fine-Gray比例ハザード回帰)

21

Log-rank

week	6-MP	CONTROL
0	21	21
5	21	15
10	15	11
15	11	8
20	8	5
25	5	4
30	4	1
35	1	0

```
> (res <- survdiff(Surv(week,remiss==1)~drug, data=Dataset, rho=0, na.action = na.omit))  
Call:  
survdiff(formula = Surv(week, remiss == 1) ~ drug, data = Dataset,  
na.action = na.omit, rho = 0)  


|              | N  | Observed | Expected | (O-E)^2/E | (O-E)^2/V |
|--------------|----|----------|----------|-----------|-----------|
| drug=6-MP    | 21 | 9        | 19.3     | 5.46      | 16.8      |
| drug=CONTROL | 21 | 21       | 10.7     | 9.77      | 16.8      |

  
Chisq= 16.8 on 1 degrees of freedom, p= 0.00004  
> km.summary.table <- summary.km(survfit=km, survdiff=res)  
> km.summary.table  
      サンプル数 生存期間中央値 95%信頼区間      P値  
drug=6-MP      21      23      13-NA 0.000417  
drug=CONTROL   21      8      4-11
```

23

生存時間解析

生存曲線の記述と群間の比較(Logrank検定)

観測期間の変数(1つ選択) イベント(1), 打ち切り(0)の変数(1つ選択)
drug remiss
week
群別する変数はChisqを導出する(クリック)
群別する変数を選択(0=複数選択可)
drug remiss
week
層別化変数(0~1つ選択)
drug remiss
week
方法
☒ Logrank
☐ Peto-Peto-Wilcoxon
異なる線の区別
色分け
線幅
線の太さ
凡例の書式
☒ 右上へ横並び
☐ 下部へ横並び
☐ マウス指定へ横並び
X軸の単位
☒ そのまま
☐ 日を月に変換
☐ 日を年に変換
☐ 月を年に変換
Post-hoc検定
(比較する群が2つの場合)
☒ No
☐ Bonferroni
☐ Holm
オプション
☒ 打ち切りをマークで表示する ☐ 95%信頼区間を表示する ☐ 異なる層毎に別の図に表示する ☒ At riskのサンプル数を表示する ☐ Y軸をパーセント表示する
生存率を表示するポイント(観測期間の単位が日で1年生存率なら365) <none>
X軸の範囲(左端,右端) 例: 0,365 <auto> Y軸の範囲(下端,上端) 例: 0,1 <auto>
X軸のラベル <auto> Y軸のラベル <auto>
一部のサンプルだけ解析対象にする場合の条件式. 例: age>50 & Sex==0 & age<50 | Sex==1
<全ての有効なケース>
ヘルプ リセット OK キャンセル 適用

22

一般化Wilcoxon
(Peto-Peto-Wilcoxon)

week	6-MP	CONTROL
0	21	21
5	21	15
10	15	11
15	11	8
20	8	5
25	5	4
30	4	1
35	1	0

```
> (res <- survdiff(Surv(week,remiss==1)~drug, data=Dataset, rho=1, na.action = na.omit))  
Call:  
survdiff(formula = Surv(week, remiss == 1) ~ drug, data = Dataset,  
na.action = na.omit, rho = 1)  


|              | N  | Observed | Expected | (O-E)^2/E | (O-E)^2/V |
|--------------|----|----------|----------|-----------|-----------|
| drug=6-MP    | 21 | 5.12     | 12.00    | 3.94      | 14.5      |
| drug=CONTROL | 21 | 14.55    | 7.68     | 6.16      | 14.5      |

  
Chisq= 14.5 on 1 degrees of freedom, p= 0.0001  
> km.summary.table <- summary.km(survfit=km, survdiff=res)  
> km.summary.table  
      サンプル数 生存期間中央値 95%信頼区間      P値  
drug=6-MP      21      23      13-NA 0.000143  
drug=CONTROL   21      8      4-11
```

24

22

24

6

Cox比例ハザード

モデル名を入力: CoxModel17

変数 (ダブルクリックして式に入れる)

AGE
Age_c (因子)
BMI
CASENO
CENSOR
CH
P
PS

モデル式:

説明変数 SEX + Age_c + STAGE + TREAT

時間 TIME イベント CENSOR

重み付け因子は、weights****で入力する!!!
Cox回帰のPTW解析では標準誤差は自動的にロバスト推定される

☒ 3レベル以上の因子についてその因子全体のP値の計算(Wald検定)

☒ 比例ハザード仮定の検定を行う。

☒ マルチプル比較をプロットする

☒ ベースラインの生存曲線を示す。

☐ モデル解算後に解算結果をアクティブモデルとして残す

☐ サブグループ解析のForest plotを示す

☐ AICを用いたステップアップのモデル選択を行う。

☐ BICを用いたステップアップのモデル選択を行う。

☐ P値を用いたステップアップのモデル選択(減少法)を行う。

☐ 一部のサブグループを除外する場合の条件式。例: age>50 & Sex=0 & p.age<50 | Sex=1

<全ての有効なケース>

ヘルプ リセット OK キャンセル 適用

Stage
Age (10歳階級カテゴリー)
を調整し、Treatの効果を検討する

29

治療効果のサブグループ解析

← 治療ありが生存に対して予防的

Subgroups	Hazard Ratio	HR	95%-CI
年齢が高い方 Age_c	40-50	1.66	[0.40; 6.85]
	50-60	0.44	[0.15; 1.28]
	60-	0.49	[0.24; 0.99]
男性 SEX	0	0.38	[0.18; 0.80]
	1	0.86	[0.37; 2.02]
ステージ4 STAGE	3	0.66	[0.29; 1.49]
	4	0.48	[0.22; 1.01]

31

```
SEX[T.1]      coef exp(coef) se(coef)      z Pr(>|z|)
Age_c[T.40-50] -0.02280  0.97746  0.22800   -0.100  0.9204
Age_c[T.50-60]  0.63245  1.89881  1.06635   0.649  0.5163
Age_c[T.60-]   0.08571  1.08791  1.05757   0.082  0.9505
Age_c[T.60-]   0.48168  1.61880  1.04505   0.461  0.6449
STAGE[T.4]     0.42166  1.52449  0.23345   1.806  0.0709
TREAT[T.1]    -0.61996  0.53796  0.27120  -2.286  0.0223 *
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	exp(coef)	exp(-coef)	lower .95	upper .95
SEX[T.1]	0.9775	1.0231	0.6252	1.5282
Age_c[T.40-50]	1.8986	0.5003	0.2470	16.1746
Age_c[T.50-60]	1.0679	0.9364	0.1344	8.4967
Age_c[T.60-]	1.6188	0.6177	0.2088	12.5528
STAGE[T.4]	1.5245	0.6560	0.9647	2.4090
TREAT[T.1]	0.5380	1.8589	0.3162	0.9154

治療効果が有意 HR=0.538 (95%CI 0.31-0.92)

30

第11回

クラスター分析

32

8

多変量解析


Multivariable: 結果変数は1つ 説明変数が多
Multivariate: 結果変数が2つ以上

Multivariate: 結果変数が2つ以上 第5日目

要約

大量の入力データを数学的に効率的に処理し、回帰や分類の予測精度向上に役立てる。

主成分分析



因子分析



分類

入力（あるいは、出力でも可）の類似するグループを作り、管理を効率化する。

クラスター分析



判別分析




第4日目まで
Multivariable: 結果変数は1つ 説明変数が多

予測

入力に対する出力の関係をモデル化（数式化）し、影響度の評価や出力の予測を行う。

回帰分析



従来の回帰分析に加えて、機械学習に分類される正則化回帰分析などがある。

33

疫学研究でのPCA、FA、クラスター分析の使用例: 食パターンと糖尿病

- 食事調査をもとに、因子分析により食事パターンを抽出
- “伝統パターン”、“洋風パターン”などを抽出し、食事パターンスコアを用いて、糖尿病発症リスクなどを検討する。

	1986	
	Prudent Pattern	Western Pattern
Vegetables†	0.75	—
Dark-yellow vegetables	0.64	—
Cruciferous vegetables	0.63	—
Green leafy vegetables	0.63	—
Legumes	0.63	—
Fruit	0.60	—
Tomatoes	0.54	—
Fish	0.51	—
Whole grains	0.38	—
Poultry	0.36	—
Salad dressing†	0.32	—
Fruit juice	0.32	—
Low-fat dairy products	0.16	—
Wine	—	—
Low-sugar drinks	—	—
Red meat	—	0.64
Processed meat	—	0.61
Refined grains	—	0.48
French fries	—	0.48
High-fat dairy products	—	0.47
Sweets and desserts	—	0.42
Eggs	—	0.42
Condiments	0.16	0.41
High-sugar drinks	—	0.36
Snacks§	—	0.36
Mayonnaise	—	0.34
Butter	—	0.34

伝統型食事パターンに含まれる食品



Dam RM, et al. Ann Intern Med. 2002;136:201-209

35

多変量解析 Multivariate Analysis

目的

- 構造を単純化する(次元の縮約)
- オーディネーションする(座標を与える)

主成分分析
因子分析
多次元尺度法
数量化Ⅱ類(コレスコル分析)

t-SNE,
数量化Ⅲ類

正準相関
PLS
主成分回帰
Reduced Rank Regression


分子生物学系
オミックス系
腸内細菌
ゲノム...

- 潜在構造を探る
 - 因子分析
 - 構造方程式モデリング(SEM)
 - IRT
 - 潜在クラス分析LCA
- 判別する
 - 判別分析
- 数値分類(クラスタリング)する
 - クラスター分析

心理社会系、マーケティング系

AI講義でも扱うかもしれない
→教師なし学習

34



基準

RR for Type 2 Diabetes

Quintile of Western Dietary Pattern Score

Physical Activity

Western dietary pattern スコア

洋食傾向が強く、BMIや身体活動量が少ない人が糖尿病になりやすい

Dam RM, et al. Ann Intern Med. 2002;136:201-209

36

食事調査票から得られた食事パターン

表1 各食事パターンに関連する食品

健康型	欧米型	伝統型
野菜、果物、いも類	肉類、加工肉、パン	ご飯、みそ汁、漬物
大豆製品、きのこ類	果物ジュース、コーヒー	サーモン、塩魚・干物
海そう類、緑茶	紅茶、ソフトドリンク	いか・たこ・えび・貝類
脂の多い魚など	マヨネーズ、ソース、魚介類など	果物・日本酒（男性のみ）

調査票

健康型食事パターン

調査票

欧米型食事パターン

Nanri A, JPHC FFQ Validation Study Group. Reproducibility and validity of dietary patterns assessed by a food frequency questionnaire used in the 5-year follow-up survey of the Japan Public Health Center-Based Prospective Study. J Epidemiol. 2012;22:205-15.

37

37

食事パターンと大腸がんリスクとの関連(JPHC研究)
女性

健康型

欧米型

伝統型

大腸 結腸 近位 遠位 直腸

低⇔スコア⇔高

Shin S, JPHC Study Group. Dietary patterns and colorectal cancer risk in middle-aged adults: A large population-based prospective cohort study. Clin Nutr. 2018;37:1019-26.

<https://epi.ncc.go.jp/jphc/outcome/7948.html>

39

39

食事パターンと大腸がんリスクとの関連(JPHC研究)
男性

健康型

欧米型

伝統型

大腸 結腸 近位 遠位 直腸

低⇔スコア⇔高

Shin S, JPHC Study Group. Dietary patterns and colorectal cancer risk in middle-aged adults: A large population-based prospective cohort study. Clin Nutr. 2018;37:1019-26.

<https://epi.ncc.go.jp/jphc/outcome/7948.html>

38

38

クラスター分析

変数、対象者を分類する

40

40

10

クラスター分析

教師なし分類(クラスタリング)

- 変数のクラスタリング
数値変数の集合を不連続あるいは階層的なクラスタに分割する
- k-means法によるクラスタリング ...あらかじめ分類するクラスター数を決定
1つ以上の量的変数から計算された距離に基づいて、不連続なクラスター分析を行う
- CLUSTER 距離に基づく階層的クラスタリング
単一連結, 完全連結, 平均連結, ウォード, セントロイド, 密度

41

“変数”のクラスタリング

Cluster Analysis

Proportion of Variance Explained

ここで切ると6クラスター

ここで切ると4クラスター

43

距離の決め方 いろいろあります

1. **Ward法**:「各クラスターに属するケースの平均値を出し、その平均値から各ケースの差を求め、差を2乗したうえで、全クラスターを合算する」(平方和 指標 E)ものである。この値が最も低いものを融合の対象とする
2. **グループ間平均連結法**:ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)のそれぞれからひとつのケースを選択してできる組み合わせ (AD, AE, AF, BD, BE, BF, CD, CE, C F)の距離を平均し、その値を両クラスター間の距離であるとする。
3. **グループ内平均連結法**:ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)に属するすべてのケースから作る可能性のある2ケースの組み合わせ (AB, AC, AD, AE, AF, BC, B D, BE, BF, CD, CE, CF, DE, DF, EF)の距離を 平均し、その値を両クラスター間の距離であるとする。
4. **最近隣法**:ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)のそれぞれからひとつのケースを選択してできる組み合わせのすべて (A D, AE, AF, BD, BE, BF, CD, CE, CF)の距離のうち最も短いものをもって、両クラスター間の距離であるとする。
5. **最遠隣法**:ひとつのクラスター(ケース:A, B, C)ともうひとつのクラスター(ケース:D, E, F)のそれぞれからひとつのケースを選択してできる組み合わせのすべて (AD, AE, AF, BD, BE, BF, CD, CE, CF)の距離のうち最も長いものをもって、両クラスター間の距離であるとする。
6. **重心法**:ひとつのクラスターについて、ケース間の距離の測定に用いる複数の変数の平均で クラスターの座標を求め、これをそのクラスターの重心とする。クラスターを構成するケース数で重み付けを行ったうえでクラスターの重心間の距離を求め、これが最も短いクラスター群を融合させる。

42

クラスター分析 階層的 対象者を分類

COMPLETE Linkage

数字は対象者

クラスター間の最大距離

2つのクラスター間の距離は、1つのクラスターの観測値と他のクラスターの観測値の間の最大距離である。


Average Linkage

クラスター間の平均距離

2つのクラスター間の距離は、各クラスターに1つずつあるオブザーベーションのペアの間の平均距離である。


44

階層的クラスター




49

[標準メニュー]-[統計量]-[次元解析]
-[クラスター分析]-[階層的クラスタ要約]



51

階層的クラスター



50

クラスターの要約(クラスター1~4)


INDICES: 1	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	256.3750	4.5000	4.4375	149.3125	0.9375	31.6875	23.0000
INDICES: 2	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	220.555556	4.333333	3.296296	84.444444	1.000000	30.333333	22.370370
INDICES: 3	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	218.4615385	5.8461538	2.5384615	30.8076923	0.9230769	28.6923077	23.3461538
INDICES: 4	カロリー	コレステロールg	タンパク質g	塩分mg	食物繊維g	炭水化物g	糖分g
	415.000000	9.166667	6.666667	52.500000	2.333333	41.000000	31.666667

52

クラスター分類をデータセットに出力

```
# 階層的クラスタリング
hclust <- hclust(dist(model.matrix(c(1 + カロリー) ~ コレステロール + タンパク質 + 炭水化物 + 食物繊維), data = Data, method = "ward.D2"))
# クラスタ数を4に設定
set.seed(123)
clusters <- cutree(hclust, k = 4)
# データセットにクラスター区分を出力
Data$cluster <- clusters
write.csv(Data, "clustered_data.csv", row.names = FALSE)
```


データセットにクラスター区分をはきだす



クラスター1~4

Factor	hclus_label	1	2	3	4	p-value
カロリー	n	256.38 (37.41)	220.56 (37.40)	218.46 (24.77)	415.00 (19.75)	<.001
コレステロール	n	4.50 (6.79)	4.33 (4.80)	5.17 (4.82)	9.17 (4.82)	0.212
タンパク質	n	4.44 (2.13)	3.30 (1.88)	2.54 (1.30)	6.67 (2.25)	<.001
炭水化物	n	149.31 (24.45)	84.44 (14.83)	30.81 (14.96)	62.90 (34.50)	<.001
食物繊維	n	0.94 (0.77)	1.00 (0.88)	0.92 (0.88)	2.33 (1.21)	0.003
塩分	n	31.89 (8.40)	30.39 (8.45)	28.09 (8.54)	41.00 (5.44)	0.024

どのクラスター間で差があるか？
余裕があれば、多重比較で比較してみよう




[塩分] 分散分析

```
> summary(AnovaModel.2)
factor(hclus.label) Df Sum Sq Mean Sq F value Pr(>F)
Residuals          71  26362      371
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary.anova
      平均 標準偏差      P値
hclus.label=1 149.31250 24.44509 1.01e-28
hclus.label=2  84.44444 14.82807
hclus.label=3  30.80769 14.95866
hclus.label=4  52.50000 34.89269


      diff      lwr      upr      p adj
2-1 -64.86806 -80.862152 -48.873959 0.0000000
3-1 -118.50481 -134.612945 -102.396670 0.0000000
4-1 -96.81250 -121.081008 -72.543992 0.0000000
3-2 -53.63675 -67.566291 -39.707214 0.0000000
4-2 -31.94444 -54.825013 -9.063876 0.0025470
4-3  21.69231 -1.268123  44.652739 0.0708733
```



チョコバーの分類(階層クラスタで)

	1		2		3		4	
M&M/Mars	Snickers Peanut Butter	Hershey	Rolo	Hershey	Cadbury Dairy Milk	Hershey	Krackel	
M&M/Mars	Twix Peanut Butter	M&M/Mars	3 Musketeers	M&M/Mars	M&M's Peanut	Hershey	Mr. Goodbar	
Hershey	Twizzler	Hershey	5th Avenue	Sherwood	Elena Mocca	Hershey	Golden Collection	
Hershey	Twix Caramel	M&M/Mars	Milky Way	Hershey	Bar None	Hershey	KiKat	
Pearson	Peanut Nut Roll	Annabelle	Abba-Zabba	Just Born	Super Hot Tamales	Hershey	Special Dark	
Brown & Haley	Almond Roca	Hershey	Cookies 'n' Mint	Myerson	Big Cherry	Hershey	Milk Chocolate Almond	
Leaf	Payday	Nestle	Crunch	Annabelle	U-No (Green)			
Nestle	Butterfinger	Hershey	Almond Joy	M&M/Mars	Skittles			
Hershey	Reese's Peanut Butter Cup	M&M/Mars	Mars	M&M/Mars	Dove			
Nestle	Baby Ruth	Hershey	Reese's Peanut Butter Cup Crunchy	Annabelle	U-No (Blue)			
Leaf	Whoppers	Hershey	Mound	Hershey	Symphony (Blue)			
Standard	Peanut Butter GooGoo	Hershey	Cadbury Roast Almond	Tootsie	Charleston Chew			
M&M/Mars	Snickers Munch	M&M/Mars	Milky Way Dark	Hershey	Milk Chocolate			
M&M/Mars	Whatchamacallit	Nabisco	Planters Original Peanut Bar	M&M/Mars	M&M's Plain			
Leaf	Heath	M&M/Mars	M&M's Peanut Butter	Hershey	Cadbury Fruit & Nut			
Annabelle	Big HunK	Hershey	Reese's Pieces	Hershey	Kisses			
		Hershey	Reese's Nutrageous	Hershey	Symphony (Red)			
		M&M/Mars	Snickers	Tobler	Toblerone			
		Charm	Sugar Daddy	Sherwood	Elena Mint			
		Bit-O-Honey	Bit-O-Honey	Nestle	Raisinets			
		Nestle	100 Grand	Adams & Brook	Cup O Gold			
		Hershey	Skor	Hershey	York Peppermint Patty			
		M&M/Mars	Milky Way Lite	Tootsie	Jr Mints			
		Weider	Tiger Milk	Hershey	Kisses Almond			
		Weider	Tiger Sport	M&M/Mars	M&M's Almond			
		Annabelle	Lo&K	Nestle	Chunky			
		Hershey	Cadbury Caramello					

バイプロット



塩分、カロリーで特徴が

クラスター4:カロリー

クラスター1:塩分

k-means法

K-means法

[標準メニュー]-[統計量]-[次元解析]

-[クラスター分析]-[k-平均クラスタ分析]

Rコマンド

データセット: Dataset

スクリプト: Rマークダウン

出力

61

ファイル編集アクティブデータセット統計解析グラフと表ツールヘルプ標準メニュー

データセット: Dataset

スクリプト: Rマークダウン

出力

61

61

K-means法

new.x.カロリーnew.x.コレステロールgnew.x.たんぱく質new.x.塩分mgnew.x.食物繊維gnew.x.炭水化物gnew.x.糖分g

1211.73085.6538462.53846230.615380.923076928.6538523.07692

2259.05264.4210534.210526141.263160.947368433.3684224.78947

3221.25004.5833333.33333382.916671.000000028.8750021.16667

4415.00009.1666676.66666752.500002.333333341.0000031.66667

63

K-means法

new.x.カロリーnew.x.コレステロールgnew.x.たんぱく質new.x.塩分mgnew.x.食物繊維gnew.x.炭水化物gnew.x.糖分g

1211.73085.6538462.53846230.615380.923076928.6538523.07692

2259.05264.4210534.210526141.263160.947368433.3684224.78947

3221.25004.5833333.33333382.916671.000000028.8750021.16667

4415.00009.1666676.66666752.500002.333333341.0000031.66667

63

63

データ

オプション

データオプション

オプション

62

データ

オプション

データオプション

オプション

62

62

k-means法による

4つのクラスター

カロリー

塩分

64

k-means法による

4つのクラスター

カロリー

塩分

64

64

チョコバーの分類(k-meansで)

1		2		3		4	
Hershey	Cadbury Dairy Milk	M&M/Mars	Snickers Peanut Butter	Hershey	Rolo	Hershey	Kracker
M&M/Mars	M&M's Peanut	M&M/Mars	Twix Peanut Butter	Annabelle	Alba-Zabba	Hershey	Mr. Goodbar
Sherwood	Elena Mocca	Hershey	Twizzler	Hershey	Cookies 'n' Mint	Hershey	Golden Collection
Just Born	Super Hot Tamales	Hershey	Twix Caramel	Nestle	Crunch	Hershey	KiKat
Myerson	Big Cherry	Pearson	Peanut Nut Roll	Hershey	Almond Joy	Hershey	Special Dark
Annabelle	U-No (Green)	Brown & Haley	Almond Roca	M&M/Mars	Mars	Hershey	Milk Chocolate Almond
M&M/Mars	Skittles	Leaf	Playday	Hershey	Bar None		
M&M/Mars	Dove	Nestle	Butterfinger	Hershey	Reese's Peanut Butter Cup Crunchy		
Annabelle	U-No (Blue)	Hershey	Reese's Peanut Butter Cup	Hershey	Symphony (Blue)		
Tootsie	Charleston Chew	Nestle	Baby Ruth	Hershey	Mound		
Hershey	Milk Chocolate	M&M/Mars	3 Musketeers	Hershey	Cadbury Roast Almond		
M&M/Mars	M&M's Plain	Leaf	Whoppers	M&M/Mars	Milky Way Dark		
Hershey	Cadbury Fruit & Nut	Hershey	5th Avenue	Nabisco	Planters Original Peanut Bar		
Hershey	Kisses	Standard	Peanut Butter GooGoo	M&M/Mars	M&M's Peanut Butter		
Hershey	Symphony (Red)	M&M/Mars	Snickers Munch	Hershey	Reese's Pieces		
Weider	Tiger Sport	M&M/Mars	Milky Way	Hershey	Reese's Nutrageous		
Hershey	Cadbury Caramello	M&M/Mars	Whatchamacallit	M&M/Mars	Snickers		
Tabler	Tablerone	Leaf	Heath	Charms	Sugar Daddy		
Sherwood	Elena Mint	Annabelle	Big Hank	Nestle	Bit-O-Honey		
Nestle	Raisinet			Nestle	100 Grand		
Adams & Bro	Cup O Gold			Hershey	Skor		
Hershey	York Peppermint Patty			M&M/Mars	Milky Way Lite		
Tootsie	Jr Mints			Weider	Tiger Milk		
Hershey	Kisses Almond			Annabelle	Look!		
M&M/Mars	M&M's Almond						
Nestle	Chunky						

65

クラスター2~5

67

Rでの出力例: k-means法による

```
## k-means
km<-kmeans(data,4)
result2 <- km$cluster
write.csv(result2,"result2.csv")

# plot
library(cluster)
clusplot(data, km$cluster, color=TRUE,
shade=TRUE, labels=2, lines=0)

# data出力
table2 <- table(answer, result2)
write.csv(table2,"table2.csv")
```

66

階層(Wards)法とK-means法

	k-means						
	カロリー	コレステロ	タンパク質	塩分mg	食物繊維g	炭水化物g	糖分g
	1	211.73	5.65	2.54	30.62	0.92	28.65
	2	259.05	4.42	4.21	141.26	0.95	33.37
	3	221.25	4.58	3.33	82.92	1.00	28.88
	4	415.00	9.17	6.67	52.50	2.33	41.00

	階層的						
	カロリー	コレステロ	タンパク質	塩分mg	食物繊維g	炭水化物g	糖分g
	1	256.38	4.50	4.44	149.31	0.94	31.69
	2	220.56	4.33	3.30	84.44	1.00	30.33
	3	218.46	5.85	2.54	30.81	0.92	28.69
	4	415.00	9.17	6.67	52.50	2.33	41.00

68

二つの方法での分類の一致度

		K-means			
		1	2	3	4
階層	1	0	16	0	0
	2	2	3	22	0
	3	24	0	2	0
	4	0	0	0	6

69

余力のある人向け


以下、ワインの成分データを示す。
「Wine.xlsx」

階層型クラスター
K-meams
等を用い、3-4クラスター程度に分類し特徴を説明せよ

71

レポート課題: クラスター分析の例題

<Candyデータ>
階層クラスター、k-meansクラスターでの各クラスター別の平均値を比較してみる



「Candy.cluster.out.csv」に
・階層
・k-meansのクラスター情報
・チョコパの属性
がまとめてある。

階層、k-meansのクラスターごと
の特徴を比較してみる

→ ANOVA
箱ひげ図

70

例 Wine data

これらのデータは、イタリアの同一地域で栽培された異なる品種から得られたワインの化学分析結果である。この分析結果は、各ワイン中の13成分の含有量を示す。

分類	成分例	主な役割
アルコール・酸	Alcohol, Malic acid	味の骨格、酸味やボディ
ミネラル	Ash, Alcalinity, Magnesium	緩衝能、発酵サポート
フェノール類	Total phenols, Flavanoids, Nonflavanoid phenols, Proanthocyanins	色・渋み・抗酸化性
色関連	Color intensity, Hue	外観、熟成指標
その他	OD280/OD315, Proline	熟成状態、構成成分

- 1) Alcohol
- 2) Malic acid
- 3) Ash
- 4) Alcalinity of ash
- 5) Magnesium
- 6) Total phenols
- 7) Flavanoids
- 8) Nonflavanoid phenols
- 9) Proanthocyanins
- 10) Color intensity
- 11) Hue
- 12) OD280/OD315 of diluted wines
- 13) Proline

72

1) Alcohol(アルコール) 意味:ワイン中のエタノール濃度(%または体積比)。 役割:味わいに「甘み」「ボディ」「温かみ」を与える。発酵で糖分がアルコールに変わるため、ブドウの糖度とも関係。	8) Nonflavanoid phenols(非フラボノイド系フェノール) 意味:フェノールのうち、フラボノイド以外の成分(例えば、ヒドロキシ桂皮酸類など)。 役割:抗酸化性に寄与し、ワインの酸化安定性や熟成に影響。
2) Malic acid(リンゴ酸) 意味:ブドウに天然に含まれる有機酸の一種。 役割:ワインの酸味を構成する主要素。マロラクティック発酵によって乳酸に変わり、味がまろやかになる。	9) Proanthocyanins(プロアントシアニン) 意味:縮合型タンニンとも呼ばれるフェノール化合物群。 役割:渋み、苦味、色の安定性に関与。熟成によりポリマー化して渋みが柔らぐ。
3) Ash(灰分) 意味:ワインを燃焼させた後に残る無機物(ミネラル分)。 役割:カリウム、カルシウム、マグネシウムなどの総量を反映し、ミネラル感やバランスに影響。	10) Color intensity(色の濃度) 意味:ワインの色の強さ。通常は可視光領域の吸光度(例:420nm+520nm+620nm)で測定。 役割:ブドウ品種、熟成、醸造方法を反映し、赤ワインでは濃いほど若い傾向。
4) Alcalinity of ash(灰分のアルカリ度) 意味:灰分中のアルカリ性成分(主に金属イオン)の含有量を示す。 役割:ワインの緩衝能(酸を中和する力)を反映し、酸味の感じ方に関係。	11) Hue(色相) 意味:ワインの色の調(赤み～茶色み)の比率。一般に 420nm/520nm の吸光度比で求める。 役割:ワインの熟成度の指標。若い赤ワインは紫～赤、熟成が進むとオレンジ～茶色に変化。
5) Magnesium(マグネシウム) 意味:ミネラルの一種で、灰分中に含まれる主要成分。 役割:発酵に必要な酵母の栄養源。味やミネラル感にも寄与。	12) OD280/OD315 of diluted wines(希釈ワインのOD280/OD315比) 意味:280nmと315nmの波長における吸光度の比。 役割:ワイン中のタンパク質結合性フェノールの指標。熟成状態やポリフェノール組成のバランスを見るために使用。
6) Total phenols(総フェノール) 意味:ワイン中に含まれるすべてのフェノール化合物の量。 役割:渋み(タンニン)、色、抗酸化性、熟成ポテンシャルに影響。	13) Proline(プロリン) 意味:ブドウ由来のアミノ酸の一種。 役割:発酵中に酵母が消費しにくいため、残存量が高くなりやすい。ワインのボディ感や熟成ポテンシャルの目安にもなる
7) Flavanoids(フラボノイド類) 意味:総フェノールの中の一部で、特に赤ワインの色と渋みの主要成分。 役割:アントシアニンやタンニンを含み、色の安定性や味の複雑さに寄与。	

73

73

品質と成分の関係イメージ

・高品質ワイン:

- ・ アルコール・酸・フェノール・ミネラルのバランスが良い。
- ・ プロリン・総フェノールが高く、色や香りが安定。

・若いワイン:

- ・ 色濃度が強く、Hue値が低い(赤味・紫味)。
- ・ プロアントシアニンやマリック酸が多め。

・熟成ワイン:

- ・ Hue値が高く(赤→茶)、フェノール構造が変化し渋みがまろやか

75

75

成分	主な特徴・役割	赤ワインとの関係	白ワインとの関係	品質・熟成への影響
1) Alcohol(アルコール)	ボディ感、甘味、温かみを与える	一般に高め(発酵完了度が高い)	やや低め(爽やかさ重視)	適度なアルコールはバランス良く、過多だと重たく感じる
2) Malic acid(リンゴ酸)	フレッシュな酸味	熟成やマロラクティック発酵で減少	フレッシュ感を保つため残りやすい	酸のバランスと熟成安定性に影響
3) Ash(灰分)	ミネラル含量の指標	豊富(皮や種由来)	少なめ	高すぎると硬い印象。適度でミネラル感が良好
4) Alcalinity of ash(灰分のアルカリ度)	酸を中和する力を示す	やや高め(酸味が柔らかい)	低め(シャープな酸味)	緩衝能が高いほど酸味がまろやか
5) Magnesium(マグネシウム)	酵母栄養源、ミネラル感	多め	少なめ	発酵の安定性に寄与
6) Total phenols(総フェノール)	渋み、抗酸化性、色安定性	非常に高い(皮・種から抽出)	低い	多いほど色と構造が豊か、熟成ポテンシャル↑
7) Flavanoids(フラボノイド類)	渋みと色の主成分	豊富(特にカベルネ系)	ほぼなし	赤ワインの骨格・タンニン感を形成
8) Nonflavanoid phenols(非フラボノイド系)	抗酸化性、酸化安定性	中程度	やや多め(酸化防止に重要)	白ワインの酸化安定性を支える
9) Proanthocyanins(プロアントシアニン)	タンニン、渋み	多い(種・皮由来)	ごく少ない	熟成で渋みが柔らくなる
10) Color intensity(色の濃度)	色の鮮やかさ・深み	高い(濃い赤・紫)	低い(薄い黄～金色)	熟成で徐々に低下
11) Hue(色相)	色調(若さ・熟成度)	若いと紫、熟成でレンガ色	若いと緑がかり、熟成で金色～琥珀色	熟成度のよい指標
12) OD280/OD315	フェノール熟成指標	熟成に伴い比が変化	同様だが変化幅は小さい	熟成ポテンシャルを推定可能
13) Proline(プロリン)	アミノ酸、旨味要素	含有量が高い(糖度高いブドウ)	やや低い	ボディ感・旨味・熟成の深みに関与

74

74

成分	赤ワイン (Red)	白ワイン (White)	ロゼワイン (Rosé)	単位
1) Alcohol (アルコール)	12.5-14.5	11.0-13.5	11.5-13.5	% vol
2) Malic acid (リンゴ酸)	0.1-0.4	1.0-3.0	0.5-1.5	g/L
3) Ash(灰分)	2.0-3.0	1.5-2.5	1.8-2.8	g/L
4) Alcalinity of ash (灰分のアルカリ度)	15-25	10-20	12-22	meq/L
5) Magnesium (マグネシウム)	90-150	60-120	70-130	mg/L
6) Total phenols (総フェノール)	1,800-3,000	200-400	800-1,200	mg GAE/L(ガ口酸当量)
7) Flavanoids (フラボノイド類)	800-1,500	20-80	200-500	mg/L
8) Nonflavanoid phenols (非フラボノイド系)	100-300	150-250	120-200	mg/L
9) Proanthocyanins (プロアントシアニン)	500-1,200	10-50	150-400	mg/L
10) Color intensity (色の濃度)	8-14	0.2-0.8	1-4	吸光度(OD値)
11) Hue(色相)	0.5-0.8(若) → 1.0+(熟)	1.0-1.2	0.9-1.1	OD420/OD520
12) OD280/OD315	1.5-2.5	0.8-1.5	1.0-2.0	比
13) Proline(プロリン)	400-1,200	200-600	300-800	mg/L

Wine Composition Comparison (Red / White / Rosé)



76

76

項目	赤ワイン	白ワイン
主な特徴	タンニンと色素が豊富、骨格がしっかり	酸味とフレッシュさが中心
フェノール類	多い(色と渋み)	少ない(透明感重視)
酸のタイプ	まろやか(マロラクティック発酵)	シャープ(リンゴ酸が残る)
熟成ポテンシャル	高い(抗酸化性強)	中程度(酸化にやや弱い)
プロリン含量	高め	低め
色変化	紫→赤→レンガ	緑がかり→金→琥珀

🍷 品質と成分の関係イメージ

- **高品質ワイン**：
 - ・ アルコール・酸・フェノール・ミネラルの**バランスが良い**。
 - ・ プロリン・総フェノールが高く、色や香りが安定。
- **若いワイン**：
 - ・ 色濃度が強く、Hue値が低い（赤味・紫味）。
 - ・ プロアントシアニンやマリック酸が多め。
- **熟成ワイン**：
 - ・ Hue値が高く（赤→茶）、フェノール構造が変化し渋みがまろやか

本実習の課題

下記の1、2、3について取り組んで提出してもらい、これらを出席と合わせて評価に用います。

1. 各演習日の課題：以下の課題を設定しています(4回分設定)。

①解析パッケージR・EZRを用いた解析実施報告

第1日目 血圧区分、箱ひげ図の作成

第2日目 t検定演習(トウモロコシの例)

第3日目 **ロジスティックまたはPoisson演習課題**

第4日目 クラスター分析

第5日目 混同行列

②Googleフォームを用いた調査 調査票の回答:回答する

調査票の作成:リンク先を送付

2. 実習で実施した調査票の作成を通じ、解析を行う視点から、調査票作成時に注意すべき点を考察する。(全員)

例:調査項目の設定、コーディングなど

3. 卒業研究を行うまでに、経験、修得しておいたほうがよいこと (全員)

卒業研究でデータ解析を行うことを想定し、統計学、データ解析において、今後必要な知識、トレーニング(本演習の復習を含め)などをあげる。

